新加坡历史降雨：时空规律与概率预测

Task 1 与 2：2017–2024 年 Spark 探索与概率预测

小组成员。潘禹翔、侯佳成、吴嘉蕊。

研究内容。本项目利用 2017–2024 年的新加坡降雨观测数据分析时间与空间变化规律，并建立模型，预测监测站在未来 30 分钟内累计雨量超过给定阈值的概率。

数据与方法。使用 NEA / data.gov.sg 的八个年度数据集，源记录共 48,538,713 条，去重后 48,538,627 条，涉及 91 个站点 ID。全量清洗和聚合由 Spark 执行；跨年比较采用 21 个稳定站点，避免监测网络变化混入年度差异。

主要结果。全部有效五分钟区间中 97.08% 无雨。合格日内样本的雨频高峰为新加坡时间 16:00–17:00。月度可用样本平均雨频以 11 月最高、7 月最低，但各月的可用年份及站点组成不完全相同。固定站点样本中，按观测时长归一化的雨量以 2019 年最低、2021 年最高。近距离站点的日雨量相关性总体高于远距离站点；八年不能据此推断长期气候变化。

年份	雨量 / 观测 24h（mm）	雨频（%）	湿区间雨强（mm/5min）	平均覆盖率（%）
2017	6.85	2.85	0.833	94.6
2018	7.10	2.90	0.840	82.9
2019	4.81	1.97	0.841	94.7
2020	7.40	2.92	0.877	95.3
2021	7.84	3.04	0.895	97.8
2022	7.71	3.08	0.868	99.0
2023	7.52	3.16	0.824	95.2
2024	7.11	3.01	0.819	95.6

表中各年均使用相同的 21 个站点，站点等权。雨量指标按观测时长归一化，不能解释为官方年度累计或真实日累计。月度图和日内图的合格样本组成仍可变化。

1. 数据来源、字段与清洗

来源与字段。每条记录包含 observation timestamp、update timestamp、station ID/name/device ID、经纬度、reading update timestamp、reading value、reading type、reading unit 及日期字段。本数据只有降雨相关观测，不包含气温、湿度和风等变量。API 预览只用于确认字段和年度 ID；所有天气结论来自完整文件。

数据核对。下载完整年度 CSV 后，将 Spark 读入的记录数与年度 API 元数据的记录数核对，并检查重复观测、时间对齐和雨量取值。

清洗步骤。Spark 按 Asia/Singapore 解析时间；保留有限、非负、单位为 mm、类型为预期五分钟累计、站点 ID 和时间合法且 CSV 记录有效的行。只有与五分钟网格的距离不超过两秒时才对齐，原始 epoch 同时保留；其他离网格记录排除并审计。按 station ID 与对齐时刻去重，优先保留 reading update 最新的行，再使用原始观测时刻及确定的字段顺序打破并列。年度文件合并后再次检查跨文件重复。

年份	源记录数	删除重复数	偏离网格超过 2 秒	负雨量数	站点数
2017	5,256,106	86	0	0	62
2018	4,594,246	0	0	0	56
2019	5,026,862	0	0	0	54
2020	6,334,473	0	0	0	80
2021	7,044,646	0	0	0	76
2022	7,133,230	0	0	0	72
2023	6,742,890	0	0	0	74
2024	6,406,260	0	0	0	70

清洗结果。86 条重复记录全部来自 2017 年；八年数据中未发现负雨量、偏离五分钟网格超过两秒的时间戳或跨文件重复。缺失时段不计为零雨量。对超过 50 mm/5min 的读数进行额外筛查，本次没有触发该条件的记录。

2. 指标定义与公平比较

设站点在给定时间段内的有效观测数为 N，雨量为 $r_i \geq 0$，有雨区间数为 $W = \sum_i \mathbf{1}(r_i > 0)$，预期日历槽数为 E。本文使用：

$$\begin{aligned} \text{覆盖率} &= N/E, \qquad E = 288 \times \text{日历天数}, \\ \text{雨频（\%）} &= 100W/N, \\ \text{湿区间雨强（mm/5min）} &= \sum_i r_i/W \quad (W > 0), \\ \text{雨量 / 观测 24h（mm）} &= 288 \sum_i r_i/N. \end{aligned}$$

预期日历槽数显式处理闰年；低覆盖率也可能反映站点只运行了部分年份。雨强的分母仅包含有雨区间。对于单个站点和同一时间段，归一化雨量等于 288 × 雨频/100 × 湿区间雨强。分别取站点平均后，该乘积恒等式一般不再成立。归一化雨量不是官方日累计或年度累计，也不能恢复遗漏风暴。

年度固定样本。八年共出现 91 个站点 ID，其中 21 个同时满足：八年均有观测、每年覆盖率至少 80%、经纬度跨度各不超过 0.005°。其余 70 个只是不进入固定站点的跨年比较，清洗时没有删除这些站点的有效观测。21 个站点等权平均；不同分析使用的站点范围见下一页。

月度与日内样本。图 2、4 从这 21 个站点中进一步筛选数据完整的年月或小时组合。月度先对站点等权平均，再对可用年份等权平均；每个合格年月有 17–21 个站点，各月有 6–8 个可用年份。严格要求同站点同月份在八年均达标时，只剩 5、6、7、9、10、12 月，作为额外对照。

空间比较。图 1 使用 2024 年的站点，当年共 70 个，其中 56 个覆盖率至少 90%，用于地图着色，另 14 个以灰色标记。图 5 使用固定 21 站的日累计，要求日覆盖率至少 95%，每对至少有 365 个共同有效日期。80%、90%、95% 是本项目选定的数据完整程度门槛。

3. 计算环境与各项分析的样本范围

计算环境。Task 1 使用 Apple Silicon Mac：10 个逻辑 CPU、16 GiB RAM，macOS 26.5.2 ARM64，Python 3.12.14、Java Temurin 17.0.20.1+1、Spark 3.5.8。Task 2 在 gpushare 运行，环境为 Python 3.11.10、Azul Zulu Java 17.0.20.1、Spark 3.5.8、XGBoost 3.2.0。gpushare 容器配额为 42 CPU、约 667.68 GiB RAM；本项目限定使用两个 CPU，driver heap 为 2 GiB。

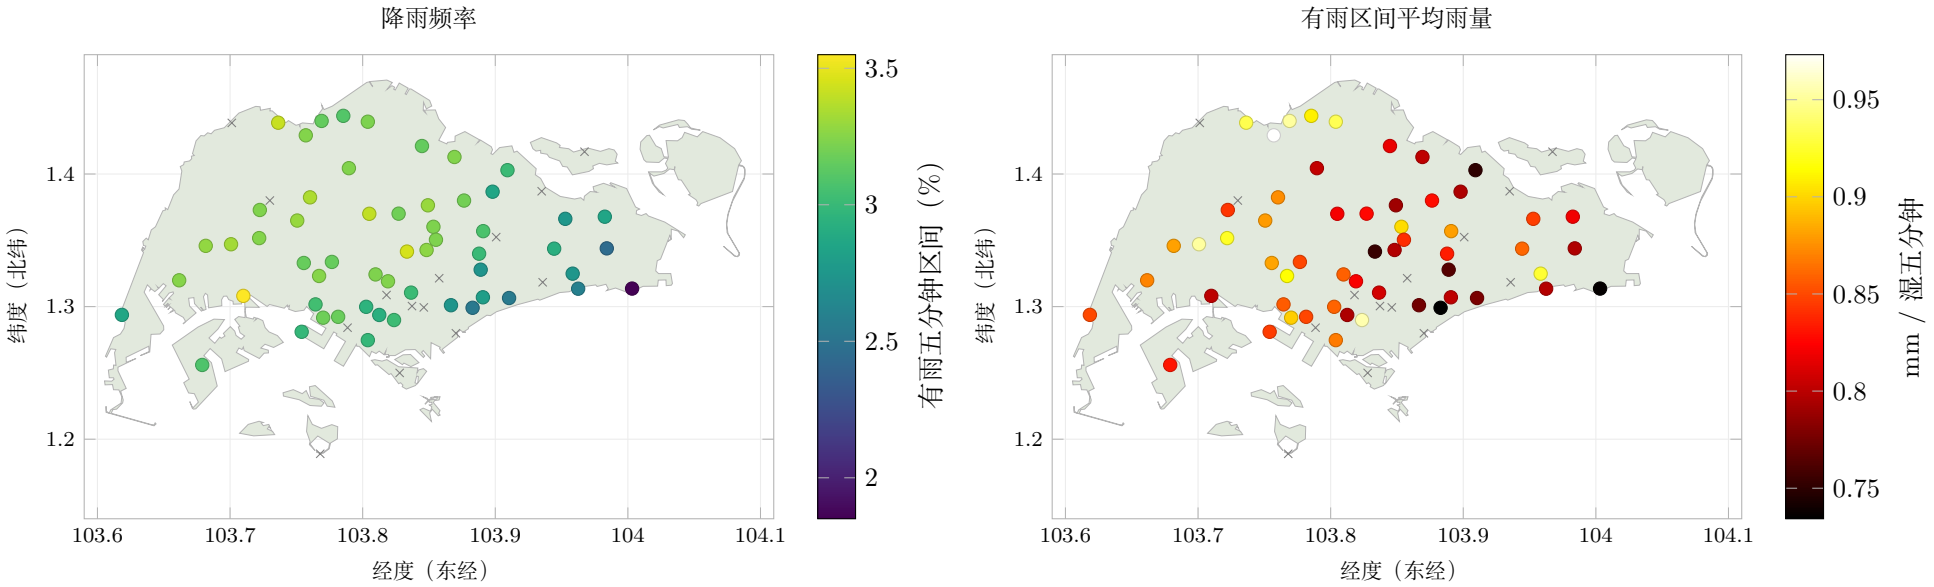
Spark 配置与分工。采用单机双线程模式 `local[2]`，shuffle partitions 为 8，default parallelism 为 2，不使用 GPU。Spark DataFrame/SQL 与窗口函数用于全量清洗、时间聚合、标签和特征构造；模型训练与评价使用 Spark ML 管线。gpushare 进程绑定 CPU 0、1，比较阶段采样内存峰值为 2.719 GiB。

分析样本。各项分析根据比较目的采用相应的站点范围与数据完整性筛选条件，具体见下表。

分析	使用范围	筛选说明
图 1：2024 站点地图	当年 70 站中的 56 站	年覆盖率至少 90%；另 14 站灰色标记
图 2：月度变化	固定 21 站的合格子集	每个合格年月保留 17–21 站
图 3：年度变化	同一组 21 站	其余 70 站不参与固定站点跨年比较
图 4：日内变化	固定 21 站的合格组合	年月小时组合覆盖率至少 80%
图 5：距离与日雨量相关性	固定 21 站，210 对	日覆盖率至少 95%，共同有效日至少 365
图 6 左：有雨时的雨量分布	八年全部 91 站	仅统计有雨五分钟区间
图 6 中、右：半小时超阈值与持续性	2024 年全部 70 站的有效观测	六个未来槽完整，或两个五分钟槽连续

清洗核对。源记录数与 API 计数一致；删除 86 条重复记录，缺失时段不补成零。全部观测的无雨比例也使用全部 91 站，而不是仅使用 21 站。

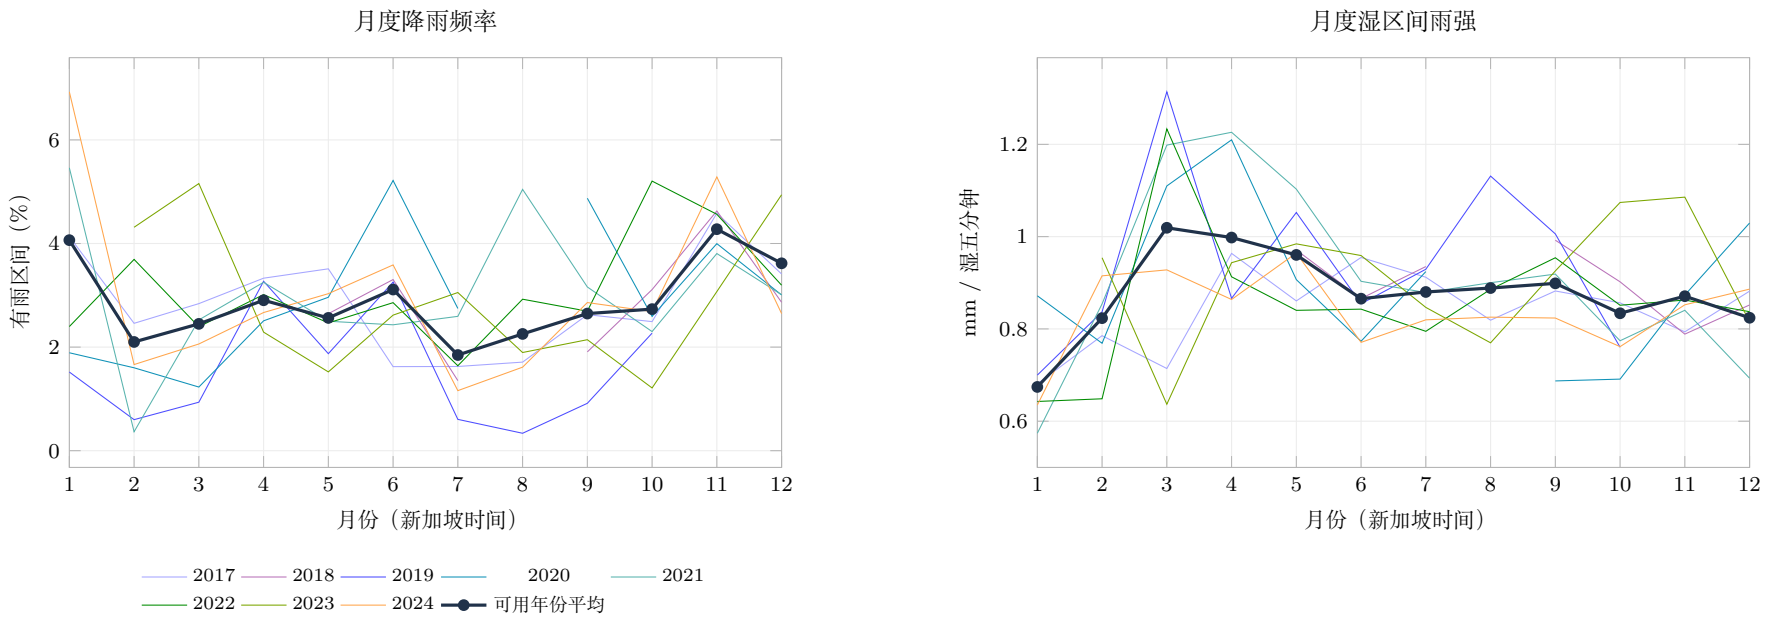
图 1：2024 年观测站降雨地图



2024 年有 70 个站点，其中 56 个年度覆盖率不低于 90%。彩色点只表示该观测站的统计量；灰色叉为低覆盖率站点。S33（Jurong Pier Road）的雨频最高，为 3.55%。地图不进行空间插值，也不代表岛上每个位置的降雨量。边界采用 geoBoundaries 中源自 URA 的 2016 年陆地轮廓（ODbL 1.0），仅作地理参照。

Task 2 特征启示（站点）。候选特征包括站点 ID 和经纬度，以表示站点间差异。Task 2 不直接沿用跨年比较的 21 站限制，而按历史特征及未来标签的完整程度筛选训练窗口。

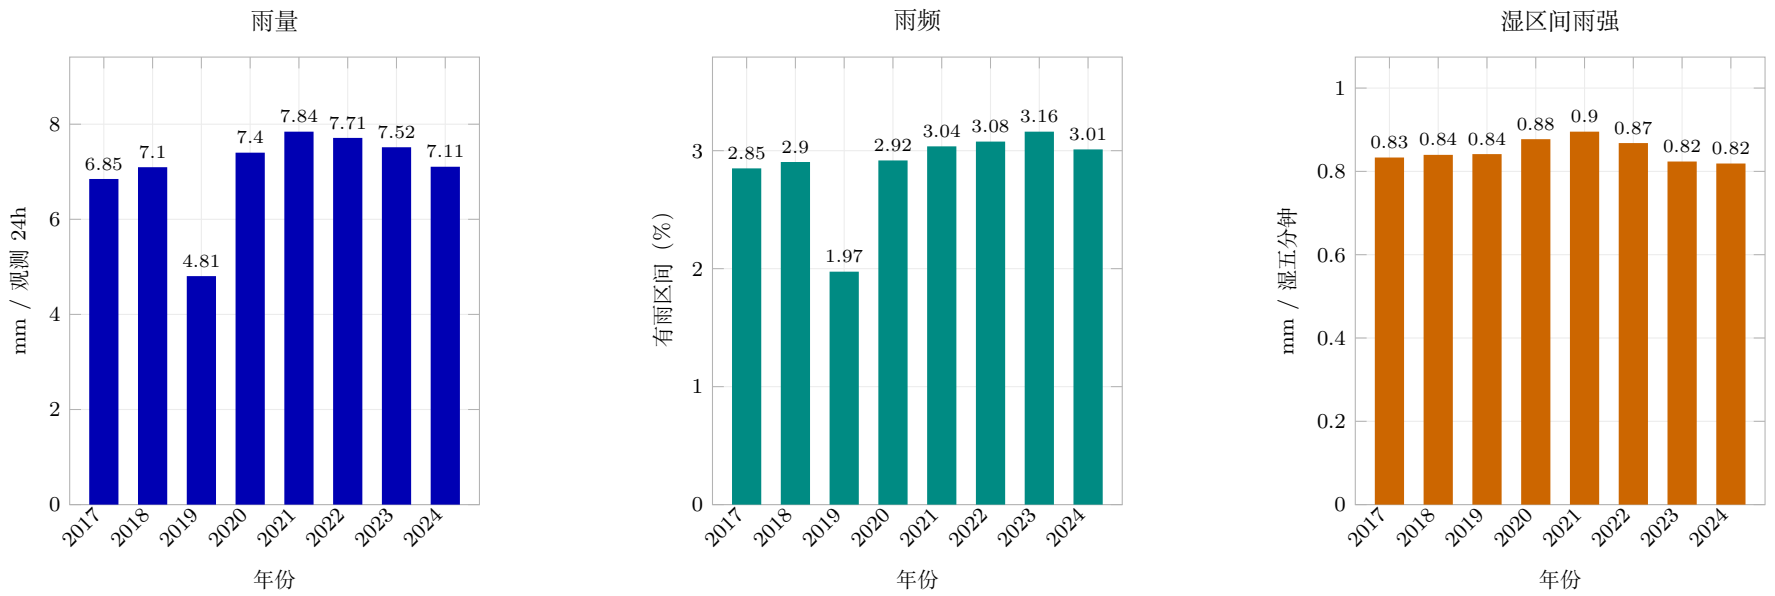
图 2：一年内的月度规律



固定站点样本中，合格站点年月的覆盖率至少为 80%，先对站点等权平均，再对可用年份等权平均。月度平均雨频以 11 月最高（4.28%）、7 月最低（1.85%）；有雨区间平均雨量以 3 月约 1.02 mm、1 月约 0.67 mm。雨频与有雨区间雨量呈现不同的季节变化。各月包含 6–8 个年份，每个合格年月包含 17–21 个站点。

Task 2 特征构造（月份）。月度雨频与雨强的变化模式不同，因而使用月份的正弦、余弦编码表示年内周期，并与小时编码组合，刻画季节与日内降雨规律的共同作用。

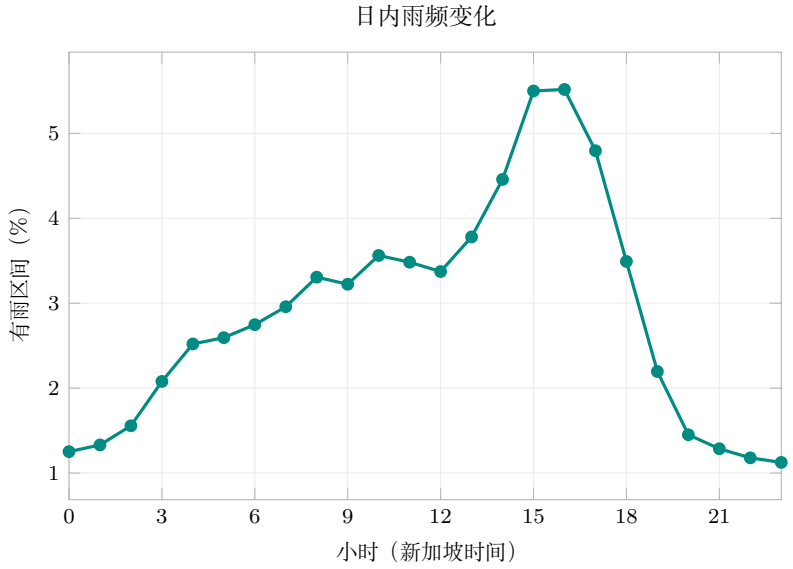
图 3：固定站点的年度变化

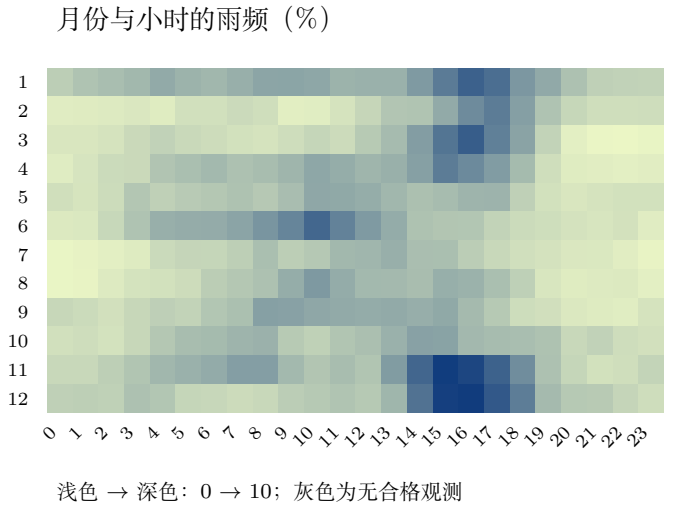


各年采用相同的 21 个站点进行等权比较，每个站点的年度覆盖率至少为 80%。平均雨量 / 观测 24h 从 2019 年的 4.81 mm 到 2021 年的 7.84 mm。2019 年的雨频为 1.97%，明显低于其余年份，而有雨区间雨量为 0.841 mm，与相邻年份接近，表明该年偏低的归一化雨量主要对应较低的降雨频率。

Task 2 特征构造（年份）。训练、验证和测试按年份划分。模型使用月份与小时的周期特征，不加入年份编号。NEA 的 2019 年气候回顾将当年偏干与强正位相印度洋偶极子联系起来，为年际变化提供外部背景。

图 4：降雨频率的日内变化

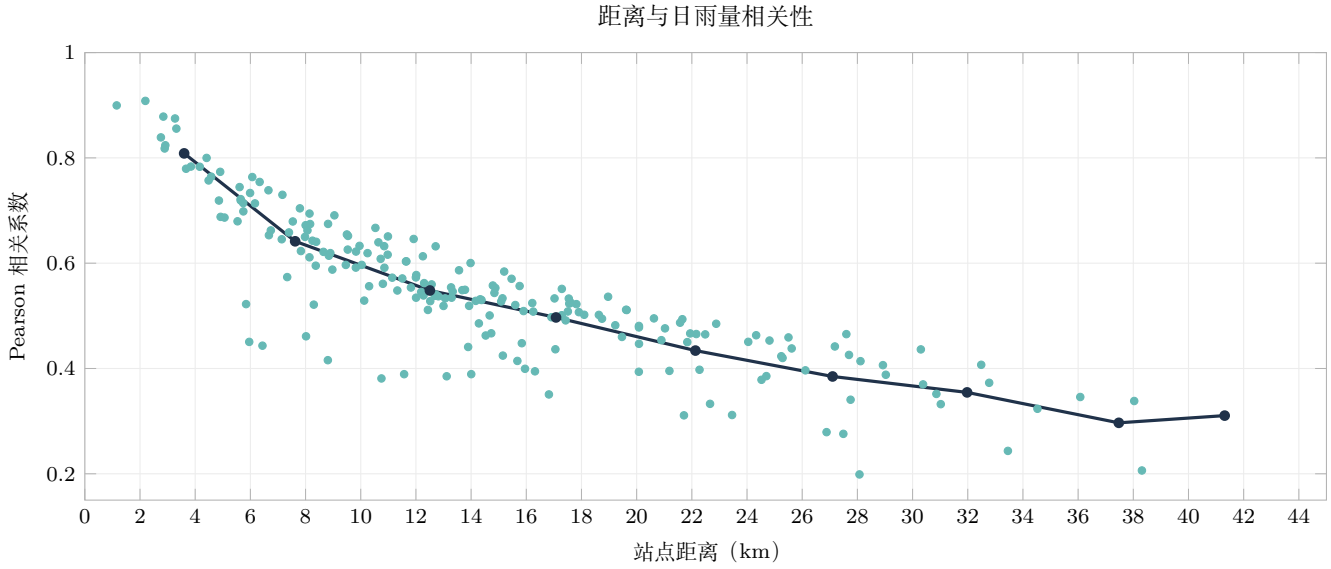




降雨频率在 16:00–17:00 达到日内高峰，且高峰时段与强度随月份变化。11–12 月的下午高峰较明显，6 月的较高雨频更接近上午至中午。统计对覆盖率至少 80% 的站点、年份、月份、小时组合等权平均。该结果支持同时使用小时、月份与二者交互项作为预测特征。

Task 2 特征启示（小时与月份）。使用新加坡当地小时的周期编码，并考虑月份与小时的交互项：下午雨频高峰的强弱和时刻会随月份变化。Logistic 和线性 SVM 需显式构造交互特征；树模型可学习这类组合关系，其实际贡献仍由对照实验检验。

图 5：站点距离与日雨量的相关性

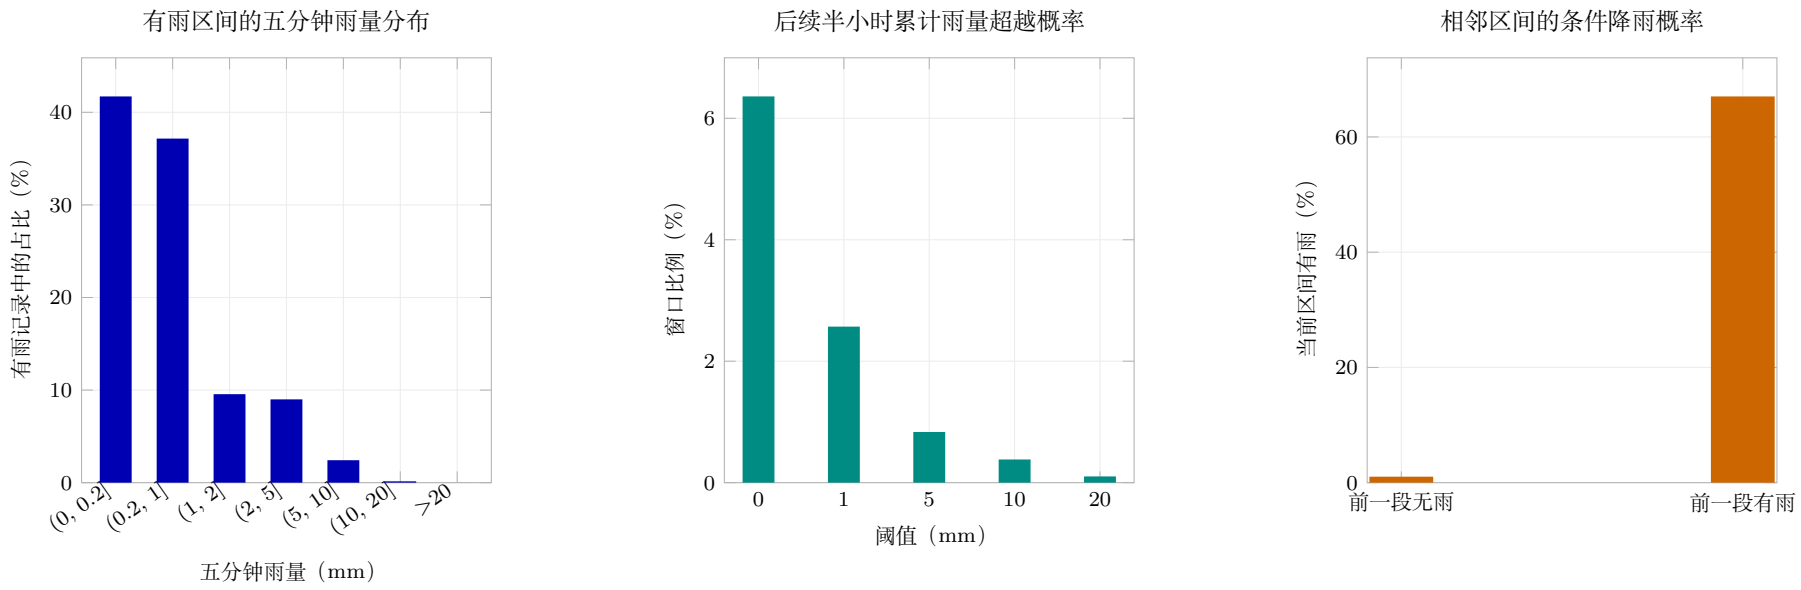


21 个站点形成 210 对站点组合。距离不超过 5 km 的 17 对站点，日雨量平均 Pearson 相关系数为 0.809；距离超过 30 km 的 12 对为 0.336。每 5 km 距离组的平均相关性总体随距离增加而降低，表明降雨具有空间相关性。

站点并非独立。附近站点可能同时经历同一场降雨；不同站点对还可能共享同一个站点。因此，91 个站点不能视为 91 份完全独立的天气样本，210 对相关系数也不是 210 个独立样本。共同有效日的筛选与前文相同。

Task 2 特征构造（邻站）。邻近站点的日雨量呈现较强相关性，因此加入三个最近邻站的历史雨量均值、最大值和有雨比例。Task 2 通过加入邻站特征前后的模型比较，评价其对半小时预测的贡献。

图 6：雨量分布、半小时超越概率与降雨持续性



有雨区间的雨量分布。八年全部站点的有雨五分钟观测中，41.72% 的雨量位于 $(0, 0.2]$ mm，37.16% 位于 $(0.2, 1]$ mm。合计 78.88% 的有雨区间雨量不超过 1 mm，表明多数降雨区间的累计雨量较小。全部有效五分钟观测中的无雨比例为 97.08%。

半小时累计雨量的超越概率。2024 年共有 6,374,476 个完整后续六区间窗口。后续 30 分钟累计雨量严格超过 0 mm 和 5 mm 的窗口比例分别为 6.36% 和 0.83%，超越概率随雨量阈值升高而降低。累计雨量按九位小数比较，以避免阈值边界的浮点误差。图中横轴按阈值类别排列。

相邻区间的降雨持续性。2024 年同站点连续五分钟观测显示，前一区间无雨时，后一区间有雨的条件概率为 1.04%；前一区间有雨时，该概率为 67.03%。降雨具有明显的短时持续性，支持在预测模型中纳入近期雨量及连续有雨时长。

Task 2 特征启示（持续性与稀有事件）。实际特征包括最近读数、过去 15/30/60 分钟累计、近期雨势变化和连续有雨时长。只使用预测时已可获得的记录，缺测不补为无雨。下文逐阈值给出正例数、PR-AUC、Brier score 和校准曲线。

4. Task 2：预测目标与时间切分

预测目标。对于站点 s、预测时刻 t 和雨量阈值 q，模型估计后续 30 分钟累计雨量严格超过 q 的概率。预测时根据站点与时刻提取本站及邻站历史特征。

$$R^{30}_{s,t} = \sum_{k=1}^{6} r_{s,t+5k\,\min}, \qquad y^{(q)}_{s,t} = \mathbf{1}(R^{30}_{s,t} > q), \qquad \hat{p}_q = P(y^{(q)} = 1 \mid x_{s,t}).$$

雨量阈值。设置 $q \in \{0, 5, 25\}$ mm，分别研究是否降雨、累计雨量超过 5 mm 和累计雨量超过 25 mm 三个目标。每个目标训练一个分类器。同一站点时刻保留一份特征和三个标签列，预测时使用与输入阈值对应的模型。

标签构造。以时间戳作为五分钟测量区间的终点，将 $(t, t+30\text{min}]$ 内六个有效区间的雨量求和，保留九位小数后与阈值比较。当前区间不计入未来累计；只有后续六个区间均有有效观测时才构造标签。累计雨量等于阈值时，标签为 0。

用途	有效行数	>0 正例	>5 正例	>25 正例
2017–2022：原始训练候选	34,542,285	–	–	–
2017–2022：训练样本（约 5%）	1,727,966	103,477	13,712	926
2023 上半年：概率校准	3,325,499	251,794	30,699	1,532
2023 下半年：模型选择	3,393,373	197,358	28,000	2,487
2024：最终测试	6,374,476	405,430	53,193	3,517

训练数据抽样。从 2017–2022 年的 34,542,285 条有效训练候选中抽取约 5%，得到 1,727,966 条训练样本。抽样依据站点和时刻的哈希值，种子为 5208，所有比较模型使用相同样本。2023 年上半年用于拟合概率校准函数，下半年用于比较模型；2024 年作为测试集。

5. 从 Task 1 到特征工程

Task 1 依据	构造方式	实际输入
下午高峰随月份变化	本地小时、月份正余弦及四个交互项	8 个日历特征；不加入年份 ID
站点差异与空间相关	站点 ID、经纬度、三个最近邻站	邻站均值、最大值、有雨比例
降雨短时持续性	最新读数、5/10/15/30/60 分钟滞后	15/30/60 分钟累计、变化、雨段长度

历史特征。使用预测时刻之前 90 分钟内的观测，观测时刻和存储更新时间均不晚于预测时刻。最近读数超过 30 分钟时标记为不可用。滞后雨量按固定五分钟时间网格检索；15/30/60 分钟累计截至最近可用读数，并同时记录观测数量与读数年龄。

邻站构造。按预测时已知的站点坐标构造三个最近其他站点；与初始位置偏离超过 0.005° 时停用该站的空间贡献。仅连接邻站当时可用的读数；分别计算最新雨量与过去 30 分钟累计的均值、最大值、有效数，以及湿比例、平均距离和年龄。全量时间窗口、特征与邻站连接由 Spark 完成；小型坐标表用于距离计算。

时间编码。令 h 为当地小时（包含分钟的小数部分），m 为月份，则小时特征为 $\sin(2\pi h/24)$、$\cos(2\pi h/24)$，月份特征为 $\sin[2\pi(m-1)/12]$、$\cos[2\pi(m-1)/12]$。四个小时与月份编码的乘积作为交互项，共形成八个时间特征。周期编码使相邻的 23:00 与 00:00、12 月与 1 月在特征空间中保持接近。

模型输入处理。线性模型对站点 ID 进行 one-hot 编码，树模型将站点 ID 作为类别特征。数值缺失值用训练样本均值填补，并保留缺失标志；无变化的常量值不进入模型。最终线性模型输入为 162 维，树模型为 73 维。Logistic 与 SVM 在拟合中使用特征标准化。

L2 Logistic 特征消融	测试 PR-AUC：0 mm	5 mm	25 mm
日历与站点	0.11652	0.01647	0.00136
加本站历史	0.53061	0.15788	0.01485
再加邻站	0.55978	0.17909	0.01734

特征组比较结果。采用 L2 Logistic，依次比较“时间与站点”“加入本站历史”“再加入邻站历史”三组输入，每组对三个雨量阈值训练模型，共九个模型。首轮比较使用相同训练样本、完整 2023 年验证集，最大迭代为 80，不进行概率校准。加入本站历史后，三个目标的测试 PR-AUC 均大幅提高；进一步加入邻站历史后继续提升。因此后续模型比较使用完整特征组。

6. 模型、不平衡处理与概率校准

模型	固定参数
L2 Logistic（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
Linear SVM（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
GBT（MLlib）	40 轮，深度 4，步长 0.1，128 bins，叶节点最少 20 行
XGBoost（Spark 接口）	80 棵树，深度 4，学习率 0.1，64 bins，子节点权重 20；$L_2 = 1$

模型实现。Logistic、Linear SVM 与 GBT 使用 `pyspark.ml`；XGBoost 使用 `SparkXGBClassifier`，设置两个 CPU worker。所有模型采用表中固定参数，随机种子为 5208。九个 SVM 模型及两个加权 Logistic 模型达到 100 次迭代上限。

三**种训练策略**。自然分布：所有样本权重为 1。类别加权：$w_+ = N/(2P)$、$w_- = N/[2(N-P)]$，使两类总权重相等且总体平均权重为 1。受约束 SMOTE：目标正例占比 20%，正例总数最多为原始正例的 10 倍，只在训练集增加样本。校准、选择和测试不重采样也不加类别权重。

受约束 SMOTE。为保留站点、时间与历史雨量特征之间的关系，仅在同站点、相同缺失模式、离散状态和雨量零值模式的少数类样本中寻找最多五个近邻。对 16 个连续雨量特征采用同一个系数插值，时间编码、坐标、观测数量、湿比例与年龄保持不变；无合适近邻时复制原样本。生成特征需满足非负雨量、完整累计单调性与湿次数一致性。近邻搜索在训练少数类样本中使用单线程 sklearn 完成，其余数据处理与训练采用 Spark。

阈值 mm	增加行数	增加后正例（%）	雨量特征改变行数	孤立状态复制行数
0	302,646	20.000	129,231	73,685
5	123,408	7.406	34,344	48,033
25	8,334	0.533	773	6,061

概率校准（Platt 方法）。基础分类器训练后，利用 2023 年上半年观测拟合一个分数到概率的函数：$\hat{p} = 1/[1 + \exp(-(az + b))]$，其中 z 为原始模型分数，a、b 为待估参数，约束 $a \geq 0$。该方法把 SVM 分数转换为概率，并调整加权或 SMOTE 训练后的概率尺度。其目标是使预测概率与实际发生频率一致，例如预测概率约为 10% 的样本中，应有约 10% 的正例。校准函数使用 MLlib Logistic 拟合，正则参数为 10^{-6}。

7. 评价方法与验证集选择

评价指标。ROC-AUC 评价正负例排序，随机排序的参考值为 0.5。PR-AUC 综合 Precision 与 Recall，适合正例比例较低的目标。对于随机排序，在不同 Recall 水平下的 Precision 接近正例比例 π，因此 PR 曲线面积的参考水平约为 π。测试集三个目标的正例比例为 0.06360、0.008345 和 0.0005517。ROC-AUC 与 PR-AUC 均使用 Spark 的精确排序积分计算。

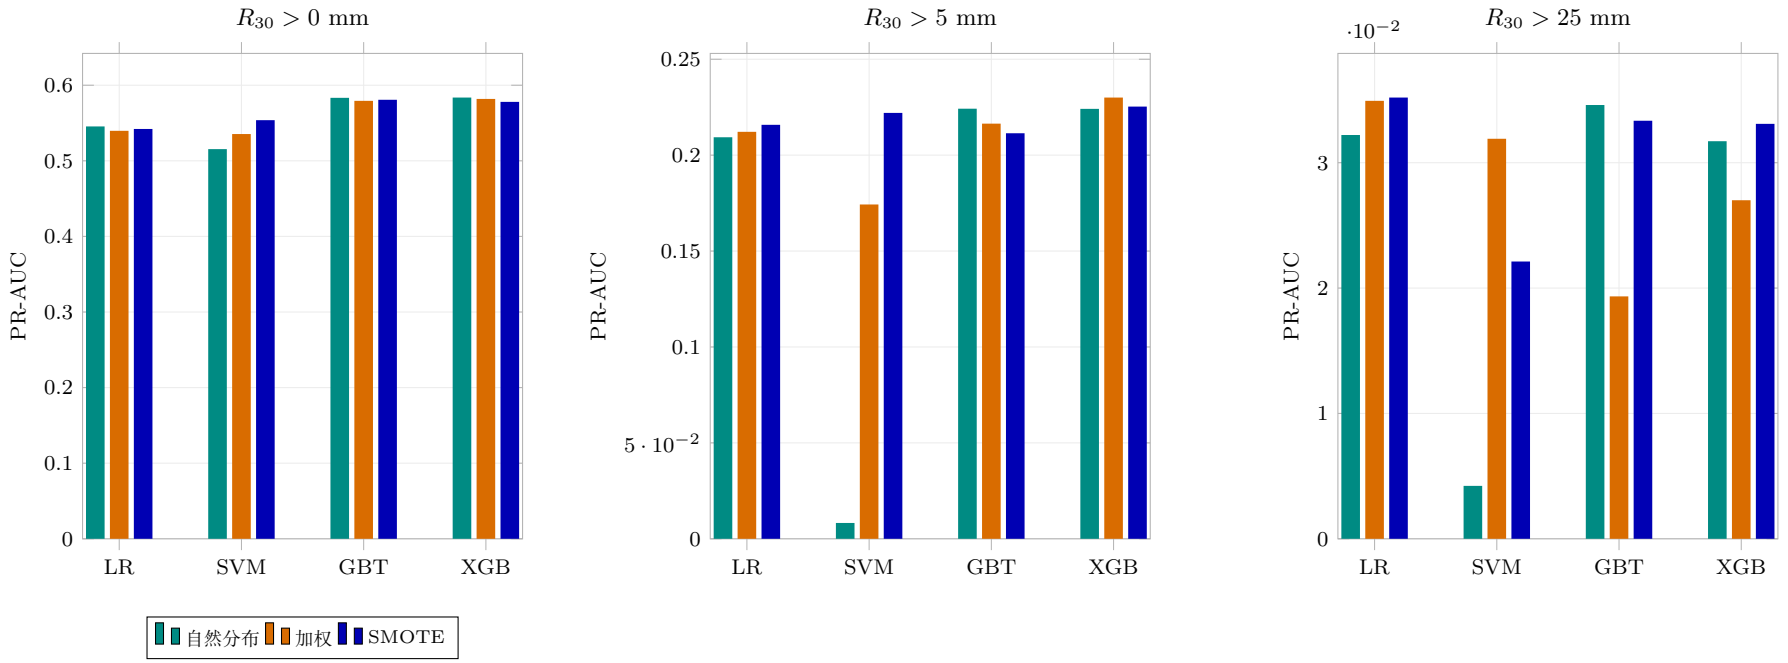
$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)^2, \qquad \text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}.$$

概率评价。Brier score 为预测概率与标签的均方差，数值越小越好。基线模型始终输出训练样本的正例比例。校准曲线将预测概率相近的测试样本分组，以组内平均预测概率为横轴、实际正例比例为纵轴，理想情况为 $y = x$。另在验证集上选择 F1 最大的概率判别阈值，用于报告 Precision、Recall、F1 和 Accuracy。概率判别阈值作用于模型输出，与定义标签的雨量阈值 q 不同。

算法 / 训练策略	选择集 PR-AUC：0 mm	5 mm	25 mm
Logistic / 自然分布	0.54547	0.20932	0.03221
Logistic / 加权	0.53968	0.21216	0.03493
Logistic / SMOTE	0.54213	0.21581	0.03520
SVM / 自然分布	0.51546	0.00825	0.00422
SVM / 加权	0.53541	0.17428	0.03191
SVM / SMOTE	0.55375	0.22202	0.02212
GBT / 自然分布	0.58332	0.22421	0.03460
GBT / 加权	0.57932	0.21642	0.01934
GBT / SMOTE	0.58073	0.21141	0.03335
XGBoost / 自然分布	0.58368	0.22413	0.03171
XGBoost / 加权	0.58186	0.23002	0.02701
XGBoost / SMOTE	0.57796	0.22531	0.03310

模型选择。在 2023 年下半年验证集上，按 PR-AUC 比较每种算法和雨量阈值的训练策略，并以 Brier score 作为并列时的比较依据。最终为 0 mm 选择自然分布训练的 XGBoost，为 5 mm 选择类别加权 XGBoost，为 25 mm 选择 SMOTE Logistic。各算法在三个目标上选出的 12 个模型均在完整 2024 年测试集上评价。

图 7：不平衡处理的验证集比较



验证结果。0 mm 目标中，树模型的 PR-AUC 高于线性模型；5 mm 目标以加权 XGBoost 最优；25 mm 目标以 SMOTE Logistic 最优。SMOTE 提升了部分线性模型的表现，而 GBT 在三个目标上均以自然分布训练获得最高验证 PR-AUC。不平衡处理的收益随算法及目标而变化。

8. 2024 年测试结果

雨量阈值 mm	算法	验证选定策略	ROC-AUC	PR-AUC	Brier
0	Logistic	自然	0.85500	0.55978	0.0392757
0	SVM	SMOTE	0.86049	0.57387	0.0399706
0	GBT	自然	0.87749	0.60338	0.0368843
0	XGBoost	自然	0.87986	0.60797	0.0364959
5	Logistic	SMOTE	0.85004	0.18162	0.0075438
5	SVM	SMOTE	0.77601	0.20093	0.0077220
5	GBT	自然	0.86100	0.20891	0.0074329
5	XGBoost	加权	0.87526	0.21299	0.0072292
25	Logistic	SMOTE	0.85651	0.01805	0.0005483
25	SVM	加权	0.84840	0.01550	0.0005484
25	GBT	自然	0.76516	0.01881	0.0005618
25	XGBoost	SMOTE	0.88889	0.01918	0.0005461

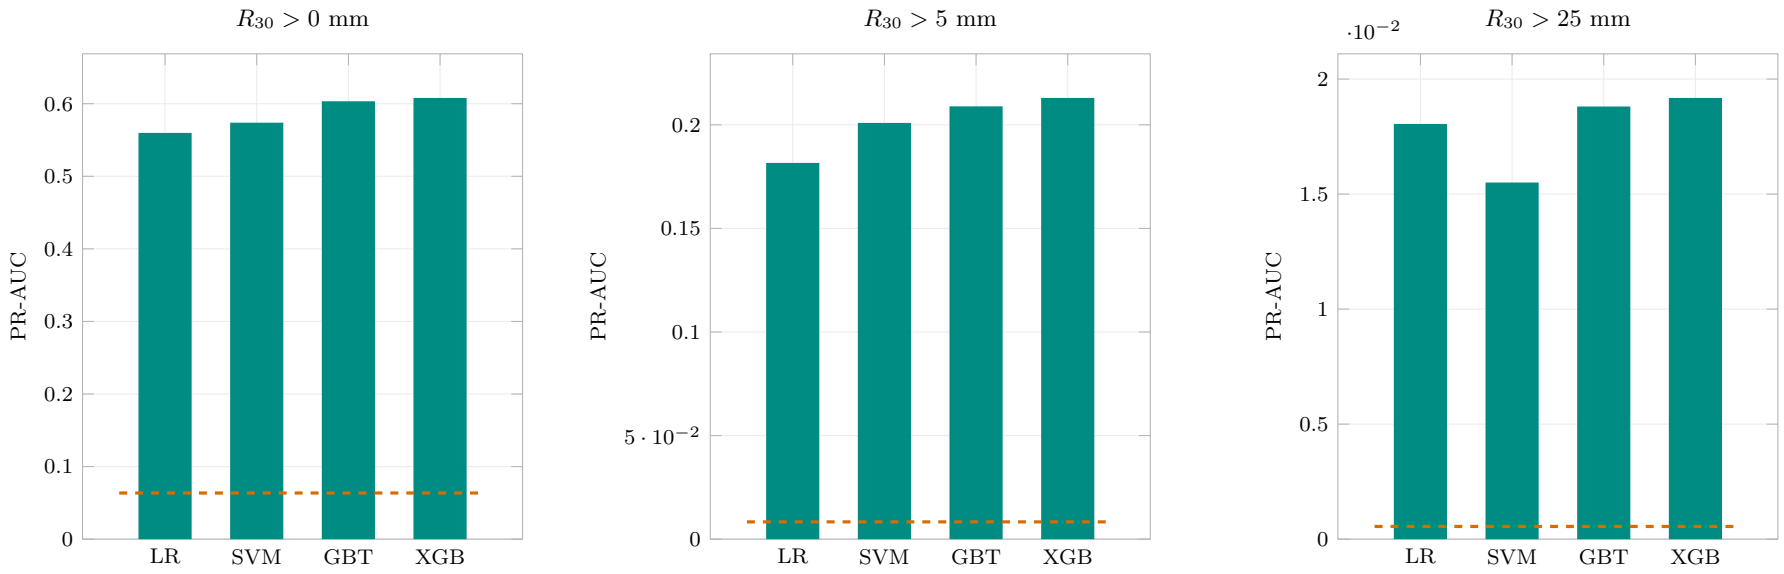
测试规模与基线。三种目标均评价 6,374,476 个真实窗口，正例比例为 6.3602%、0.83447%、0.055173%。常数训练正例率基线的 Brier 依次为 0.0595707、0.0082752、0.0005514；全预测无雨的 Accuracy 依次达 93.64%、99.17%、99.945%，说明 Accuracy 不能代替稀有事件识别能力。所有表格均为校准后结果。

测试结果。XGBoost 在三个目标上的测试 PR-AUC 分别为 0.60797、0.21299 和 0.01918。25 mm 目标的 ROC-AUC 为 0.88889，但 PR-AUC 仍较低，反映出稀有强降雨事件识别的困难。该目标下 GBT 的 Brier 为 0.0005618，高于常数基线，说明排序能力与概率准确性需要分别评价。最终 25 mm 模型为验证集选出的 SMOTE Logistic。

雨量阈值 mm	算法	训练诊断 PR-AUC	选择 PR-AUC	测试 PR-AUC
0	XGB	0.61237	0.58368	0.60797
5	XGB	0.22789	0.23002	0.21299
25	LOGISTIC	0.04515	0.03520	0.01805

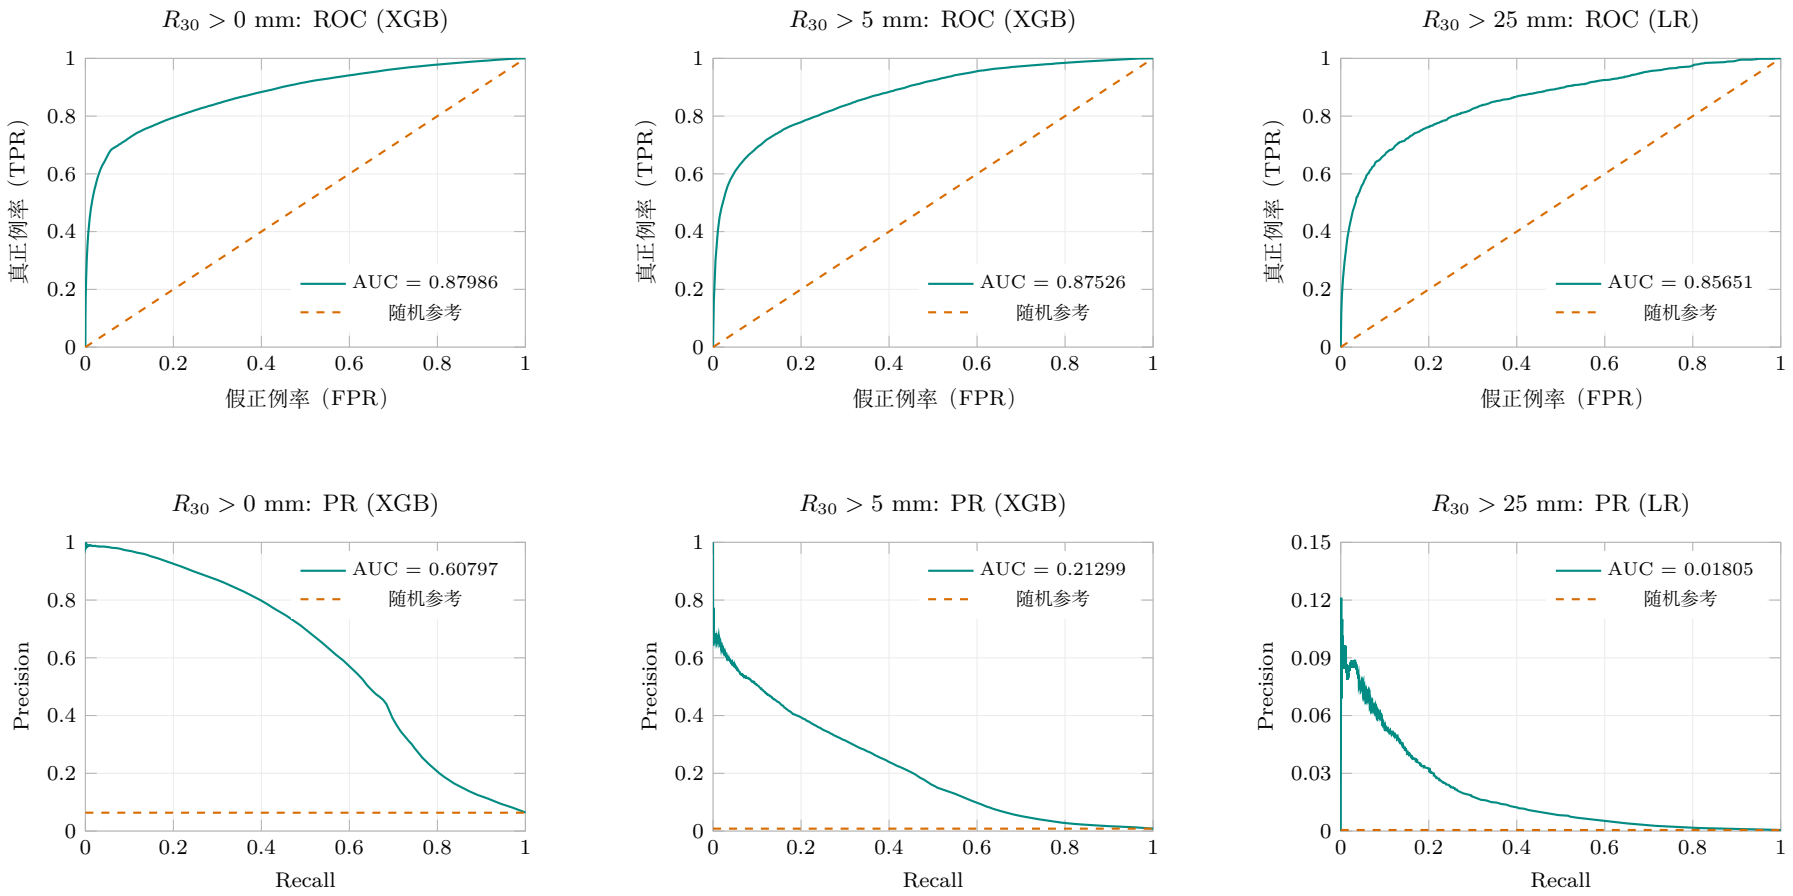
训练与测试比较。训练指标在原始训练样本的固定 20% 子集（344,957 行）上计算，验证与测试使用全量样本。25 mm 自然分布 GBT 的训练 PR-AUC 为 0.17452，验证为 0.03460，显示较明显的训练与验证差距。三个时期的正例比例不同，PR-AUC 的跨时期变化也受事件发生频率影响。

图 8：测试集排序与概率误差



模型比较。测试集上，XGBoost 在三个目标中均取得最高 PR-AUC。橙色虚线表示随机排序的近似参考水平，即测试正例比例。25 mm 目标的 PR-AUC 虽高于约 0.00055 的参考水平，但绝对值仍较低，稀有事件预测是本项目最困难的目标。

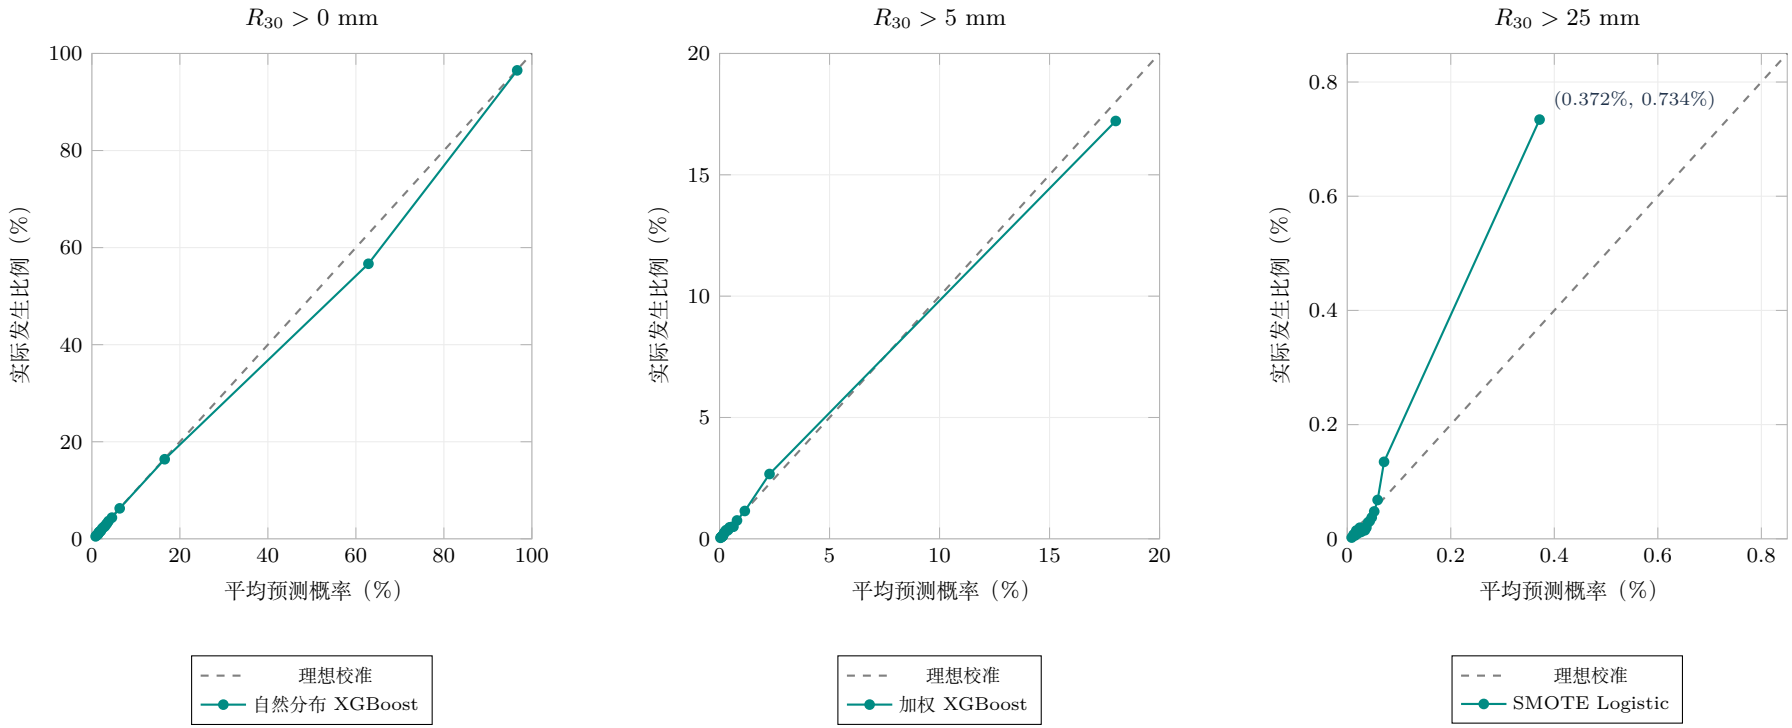
图 9：最终选定模型的 ROC 与 PR 曲线



评价对象。三列依次为自然分布 XGBoost、类别加权 XGBoost 和 SMOTE Logistic，均由 2023 年下半年验证集选定。曲线及 AUC 使用完整 2024 年测试集的 6,374,476 个窗口；各模型仍对应前述约 5% 的训练样本。ROC 图中虚线为 $y = x$，PR 图中虚线为测试集正例比例。25 mm 的 PR 面板将纵轴放大至 0–0.15，以展示低 Precision 区间。

排序表现。三个目标的 ROC-AUC 分别为 0.87986、0.87526 和 0.85651，PR-AUC 分别为 0.60797、0.21299 和 0.01805。随着雨量阈值提高，PR 曲线整体下降，说明在更稀少的降雨事件中同时取得较高 Precision 和 Recall 更困难。25 mm 模型虽具有较高 ROC-AUC，实际稀有事件识别能力仍有限。

图 10：校准曲线与概率质量



测试集校准结果。图中展示各雨量阈值的最终选定模型。0 mm 的 XGBoost 在平均预测概率为 96.66% 的组中，实际发生比例为 96.52%；5 mm 的加权 XGBoost 在平均预测为 18.01% 的组中，实际比例为 17.22%。25 mm 的 SMOTE Logistic 在最高预测概率组包含 252,650 个窗口，平均预测为 0.372%，实际超越比例为 0.734%，表明该组风险被低估。图中所有坐标均以百分比表示。

校准前后比较。25 mm 的 SMOTE Logistic 在验证集上，Brier score 从校准前的 0.0011352 降至校准后的 0.0007248；平均预测概率从 0.55317% 降至 0.04886%，实际正例比例为 0.07329%。Platt 校准降低了重采样后的整体概率高估，但对较高风险组仍存在低估。

9. 选定模型的分类指标与补充分析

雨量阈值 mm	验证选定概率截断	Precision	Recall	F1	Accuracy
0	0.31989	0.61636	0.56524	0.58970	0.94997
5	0.15488	0.28201	0.34305	0.30955	0.98723
25	0.01462	0.05165	0.11288	0.07087	0.99837

分类结果。各模型使用验证集选定的概率判别阈值计算测试集分类指标。25 mm 目标的 F1 较低，而 Accuracy 较高，主要由于负例占比很大。因此主要以 ROC-AUC、PR-AUC 比较模型，并用 Brier score 和校准曲线评价概率预测。

SMOTE 效果。25 mm 目标增加了 8,334 条训练样本，其中 773 条的雨量特征发生数值变化，6,061 条为无合适近邻时的复制。严格约束使合成样本中重复信息较多，是该策略增益有限的可能原因。增加真实强降雨样本、调整类别权重及模型参数，可作为后续改进方向。

跨阈值概率关系。三个目标分别训练，因此可能出现高雨量阈值对应的预测概率反而较高的情况。2024 年各算法选定模型中，违反 $\hat{p}_{25} \le \hat{p}_5 \le \hat{p}_0$ 的窗口数为 Logistic 1、SVM 2,448、GBT 528、XGBoost 247，分母均为 6,374,476。该比较使用同一算法的三个模型；最终跨算法组合的联合约束可在后续通过单调校准处理。

进一步分析。同一降雨过程可能同时影响邻近站点，且相邻半小时窗口存在重叠。后续可按日期或降雨事件进行分组评价，研究模型在不同站点、年份及事件中的稳定性。

10. AI 使用声明与参考文献

AI 使用声明。本项目使用 OpenAI Codex 辅助研究设计、数据处理和模型代码编写、结果核对与报告文字整理。报告中的降雨统计与模型评价结果均来自实际数据处理和模型运行；SMOTE 合成样本仅用于训练。

资料来源。

1. NEA，Historical Rainfall across Singapore，2017–2024 年度数据集。
2. Meteorological Service Singapore，Climate of Singapore。
3. NEA，2019 年气候回顾。用于偏干年份与正位相印度洋偶极子的外部背景，未用作模型预测特征。
4. geoBoundaries，Singapore ADM0；轮廓源自 URA 2016 年资料，ODbL 1.0。
5. Apache Spark 3.5.8，MLlib 分类与回归文档，用于 Logistic、Linear SVM 与 GBT 实现；评价采用 Spark BinaryClassificationEvaluator。
6. XGBoost，PySpark Estimator 文档，用于外部 Spark XGBoost 集成；实际安装版本为 3.2.0。
7. scikit-learn，Precision–Recall 文档与概率校准文档。