新加坡历史降雨：时空规律与概率预测

Task 1 与 2：2017–2024 年 Spark 探索与概率预测

小组成员。潘禹翔、侯佳成、吴嘉蕊。**范围与状态**。本报告包含 Task 1 的降雨探索与 Task 2 的半小时超阈值概率预测。模型已在 gpushare 训练、校准和评估，成员为潘禹翔、侯佳成、吴嘉蕊。

数据与方法。使用 NEA / data.gov.sg 的八个年度数据集，源记录共 48,538,713 条，去重后 48,538,627 条，涉及 91 个站点 ID。全量清洗和聚合由 Spark 执行；跨年比较采用 21 个稳定站点，避免监测网络变化混入年度差异。

主要结果。全部有效五分钟区间中 97.08% 无雨。合格日内样本的雨频高峰为新加坡时间 16:00–17:00。月度可用样本平均雨频以 11 月最高、7 月最低，但各月的可用年份及站点组成不完全相同。固定站点样本中，按观测时长归一化的雨量以 2019 年最低、2021 年最高。近距离站点的日雨量相关性总体高于远距离站点；八年不能据此推断长期气候变化。

年份	雨量 / 观测 24h（mm）	雨频（%）	湿区间雨强（mm/5min）	平均覆盖率（%）
2017	6.85	2.85	0.833	94.6
2018	7.10	2.90	0.840	82.9
2019	4.81	1.97	0.841	94.7
2020	7.40	2.92	0.877	95.3
2021	7.84	3.04	0.895	97.8
2022	7.71	3.08	0.868	99.0
2023	7.52	3.16	0.824	95.2
2024	7.11	3.01	0.819	95.6

表中各年均使用相同的 21 个站点，站点等权。雨量指标按观测时长归一化，不能解释为官方年度累计或真实日累计。月度图和日内图的合格样本组成仍可变化。

1. 数据来源、字段与清洗

来源与字段。每条记录包含 observation timestamp、update timestamp、station ID/name/device ID、经纬度、reading update timestamp、reading value、reading type、reading unit 及日期字段。本数据只有降雨相关观测，不包含气温、湿度和风等变量。API 预览只用于确认字段和年度 ID；所有天气结论来自完整文件。

来源追踪。每个完整 CSV 的清单保存官方数据集 ID、API 行数、下载时间、字节数和原始 CSV 字节的 SHA256。清洗时将实读 CSV 行数与该年度记录的 API 行数逐一核对。

清洗步骤。Spark 按 Asia/Singapore 解析时间；保留有限、非负、单位为 mm、类型为预期五分钟累计、站点 ID 和时间合法且 CSV 记录有效的行。只有与五分钟网格的距离不超过两秒时才对齐，原始 epoch 同时保留；其他离网格记录排除并审计。按 station ID 与对齐时刻去重，优先保留 reading update 最新的行，再使用原始观测时刻及确定的字段顺序打破并列。年度文件合并后再次检查跨文件重复。

年份	源记录数	删除重复数	偏离网格超过 2 秒	负雨量数	站点数
2017	5,256,106	86	0	0	62
2018	4,594,246	0	0	0	56
2019	5,026,862	0	0	0	54
2020	6,334,473	0	0	0	80
2021	7,044,646	0	0	0	76
2022	7,133,230	0	0	0	72
2023	6,742,890	0	0	0	74
2024	6,406,260	0	0	0	70

实际审计。86 条重复记录全部来自 2017 年；八年没有负雨量或偏离网格超过两秒的记录。全量聚合的跨文件重复数为零。不存在年度覆盖率不低于 90% 却所有读数均为零的站点年。缺失时段从不补成零。主分析会保留并标记大于 50 mm/5min 的读数，本次实际标记数为零；50 mm 是敏感性筛查值，并非官方质量阈值。合法读数仍可能包含传感器误差。

2. 指标定义与公平比较

设站点在给定时间段内的有效观测数为 N，雨量为 $r_i \geq 0$，有雨区间数为 $W = \sum_i \mathbf{1}(r_i > 0)$，预期日历槽数为 E。本文使用：

$$\begin{aligned} \text{覆盖率} &= N/E, \qquad E = 288 \times \text{日历天数}, \\ \text{雨频（\%）} &= 100W/N, \\ \text{湿区间雨强（mm/5min）} &= \sum_i r_i/W \quad (W > 0), \\ \text{雨量 / 观测 24h（mm）} &= 288 \sum_i r_i/N. \end{aligned}$$

预期日历槽数显式处理闰年；低覆盖率也可能反映站点只运行了部分年份。雨强的分母仅包含有雨区间。对于单个站点和同一时间段，归一化雨量等于 288 × 雨频/100 × 湿区间雨强。分别取站点平均后，该乘积恒等式一般不再成立。归一化雨量不是官方日累计或年度累计，也不能恢复遗漏风暴。

年度固定样本。八年共出现 91 个站点 ID，其中 21 个同时满足：八年均有观测、每年覆盖率至少 80%、经纬度跨度各不超过 0.005°。其余 70 个只是不进入固定站点的跨年比较，清洗时没有删除这些站点的有效观测。21 个站点等权平均；不同分析使用的站点范围见下一页。

月度与日内样本。图 2、4 从这 21 个站点中进一步筛选数据完整的年月或小时组合。月度先对站点等权平均，再对可用年份等权平均；每个合格年月有 17–21 个站点，各月有 6–8 个可用年份。严格要求同站点同月份在八年均达标时，只剩 5、6、7、9、10、12 月，作为额外对照。

空间比较。图 1 使用 2024 年的站点，当年共 70 个，其中 56 个覆盖率至少 90%，用于地图着色，另 14 个以灰色标记。图 5 使用固定 21 站的日累计，要求日覆盖率至少 95%，每对至少有 365 个共同有效日期。80%、90%、95% 是本项目选定的数据完整程度门槛。

3. 计算环境与各项分析的样本范围

实际计算环境。Task 1 主体分析此前在 Apple Silicon Mac 上完成：10 个逻辑 CPU、16 GiB RAM，macOS 26.5.2 ARM64，Python 3.12.14、Java Temurin 17.0.20.1+1、Spark 3.5.8。Task 2 的标签、特征、全部模型及评估于 2026 年 10 月 9 日在 gpushare 完成：Python 3.11.10、Azul Zulu Java 17.0.20.1、Spark 3.5.8、XGBoost 3.2.0。容器配额为 42 CPU、约 667.68 GiB RAM，项目实际仅绑定 CPU 0、1，使用 2 GiB driver heap 和 4 GiB 进程树 RSS 采样停止界限。

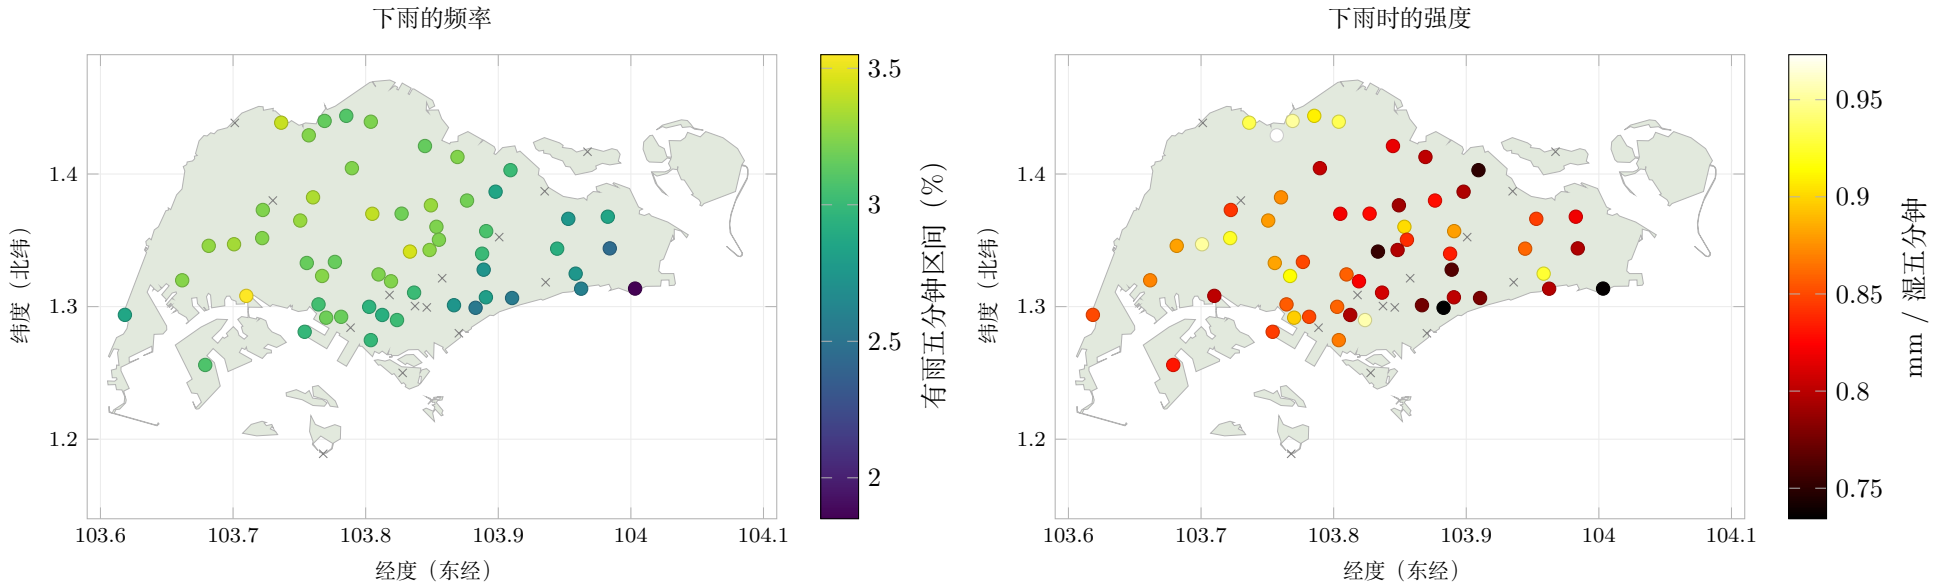
Spark 配置与分工。使用 `local[2]`，即单机两个 Spark 工作线程；driver heap 为 2 GiB，shuffle partitions 为 8，default parallelism 为 2。按年度串行处理，不使用 GPU。清洗、去重、时间分组及全量聚合由 Spark DataFrame/SQL 和窗口完成；汇总后的少量数据用于绘图与日雨量相关性计算。

各项分析用了哪些站点？筛选服务于特定比较，不是将未进入固定样本的站点全部删除。

分析	使用范围	筛选说明
图 1：2024 站点地图	当年 70 站中的 56 站	年覆盖率至少 90%；另 14 站灰色标记
图 2：月度变化	固定 21 站的合格子集	每个合格年月保留 17–21 站
图 3：年度变化	同一组 21 站	其余 70 站不参与固定站点跨年比较
图 4：日内变化	固定 21 站的合格组合	年月小时组合覆盖率至少 80%
图 5：距离与日雨量相关性	固定 21 站，210 对	日覆盖率至少 95%，共同有效日至少 365
图 6 左：有雨时的雨量分布	八年全部 91 站	仅统计有雨五分钟区间
图 6 中、右：半小时超阈值与持续性	2024 年全部 70 站的有效观测	六个未来槽完整，或两个五分钟槽连续

清洗核对。源记录数与 API 计数一致；删除 86 条重复记录，缺失时段不补成零。全部观测的无雨比例也使用全部 91 站，而不是仅使用 21 站。

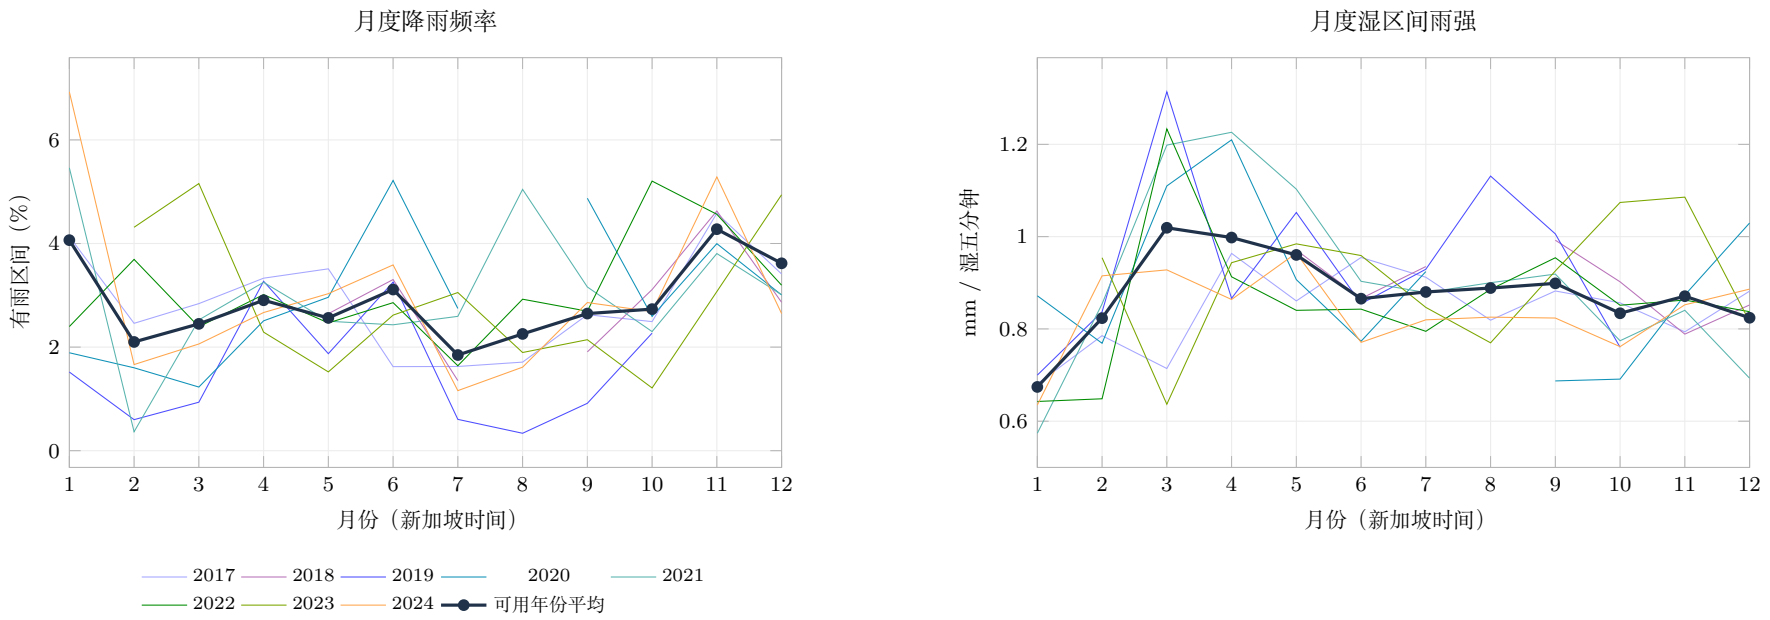
图 1：2024 年观测站降雨地图



2024 年有 70 个站点，其中 56 个年度覆盖率不低于 90%。彩色点只表示该观测站的统计量；灰色叉为低覆盖率站点。S33（Jurong Pier Road）的雨频最高，为 3.55%。地图不进行空间插值，也不代表岛上每个位置的降雨量。边界采用 geoBoundaries 中源自 URA 的 2016 年陆地轮廓（ODbL 1.0），仅作地理参照。

Task 2 特征启示（站点）。候选特征包括站点 ID 和经纬度，以表示站点间差异。Task 2 不直接沿用跨年比较的 21 站限制，而按历史特征及未来标签的完整程度筛选训练窗口。

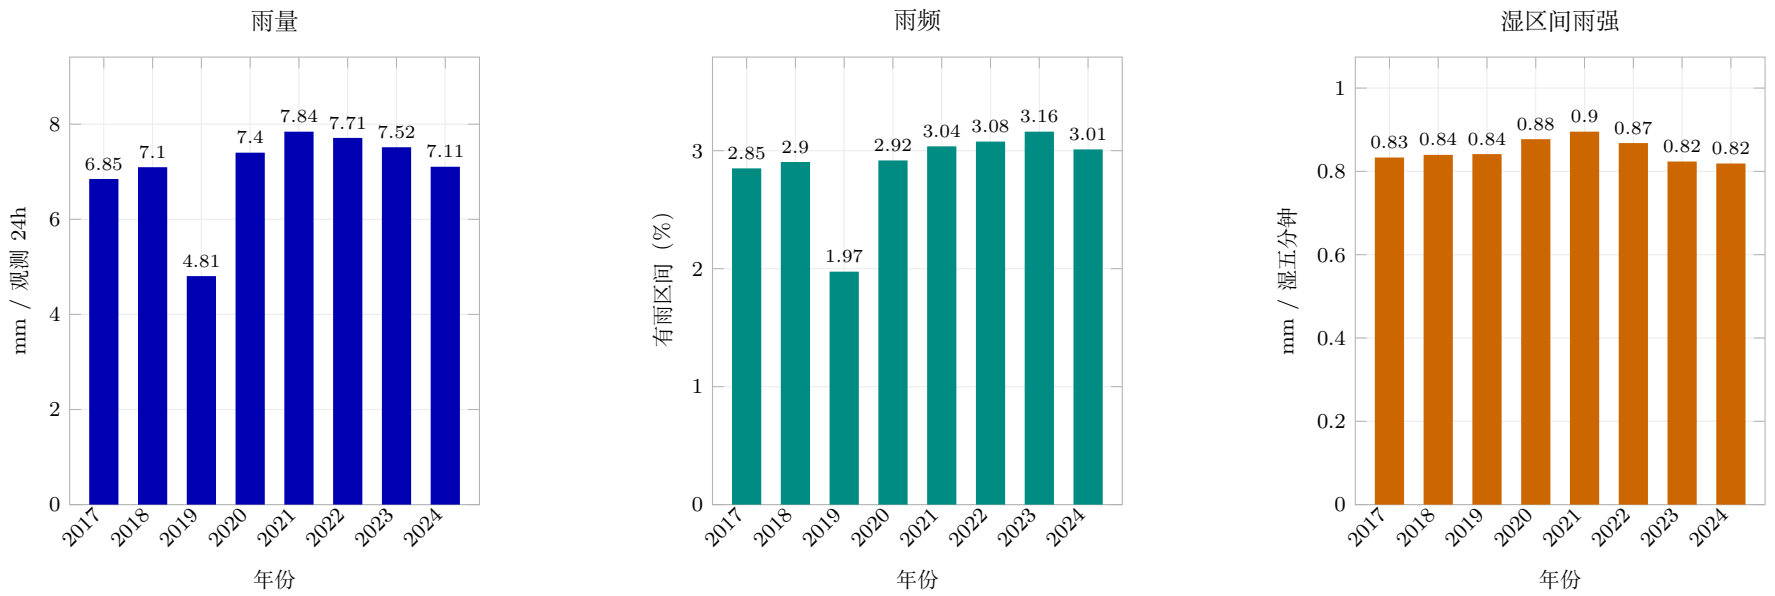
图 2：一年内的月度规律



从年度固定站点池中筛选每个年月覆盖率不低于 80% 的站点，先站点等权，再对可用年份等权平均。11 月平均雨频最高（4.28%），7 月最低（1.85%）；3 月平均湿区间雨强约为 1.02 mm，而 1 月约为 0.67 mm。雨频和雨强可以呈现不同的季节模式。每月可用年份为 6–8 年，合格站点可变化，因此不能把这些均值当作完全平衡的季节比较。MSS 所述较湿的 11 月至次年 1 月提供背景；本数据不能独立证明季风因果关系。

Task 2 特征启示（月份）。保留月份或年内日期的周期编码，并通过有无月份特征的对照检验其贡献。新加坡受季风影响，但没有界限分明的旱季和雨季；较少降雨不等于不下雨，雨频也不等于累计雨量。

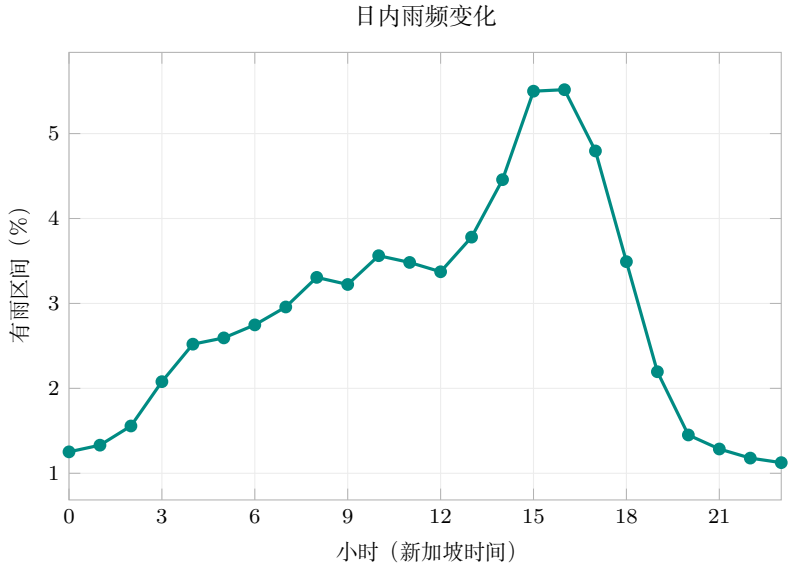
图 3：固定站点的年度变化

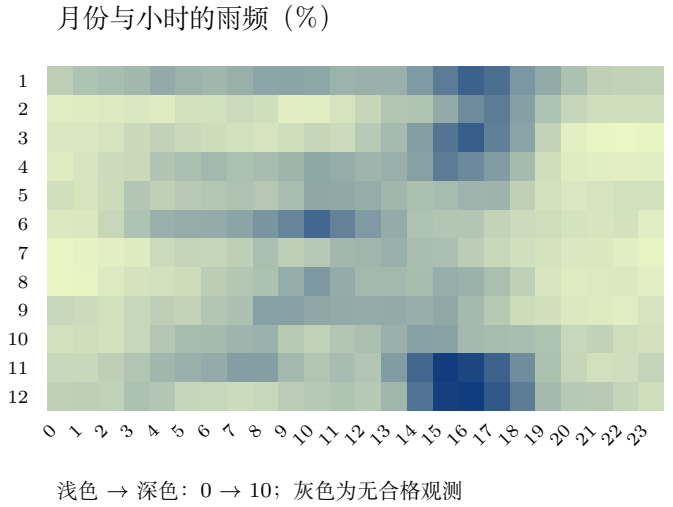


相同 21 个站点、每站每年覆盖率至少 80%。平均雨量 / 观测 24h 从 2019 年的 4.81 mm 到 2021 年的 7.84 mm；雨频和湿区间雨强的变化并不完全同步。将总雨量拆成频率和强度，有助于解释年际差异。但覆盖率归一化不能恢复缺失风暴，2018 年平均覆盖率约为 82.9%，明显低于多数年份。八年仅支持描述性比较，本报告不进行长期气候趋势或显著性断言。

Task 2 特征启示（年份）。暂不将年份编号作为主模型特征，以免记住特定年份而难以预测未来年份。NEA 对 2019 年的回顾记载了偏干及强正位相印度洋偶极子背景；这是外部气候背景，不是本数据的因果证明。按时间划分训练、验证与测试，并报告跨年表现。

图 4：一天内何时更容易下雨

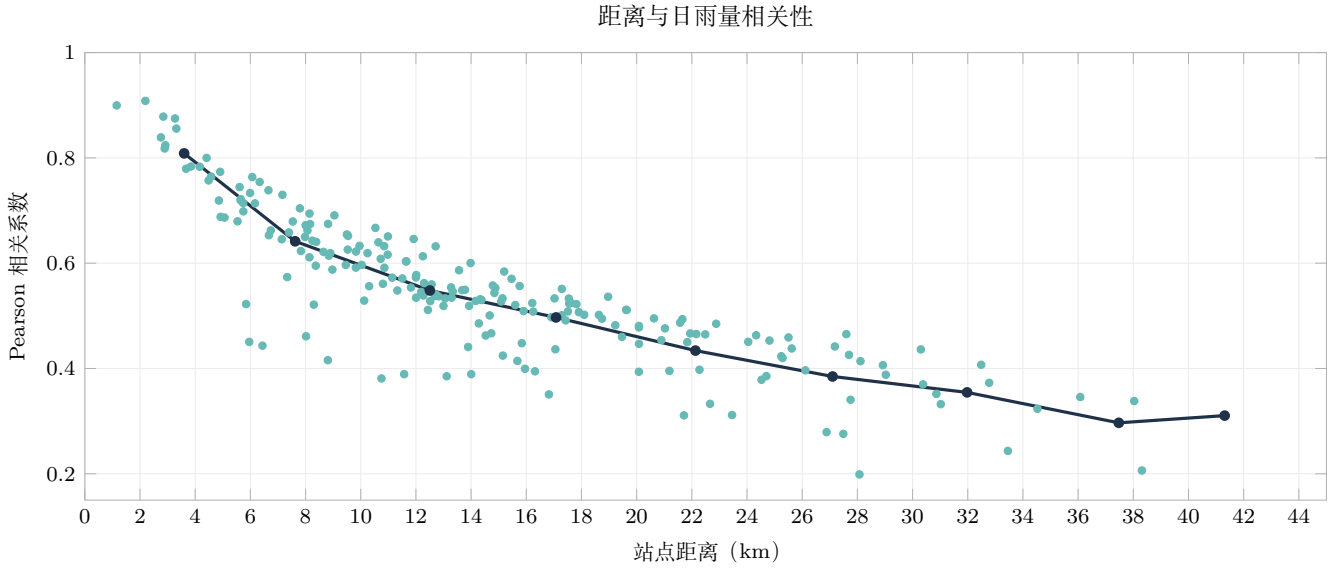




雨频最高的小时为 16:00–17:00，右图显示该周期随月份变化；例如 6 月的高值时段更靠近上午至中午。筛选条件为站点、年份、月份、小时组合的覆盖率不低于 80%，合格组合等权平均。不同组合的组成仍可变化。MSS 描述的下午降雨周期是背景信息；本分析没有额外温度、风或湿度观测来解释其机制。

Task 2 特征启示（小时与月份）。使用新加坡当地小时的周期编码，并考虑月份与小时的交互项：下午雨频高峰的强弱和时刻会随月份变化。Logistic 和线性 SVM 需显式构造交互特征；树模型可学习这类组合关系，其实际贡献仍由对照实验检验。

图 5：站点距离与日雨量的相关性

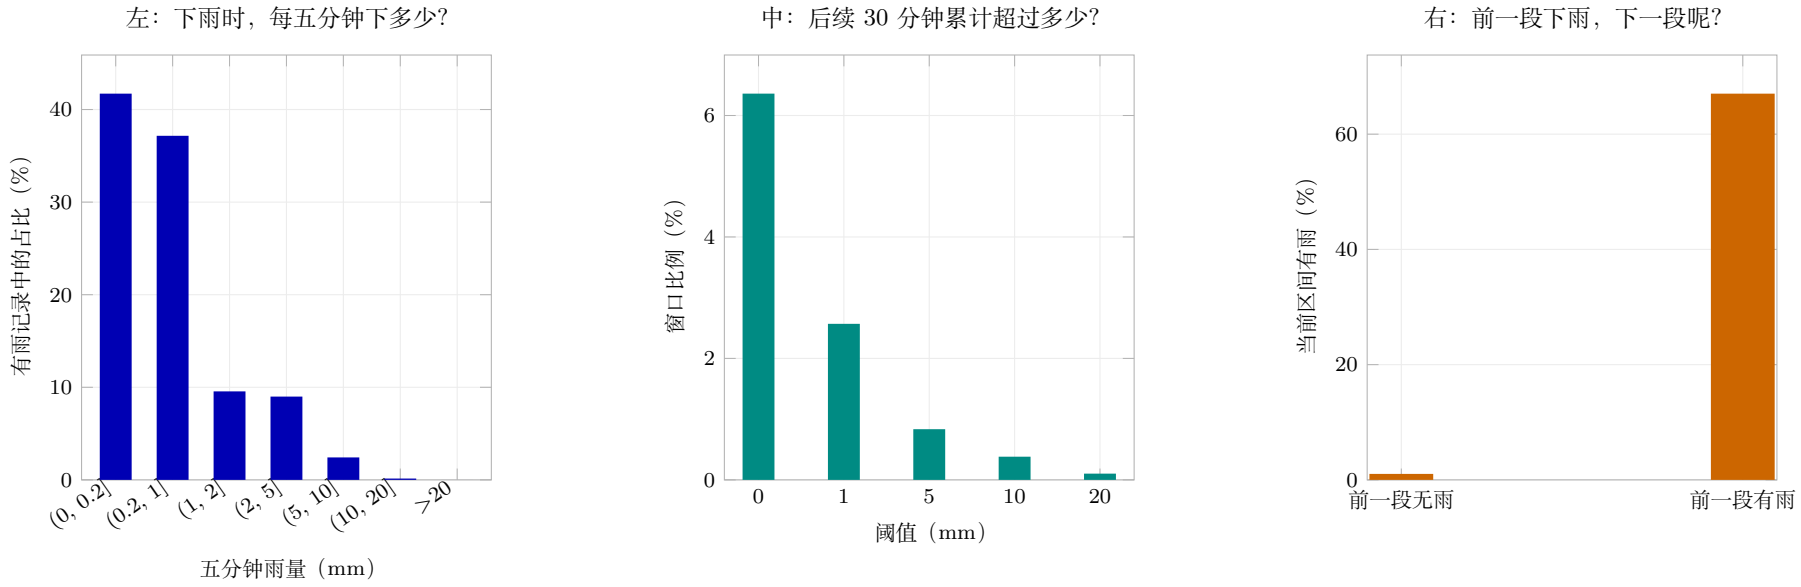


每个点代表一对站点：横轴是两站距离，纵轴是两站在共同有效日期上的日雨量 Pearson 相关系数。深线是每 5 km 距离分组的平均相关性。21 站形成 210 对；距离不超过 5 km 的 17 对平均相关性为 0.809，超过 30 km 的 12 对为 0.336。**总体上，距离较近的站点，日雨量更容易一起增减**。这并不表示每一对近站的相关性都高于每一对远站。

站点并非独立。附近站点可能同时经历同一场降雨；不同站点对还可能共享同一个站点。因此，91 个站点不能视为 91 份完全独立的天气样本，210 对相关系数也不是 210 个独立样本。共同有效日的筛选与前文相同。

Task 2 特征启示（邻站）。加入三个最近邻站在预测时已可获得的历史雨量：均值、最大值、有雨比例，以及有效邻站数、距离和数据年龄。图神经网络暂缓。日雨量相关性提供候选特征依据；Task 2 另以有无邻站特征的模型比较检验预测增益。

图 6：雨下多大、半小时超阈值与短时持续性



左图：下雨时有多大。分母是八年所有站点的**有雨**五分钟记录。柱子表示不同雨量范围所占比例；例如 41.72% 的有雨记录在 $(0, 0.2]$ mm，37.16% 在 $(0.2, 1]$ mm。二者合计约 78.88%，说明多数有雨区间的雨量不超过 1 mm。无雨记录未画入左图；在全部有效记录中，无雨比例为 97.08%。

中图：半小时累计超过阈值有多常见。统计 2024 年的 6,374,476 个完整后续六槽窗口，以 $(t, t + 30\text{min}]$ 内六个五分钟读数的和表示累计量。累计量保留九位小数，避免浮点求和在阈值边界产生误判。横轴是雨量阈值，纵轴是严格超过该阈值的窗口比例。超过 0 mm 的比例为 6.36%，超过 5 mm 为 0.83%；阈值越大，事件越少。横轴按五个类别等距排列，不表示阈值差距相等。

右图：降雨是否会接着下。统计 2024 年同站点连续两个五分钟区间。前一段无雨时，下一段有雨的比例为 1.04%；前一段有雨时，下一段有雨的比例为 67.03%。这说明近期降雨可为 Task 2 提供有用信息。中图和右图是历史统计，**不是模型的预测成绩**。

Task 2 特征启示（持续性与稀有事件）。实际特征包括最近读数、过去 15/30/60 分钟累计、近期雨势变化和连续有雨时长。只使用预测时已可获得的记录，缺测不补为无雨。下文逐阈值给出正例数、PR-AUC、Brier score 和校准曲线。

4. Task 2：预测目标与时间切分

预测的是什么？输入站点 s、新加坡预测时刻 t 和雨量阈值 q，输出后续 30 分钟累计雨量严格超过 q 的概率。本站及邻站历史由接口按时刻检索，无需用户手动输入一串观测。

$$R^{30}_{s,t} = \sum_{k=1}^{6} r_{s,t+5k\,\min}, \qquad y^{(q)}_{s,t} = \mathbf{1}(R^{30}_{s,t} > q), \qquad \hat{p}_q = P(y^{(q)} = 1 \mid x_{s,t}).$$

阈值与接口范围。本次使用 $q \in \{0, 5, 25\}$ mm：0 表示是否有雨；5 表示较大半小时累计；25 表示稀有高累计事件。这是项目选定的实验阈值，不将其命名为新加坡官方暴雨等级。三个分类器分别训练；同一站点时刻只保留一份特征及三个标签列，不复制三份特征样本。预测时用阈值选择对应模型，当前不支持任意未训练阈值；若课程要求连续任意阈值，需要进一步扩展分布或阈值条件模型。50 mm 与图神经网络暂不开展。

标签有效性。只保留后续恰好六个不同且有效的五分钟槽；当前读数不进入标签。累计保留九位小数后作严格大于比较，等于阈值记为 0。缺一个未来槽则窗口无效，缺测不补零。以读数时间为区间终点是本项目的操作性假设；档案不足以确认实时首次发布时间。

用途	有效行数	> 0 正例	> 5 正例	> 25 正例
2017–2022：原始训练候选	34,542,285	–	–	–
2017–2022：固定 5% 训练样本	1,727,966	103,477	13,712	926
2023 上半年：概率校准	3,325,499	251,794	30,699	1,532
2023 下半年：模型选择	3,393,373	197,358	28,000	2,487
2024：最终测试	6,374,476	405,430	53,193	3,517

防止时间泄漏。标签窗口不得跨训练、校准、选择或测试边界；7 月切分额外剔除 402 行。5% 样本用固定哈希种子 5208，从真实训练候选抽取，并供所有模型共享；这是资源受限的训练，不宣称全量训练。验证、测试均保留完整自然分布。全量特征表覆盖 47,636,035 行。2024 已用于 Task 1 探索，应称为模型选择之外的时间后移测试集，而非整个研究从未接触的数据。

5. 从 Task 1 到特征工程

Task 1 依据	构造方式	实际输入
下午高峰随月份变化	本地小时、月份正余弦及四个交互项	8 个日历特征；不加入年份 ID
站点差异与空间相关	站点 ID、经纬度、三个最近邻站	邻站均值、最大值、有雨比例
降雨短时持续性	最新读数、5/10/15/30/60 分钟滞后	15/30/60 分钟累计、变化、雨段长度
缺测与覆盖率差异	有效读数数目、可用标志、数据年龄	缺测指示、有效邻站数及距离

时间可用性。读取预测时刻之前 90 分钟的档案，要求观测、对齐槽和存储更新时间均不晚于 t；最新读数超过 30 分钟则视为不可用。滚动累计截至最新可用读数，并同时输入其年龄和窗口有效数。精确滞后按日历槽检索，不能把缺槽后的上一行当作固定五分钟滞后。档案更新时刻只是保守可用性代理，不是首次发布时间。

邻站构造。按预测时已知的站点坐标构造三个最近其他站点；与初始位置偏离超过 0.005° 时停用该站的空间贡献。仅连接邻站当时可用的读数；分别计算最新雨量与过去 30 分钟累计的均值、最大值、有效数，以及湿比例、平均距离和年龄。全量时间窗口、特征与邻站连接由 Spark 完成；小型坐标表用于距离计算。

预处理与维度。显式列出 46 个数值候选及站点 ID，排除未来累计、标签和审计列。固定训练样本中常量位置变化值不入向量，保留 45 个值及 27 个有信息的缺测标志；均值填补只在训练样本拟合。线性模型使用站点 one-hot，共 162 维；树模型使用有类别元数据的站点索引，共 73 维。XGBoost 明确指定站点为类别，避免将编号当连续顺序。

L2 Logistic 特征消融	测试 PR-AUC：0 mm	5 mm	25 mm
日历与站点	0.11652	0.01647	0.00136
加本站历史	0.53061	0.15788	0.01485
再加邻站	0.55978	0.17909	0.01734

消融解读。首轮九个自然分布 Logistic 模型使用相同训练样本，完整 2023 验证，不做后续 Platt 校准，最大迭代 80。本站历史带来主要增益，邻站进一步提高三个目标的 PR-AUC。因此后续比较均保留完整特征。这支持特征组的价值，不能据此声称每个单独特征都有贡献；也不以测试结果重新选取后续参数。

6. 模型、不平衡处理与概率校准

模型	固定参数
L2 Logistic（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
Linear SVM（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
GBT（MLlib）	40 轮，深度 4，步长 0.1，128 bins，叶节点最少 20 行
XGBoost（Spark 接口）	80 棵树，深度 4，学习率 0.1，64 bins，子节点权重 20；$L_2 = 1$

Spark 的使用范围。前三类使用 `pyspark.ml`（MLlib 的 DataFrame API），XGBoost 使用外部 `SparkXGBClassifier`，不是内置 MLlib 算法。所有训练、预测和全量评价均通过 Spark；XGBoost 使用两个 CPU worker。参数预先固定，种子 5208，不宣称已系统优化超参数。36 个候选中，九个 SVM 及两个加权 Logistic 达到 100 次迭代上限，进一步增加迭代可能改变比较。

三**种训练策略**。自然分布：所有样本权重为 1。类别加权：$w_+ = N/(2P)$、$w_- = N/[2(N-P)]$，使两类总权重相等且总体平均权重为 1。受约束 SMOTE：目标正例占比 20%，正例总数最多为原始正例的 10 倍，只在训练集增加样本。校准、选择和测试不重采样也不加类别权重。

为什么约束 SMOTE？普通插值可能产生不存在的站点编码、断裂的日历周期或矛盾的湿次数。这里只在同站点、相同缺测模式、离散状态和雨量零值模式中寻找最多五个少数类近邻；只对 16 个连续雨量特征用同一个插值系数。日历、坐标、可用数、湿比例和年龄保持不变，孤立状态回退为复制。增加的向量经非负性、周期范数、完整累计单调性和湿次数一致性检查。少数类邻近搜索在有界训练池中用单线程 sklearn 完成，其余数据与模型操作由 Spark 完成。

阈值 mm	增加行数	增加后正例（%）	雨量特征改变行数	孤立状态复制行数
0	302,646	20.000	129,231	73,685
5	123,408	7.406	34,344	48,033
25	8,334	0.533	773	6,061

校准。每个候选的原始分数在自然分布的 2023 上半年拟合 Platt 映射：$\hat{p} = \sigma(az + b)$，约束 $a \geq 0$，使用 MLlib Logistic（正则 10^{-6}）。SVM 间隔经此步骤转换成概率；加权或 SMOTE 改变训练先验，校准也用于纠正概率尺度。校准不会自动保证换年份后的概率准确。

7. 评价方法与验证集选择

主要指标。ROC-AUC 衡量正负例排序，随机排序约为 0.5；PR-AUC 关注检出的正例是否准确以及覆盖多少正例，稀有事件下更有区分度。采用 Spark 精确排序积分（`numBins=0`）的梯形 PR 面积，不与 sklearn average precision 混称。无信息排序的参考 PR 水平接近正例比例；测试集三个目标依次为 0.06360、0.008345、0.0005517。

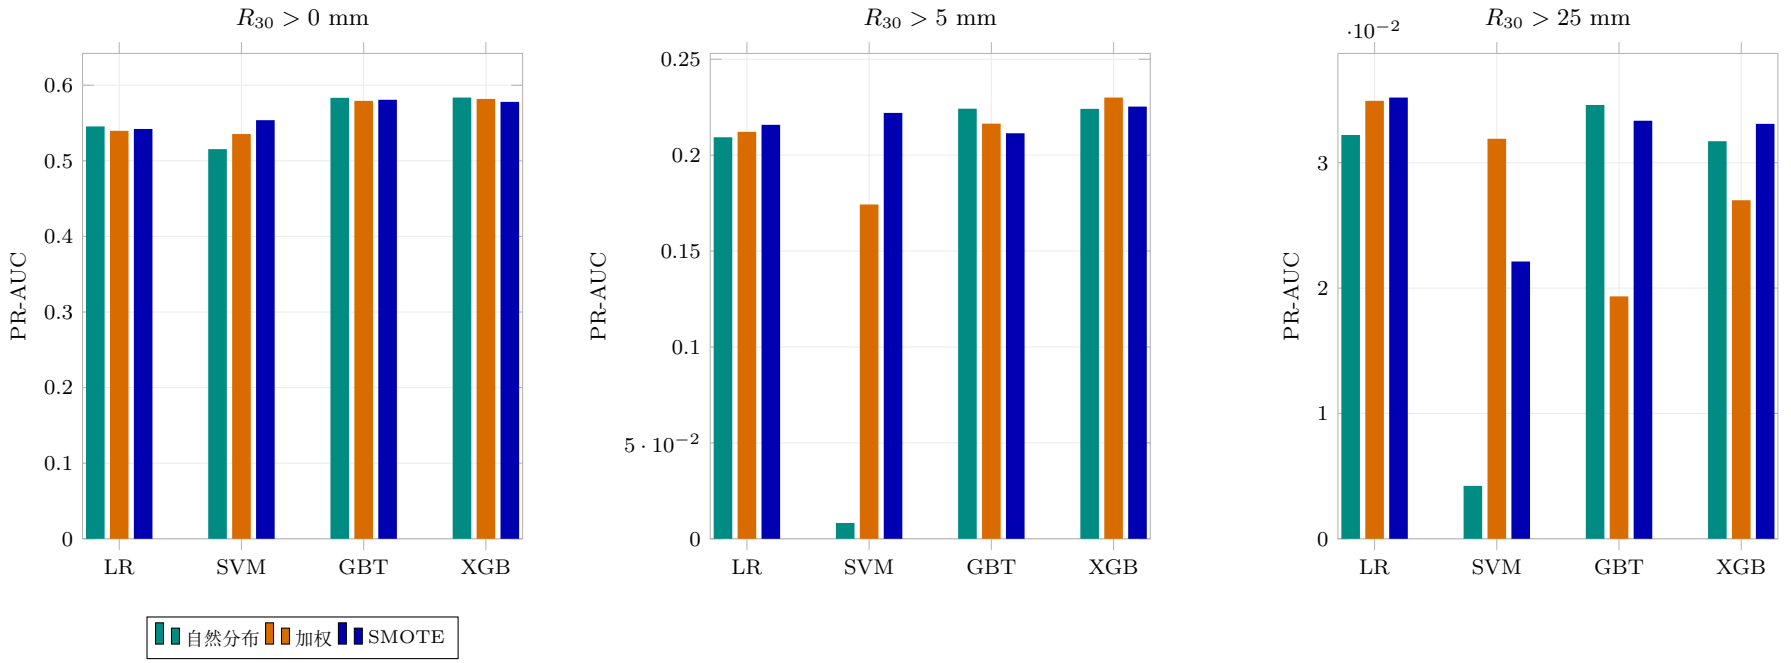
$$\text{Brier} = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)^2, \qquad \text{Precision} = \frac{TP}{TP+FP}, \quad \text{Recall} = \frac{TP}{TP+FN}.$$

概率与单点分类。Brier 越小越好，与固定输出真实训练正例率的基线比较。校准曲线将近似等频概率分组的平均预测与实际频率比较；分数并列会合并组，因此不强制恰好 20 个点。Precision、Recall、F1、Accuracy 仅作为辅助，概率截断在选择集上从候选网格最大化 F1 后固定；这与输入雨量阈值 q 是两种不同阈值。

算法 / 训练策略	选择集 PR-AUC：0 mm	5 mm	25 mm
Logistic / 自然分布	0.54547	0.20932	0.03221
Logistic / 加权	0.53968	0.21216	0.03493
Logistic / SMOTE	0.54213	0.21581	0.03520
SVM / 自然分布	0.51546	0.00825	0.00422
SVM / 加权	0.53541	0.17428	0.03191
SVM / SMOTE	0.55375	0.22202	0.02212
GBT / 自然分布	0.58332	0.22421	0.03460
GBT / 加权	0.57932	0.21642	0.01934
GBT / SMOTE	0.58073	0.21141	0.03335
XGBoost / 自然分布	0.58368	0.22413	0.03171
XGBoost / 加权	0.58186	0.23002	0.02701
XGBoost / SMOTE	0.57796	0.22531	0.03310

冻结选择。在 2023 下半年按 PR-AUC 选每种算法、每个阈值的策略，Brier 仅打破并列；再选默认算法。默认路由为 0 mm：自然分布 XGBoost；5 mm：加权 XGBoost；25 mm：SMOTE Logistic。最终仅将每类算法各阈值选出的 12 个模型用于完整 2024 测试。SMOTE 改善了某些线性模型，但 GBT 三个目标均选择自然分布，不能概括为所有模型都会改善。

图 7：不平衡处理的验证集比较



怎样读图。每个面板对应一个雨量阈值，同一算法的三根柱子在完整自然分布选择集上比较。高阈值更罕见，三个面板使用各自纵轴刻度。0 mm 的树模型领先，5 mm 的 XGBoost 加权最优，25 mm 的 Logistic SMOTE 选择集 PR-AUC 最高。策略是否有效取决于模型和目标，不能仅依据训练正例数增加来判断。

8. 2024 年时间后移测试结果

雨量阈值 mm	算法	验证选定策略	ROC-AUC	PR-AUC	Brier
0	Logistic	自然	0.85500	0.55978	0.0392757
0	SVM	SMOTE	0.86049	0.57387	0.0399706
0	GBT	自然	0.87749	0.60338	0.0368843
0	XGBoost	自然	0.87986	0.60797	0.0364959
5	Logistic	SMOTE	0.85004	0.18162	0.0075438
5	SVM	SMOTE	0.77601	0.20093	0.0077220
5	GBT	自然	0.86100	0.20891	0.0074329
5	XGBoost	加权	0.87526	0.21299	0.0072292
25	Logistic	SMOTE	0.85651	0.01805	0.0005483
25	SVM	加权	0.84840	0.01550	0.0005484
25	GBT	自然	0.76516	0.01881	0.0005618
25	XGBoost	SMOTE	0.88889	0.01918	0.0005461

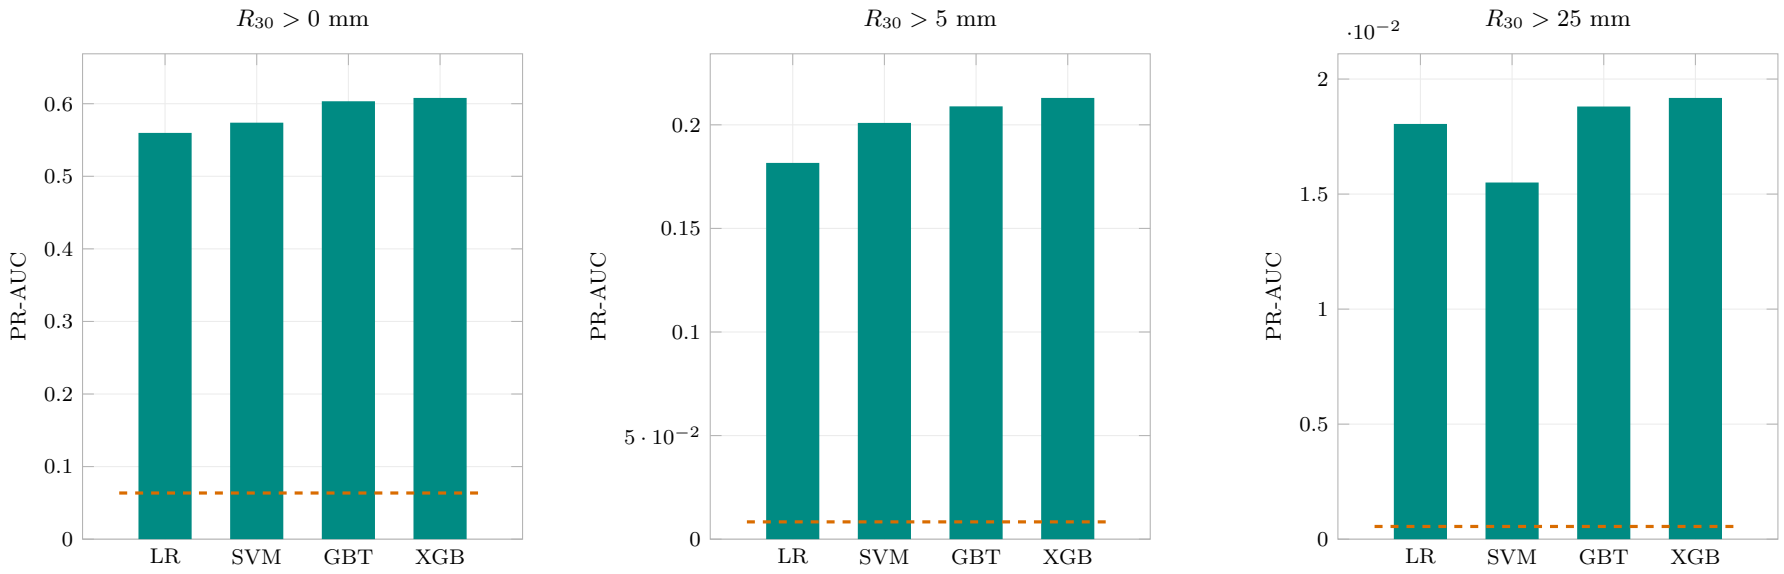
测试规模与基线。三种目标均评价 6,374,476 个真实窗口，正例比例为 6.3602%、0.83447%、0.055173%。常数训练正例率基线的 Brier 依次为 0.0595707、0.0082752、0.0005514；全预测无雨的 Accuracy 依次达 93.64%、99.17%、99.945%，说明 Accuracy 不能代替稀有事件识别能力。所有表格均为校准后结果。

结果解读。XGBoost 的测试 PR-AUC 在三个目标上分别为 0.60797、0.21299、0.01918；高阈值 ROC-AUC 仍达 0.88889，但 PR-AUC 很低，意味着极端事件虽能富集，可靠识别仍困难。25 mm GBT 的 Brier 为 0.0005618，甚至劣于常数基线。25 mm 默认仍使用验证集选出的 Logistic，不能看到测试结果后再换成 XGBoost。

默认目标 mm	算法	训练诊断 PR-AUC	选择 PR-AUC	测试 PR-AUC
0	XGB	0.61237	0.58368	0.60797
5	XGB	0.22789	0.23002	0.21299
25	LOGISTIC	0.04515	0.03520	0.01805

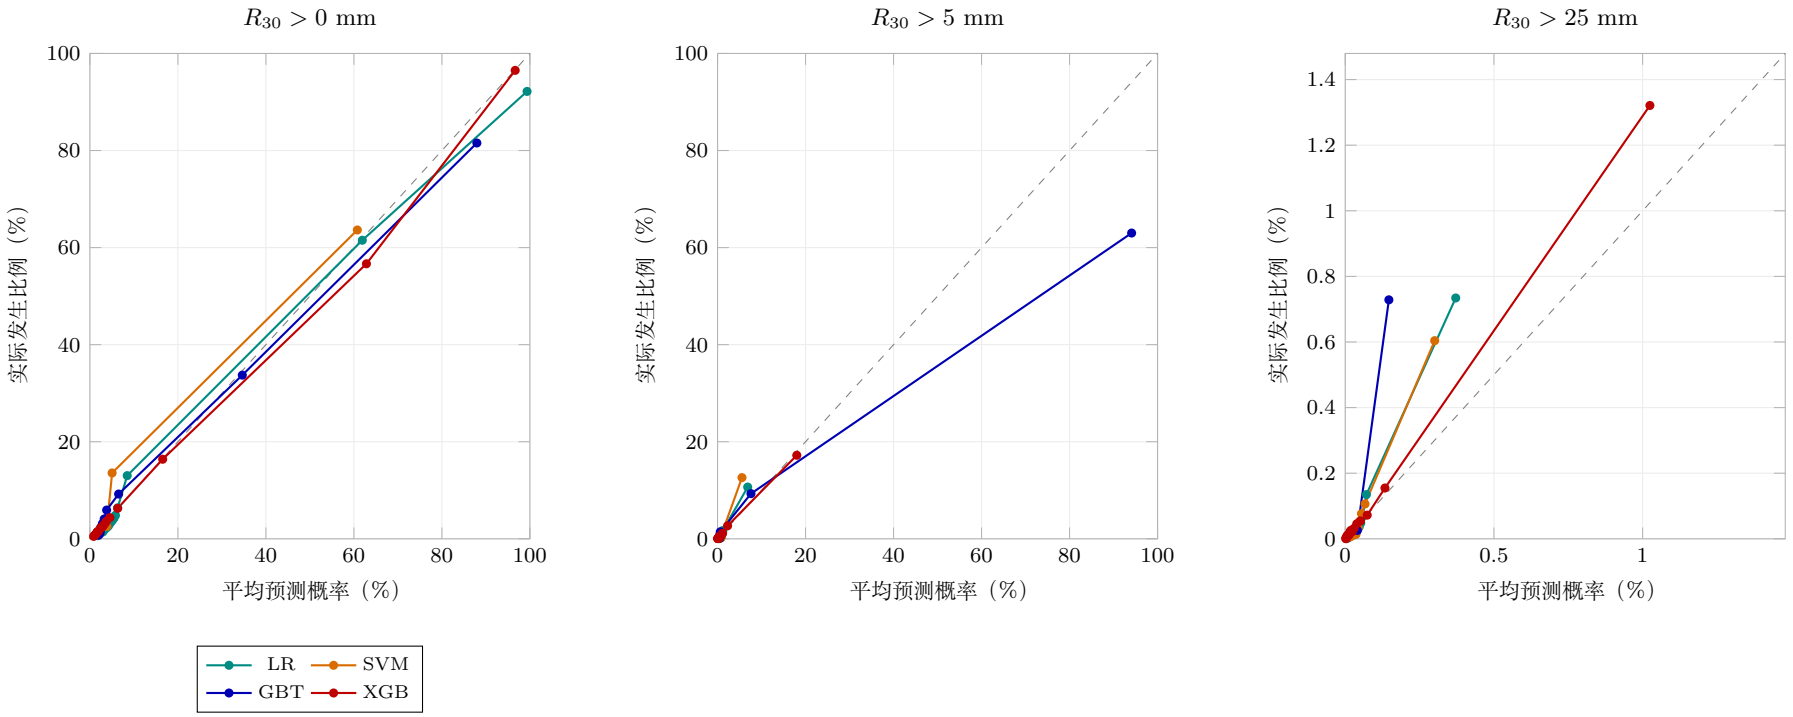
样本内外评价。训练诊断统一使用原始真实训练样本的固定 20% 子集（344,957 行），不评价合成训练行；选择集与测试集分别评价全量。以上数值的正例比例不同，不能把 PR-AUC 差距全部解释成过拟合。25 mm 自然 GBT 的训练诊断 PR-AUC 为 0.17452，选择为 0.03460，提示稀有标签下的泛化困难；926 个原始训练正例又可能对应重叠窗口，并非 926 场独立暴雨。

图 8：测试集排序与概率误差



参考线。橙色虚线为测试正例比例，提供无信息排序的 PR 参考水平。各柱对应前表中已经冻结的算法策略。25 mm 虽高于约 0.00055 的参考线，但绝对 PR-AUC 仍很小；高 ROC-AUC 不等于很高的暴雨预测精确率。概率误差另见 Brier 表与下一页校准曲线。

图 9：校准曲线与概率质量



怎样读图。灰虚线为理想校准；线上方表示实际发生更多、模型低估，线下方表示高估。每点是一组分数相近的真实测试窗口，点数少不代表测试样本少。稀有事件大部分概率接近零，最高概率组仍包含大量低风险窗口，因此曲线不是完整高风险尾部诊断。

实际校准收益。25 mm 的 SMOTE Logistic 在选择集上，未经校准 Brier 为 0.0011352，校准后降至 0.0007248；平均概率从 0.0055317 降至 0.0004886，而实际正例率为 0.0007329。校准显著纠正重采样引入的概率膨胀，但仍低估部分风险，且校准之后必须再用后移测试评价。

9. 默认模型的单点指标与补充观察

雨量阈值 mm	验证选定概率截断	Precision	Recall	F1	Accuracy
0	0.31989	0.61636	0.56524	0.58970	0.94997
5	0.15488	0.28201	0.34305	0.30955	0.98723
25	0.01462	0.05165	0.11288	0.07087	0.99837

使用含义。表中的概率截断仅展示一个固定工作点；例如 25 mm 的 F1 仍较低，高 Accuracy 主要来自大量负例。实际预警可根据误报与漏报成本调整概率截断，但不得在测试标签上挑出最优截断再宣称泛化成绩。主比较继续使用 ROC-AUC、PR-AUC，并单独评价概率质量。

SMOTE 的信息量。25 mm 共增加 8,334 行，其中只有 773 行改变雨量特征，6,061 行来自孤立状态复制。受约束合成保持一致性，却不能制造新暴雨信息；这解释为何增加样本未带来普遍巨大提升。未来可增加真实正例训练规模、优化稀有事件权重和参数，并按独立天气事件划分或分组评估。

跨阈值一致性。三个目标独立训练与校准，不能保证 $\hat{p}_{25} \le \hat{p}_5 \le \hat{p}_0$。在 2024 全量测试上，同算法选定模型组合的违反次数为 Logistic 1、SVM 2,448、GBT 528、XGBoost 247（分母均为 6,374,476）。这是各算法组合的核验；混合算法默认路由尚未做该全量检查。后续可加入联合单调校准，但本次不宣称已获得完整一致的雨量分布。

空间与时间依赖。站点邻近、同一事件与重叠半小时窗口导致样本相关，百万行不等于百万个独立天气事件。本次报告描述性测试成绩，不给出基于独立行假设的置信区间。未来可用按日期或天气事件的分块重采样评估不确定性，进一步检验跨站点及跨年份泛化。

10. 计算资源、模型保存与预测复现

实际服务器配置。gpushare 单机 Spark `local[2]`，CPU affinity 为 0、1；driver heap 2 GiB，shuffle partitions 8，BLAS/OpenMP 单线程，nice 19、idle I/O，不使用 GPU。每五秒采样进程树 RSS，超过 4 GiB 或项目磁盘剩余少于 5 GiB 时停止；这是采样保护，不是操作系统硬限额。比较阶段采样 RSS 峰值 2.719 GiB，最小磁盘剩余 26.984 GiB，含中断尝试。当前部署并非多节点集群，也没有用多个 Docker 模拟集群。

耗时与执行范围。36 个最终有效基础模型的拟合时间合计约 32.05 分钟；各训练组连同校准、训练诊断和选择集评价的工作进程时间合计约 58.30 分钟。最近一次恢复运行约 48.95 分钟，复用了已完成的组，不能当作从头运行总耗时。全量标签与特征准备另计，首次下载、失败重试、模型传输与报告编译也未包含在上述拟合时间内。

已保存的模型。保留全部 36 个比较 Pipeline 与首轮九个 Logistic 模型，包括训练拟合的填补、编码、基础分类器及 Platt 映射。`models/model_comparison/manifest.json` 记录阈值路由、验证选择、参数和合成版本。36 个比较模型共 2,053 个文件、3,869,936 字节；这些模型内部的 metadata/data 是必要训练产物，不能当统计中间文件删除。服务器与本地模型文件已逐一 SHA256 核验一致。

保存与载入核验。12 个验证选定完整 Pipeline 在 15 条无标签真实特征行上通过保存载入预测核验，包括三个未知站点 ID；与分离预处理及模型步骤的概率差为零。只输入站点、时刻、阈值的档案预测示例：S07，2024-03-01 12:00:00+08:00，5 mm，默认加权 XGBoost 输出 0.00618169（约 0.618%）。这验证了历史档案检索和模型路由，尚不是实时在线天气服务。

```
PYTHONPATH=.runtime/python python scripts/run_task2_models.py \
  --predict-station S07 --predict-time 2024-03-01T12:00:00+08:00 \
  --threshold 5
```

材料组织。README 包含环境准备、八年数据下载、Spark 特征构造、训练、评价与预测命令。原始年度数据和工作目录不进入 Git；按 README 可从官方来源重新下载。报告与模型可直接查看和加载，生成新的历史预测特征则需要重建数据。已保存独立 LaTeX 和模型后，再进行 Git 备份与 Desktop 副本同步。

11. AI 使用声明、来源与复现

AI 使用声明。OpenAI Codex 协助项目规划、API 检查、运行环境配置、PySpark 清洗、聚合、标签与特征工程、MLlib 和 XGBoost 训练、受约束 SMOTE 实现、执行核验、指标与图表代码、中英文 LaTeX 写作翻译、编译及排版检查。天气统计与模型成绩来自真实年度数据的实际运行；SMOTE 只用于训练，合成向量不作为真实观测或验证、测试样本。组员须审阅代码、方法和结果，并对最终提交负责。

资料来源。

1. NEA，Historical Rainfall across Singapore，2017–2024 年度数据集：data.gov.sg 集合 2279。运行下载脚本时生成年度来源和校验信息。
2. Meteorological Service Singapore，Climate of Singapore。仅用于季节与日内周期的气候背景，不代替项目观测，也不证明机制或因果关系。
3. NEA，2019 年气候回顾。用于偏干年份与正位相印度洋偶极子的外部背景，未用作模型预测特征。
4. geoBoundaries，Singapore ADM0 元数据。轮廓源自 URA 2016 年资料，ODbL 1.0；下载的发布元数据和 GeoJSON 保存在 `reports/assets/`，不应解释为现今海岸线测绘。
5. Apache Spark 3.5.8，MLlib 分类与回归文档，用于 Logistic、Linear SVM 与 GBT 实现；评价采用 Spark BinaryClassificationEvaluator。
6. XGBoost，PySpark Estimator 文档，用于外部 Spark XGBoost 集成；实际安装版本为 3.2.0。

可复现材料。源码与运行说明在 `scripts/` 和 `README.md`；中英文报告保留独立 LaTeX 与 PDF。`models/` 保留训练好的 Spark Pipeline、预处理器和阈值路由清单。图表数值直接内嵌 LaTeX，不依赖独立图片、统计 CSV 或交互页面；运行脚本可在临时工作目录重新生成统计与核验记录。

课程提交状态。提交材料为完整源代码与 README、训练好的模型及 PDF 报告；截止日期为 2026 年 10 月 18 日。两项任务的分析与模型已完成，本报告按小组要求只列成员姓名。Git 备份地址为 `https://github.com/Panyuxiang0830/singapore_rainfall.git`。服务器目录只在整个项目完成且持久备份核验后清理。