新加坡历史降雨：时空规律与概率预测

Task 1 与 2：2017–2024 年 Spark 探索与概率预测

小组成员。潘禹翔、侯佳成、吴嘉蕊。

研究内容。本项目利用 2017–2024 年的新加坡降雨观测数据分析时间与空间变化规律，并建立模型，预测监测站在未来 30 分钟内累计雨量超过给定阈值的概率。

数据与方法。使用 NEA / data.gov.sg 的八个年度数据集，源记录共 48,538,713 条，去重后 48,538,627 条，涉及 91 个站点 ID。全量清洗和聚合由 Spark 执行；跨年比较采用 21 个稳定站点，避免监测网络变化混入年度差异。

主要结果。全部有效五分钟区间中 97.08% 无雨。合格日内样本的雨频高峰为新加坡时间 16:00–17:00。月度可用样本平均雨频以 11 月最高、7 月最低，但各月的可用年份及站点组成不完全相同。固定站点样本中，按观测时长归一化的雨量以 2019 年最低、2021 年最高。近距离站点的日雨量相关性总体高于远距离站点；八年不能据此推断长期气候变化。

预测结果。使用 2017–2022 年全部 34,542,285 条有效记录训练模型，2023 年用于概率校准和选择，2024 年用于测试。原模型比较选定三个 XGBoost 模型；后续 5 mm 调参模型的测试 PR-AUC 从 0.21839 提高至 0.22640，Brier 从 0.0072009 降至 0.0071609。当前预测入口采用该 5 mm 模型，0 与 25 mm 沿用原模型。额外空间交互特征未改善 2023 年验证表现，未采用。

年份	雨量 / 观测 24h（mm）	雨频（%）	湿区间雨强（mm/5min）	平均覆盖率（%）
2017	6.85	2.85	0.833	94.6
2018	7.10	2.90	0.840	82.9
2019	4.81	1.97	0.841	94.7
2020	7.40	2.92	0.877	95.3
2021	7.84	3.04	0.895	97.8
2022	7.71	3.08	0.868	99.0
2023	7.52	3.16	0.824	95.2
2024	7.11	3.01	0.819	95.6

表中各年均使用相同的 21 个站点，站点等权。雨量指标按观测时长归一化，不能解释为官方年度累计或真实日累计。月度图和日内图的合格样本组成仍可变化。

1. 数据来源、字段与清洗

来源与字段。每条记录包含 observation timestamp、update timestamp、station ID/name/device ID、经纬度、reading update timestamp、reading value、reading type、reading unit 及日期字段。本数据只有降雨相关观测，不包含气温、湿度和风等变量。API 预览只用于确认字段和年度 ID；所有天气结论来自完整文件。

数据核对。下载完整年度 CSV 后，将 Spark 读入的记录数与年度 API 元数据的记录数核对，并检查重复观测、时间对齐和雨量取值。

清洗步骤。Spark 按 Asia/Singapore 解析时间；保留有限、非负、单位为 mm、类型为预期五分钟累计、站点 ID 和时间合法且 CSV 记录有效的行。只有与五分钟网格的距离不超过两秒时才对齐，原始 epoch 同时保留；其他离网格记录排除并审计。按 station ID 与对齐时刻去重，优先保留 reading update 最新的行，再使用原始观测时刻及确定的字段顺序打破并列。年度文件合并后再次检查跨文件重复。

年份	源记录数	删除重复数	偏离网格超过 2 秒	负雨量数	站点数
2017	5,256,106	86	0	0	62
2018	4,594,246	0	0	0	56
2019	5,026,862	0	0	0	54
2020	6,334,473	0	0	0	80
2021	7,044,646	0	0	0	76
2022	7,133,230	0	0	0	72
2023	6,742,890	0	0	0	74
2024	6,406,260	0	0	0	70

清洗结果。86 条重复记录全部来自 2017 年；八年数据中未发现负雨量、偏离五分钟网格超过两秒的时间戳或跨文件重复。缺失时段不计为零雨量。对超过 50 mm/5min 的读数进行额外筛查，本次没有触发该条件的记录。

2. 指标定义与公平比较

设站点在给定时间段内的有效观测数为 N，雨量为 $r_i \geq 0$，有雨区间数为 $W = \sum_i \mathbf{1}(r_i > 0)$，预期日历槽数为 E。本文使用：

$$\begin{aligned} \text{覆盖率} &= N/E, \qquad E = 288 \times \text{日历天数}, \\ \text{雨频（\%）} &= 100W/N, \\ \text{湿区间雨强（mm/5min）} &= \sum_i r_i/W \quad (W > 0), \\ \text{雨量 / 观测 24h（mm）} &= 288 \sum_i r_i/N. \end{aligned}$$

预期日历槽数显式处理闰年；低覆盖率也可能反映站点只运行了部分年份。雨强的分母仅包含有雨区间。对于单个站点和同一时间段，归一化雨量等于 288 × 雨频/100 × 湿区间雨强。分别取站点平均后，该乘积恒等式一般不再成立。归一化雨量不是官方日累计或年度累计，也不能恢复遗漏风暴。

年度固定样本。八年共出现 91 个站点 ID，其中 21 个同时满足：八年均有观测、每年覆盖率至少 80%、经纬度跨度各不超过 0.005°。其余 70 个只是不进入固定站点的跨年比较，清洗时没有删除这些站点的有效观测。21 个站点等权平均；不同分析使用的站点范围见下一页。

月度与日内样本。图 2、4 从这 21 个站点中进一步筛选数据完整的年月或小时组合。月度先对站点等权平均，再对可用年份等权平均；每个合格年月有 17–21 个站点，各月有 6–8 个可用年份。严格要求同站点同月份在八年均达标时，只剩 5、6、7、9、10、12 月，作为额外对照。

空间比较。图 1 使用 2024 年的站点，当年共 70 个，其中 56 个覆盖率至少 90%，用于地图着色，另 14 个以灰色标记。图 5 使用固定 21 站的日累计，要求日覆盖率至少 95%，每对至少有 365 个共同有效日期。80%、90%、95% 是本项目选定的数据完整程度门槛。

3. 计算环境与各项分析的样本范围

计算环境。Task 1 使用 Apple Silicon Mac：10 个逻辑 CPU、16 GiB RAM，macOS 26.5.2 ARM64，Python 3.12.14、Java Temurin 17.0.20.1+1、Spark 3.5.8。Task 2 在 gpushare 运行，环境为 Python 3.11.10、Azul Zulu Java 17.0.20.1、Spark 3.5.8、XGBoost 3.2.0。gpushare 容器配额为 42 CPU、约 667.68 GiB RAM；完整特征的模型训练限定使用 20 个 CPU，默认 driver heap 为 6 GiB。

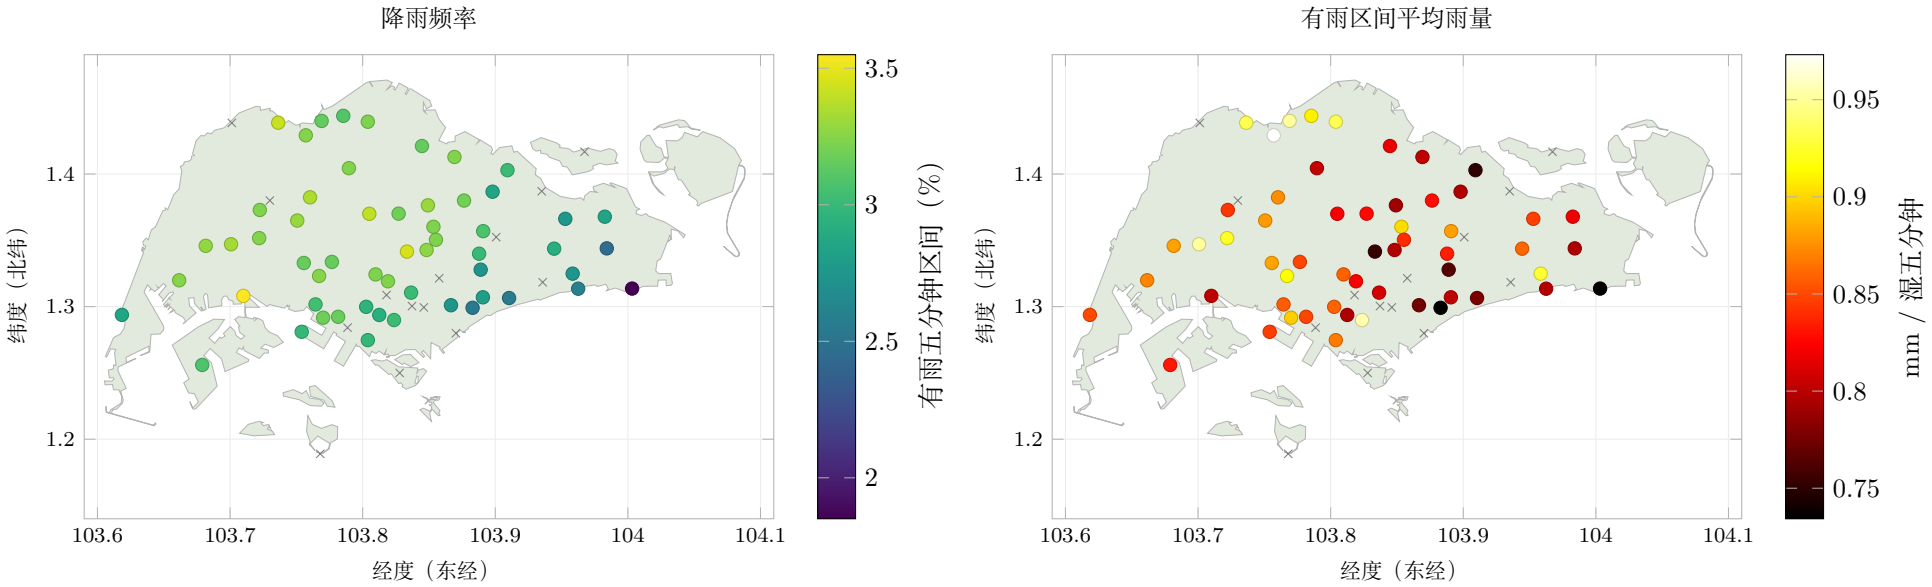
Spark 配置与分工。Task 1 与初始特征组比较采用单机双线程模式 `local[2]`。完整特征的模型比较与评价采用 `local[20]`，shuffle partitions 为 80，default parallelism 为 20。XGBoost 使用两个工作进程，每个任务配置 10 个 CPU。不使用 GPU，以低优先级串行执行各项实验。Spark DataFrame/SQL 与窗口函数用于全量清洗、时间聚合、标签和特征构造；模型训练与评价使用 Spark ML 管线。一般阶段 Java 堆为 6 GiB，进程总内存停止上限为 12 GiB；XGBoost 训练和评价的总内存上限为 40 GiB。

分析样本。各项分析根据比较目的采用相应的站点范围与数据完整性筛选条件，具体见下表。

分析	使用范围	筛选说明
图 1：2024 站点地图	当年 70 站中的 56 站	年覆盖率至少 90%；另 14 站灰色标记
图 2：月度变化	固定 21 站的合格子集	每个合格年月保留 17–21 站
图 3：年度变化	同一组 21 站	其余 70 站不参与固定站点跨年比较
图 4：日内变化	固定 21 站的合格组合	年月小时组合覆盖率至少 80%
图 5：距离与日雨量相关性	固定 21 站，210 对	日覆盖率至少 95%，共同有效日至少 365
图 6 左：有雨时的雨量分布	八年全部 91 站	仅统计有雨五分钟区间
图 6 中、右：半小时超阈值与持续性	2024 年全部 70 站的有效观测	六个未来槽完整，或两个五分钟槽连续

清洗核对。源记录数与 API 计数一致；删除 86 条重复记录，缺失时段不补成零。全部观测的无雨比例也使用全部 91 站，而不是仅使用 21 站。

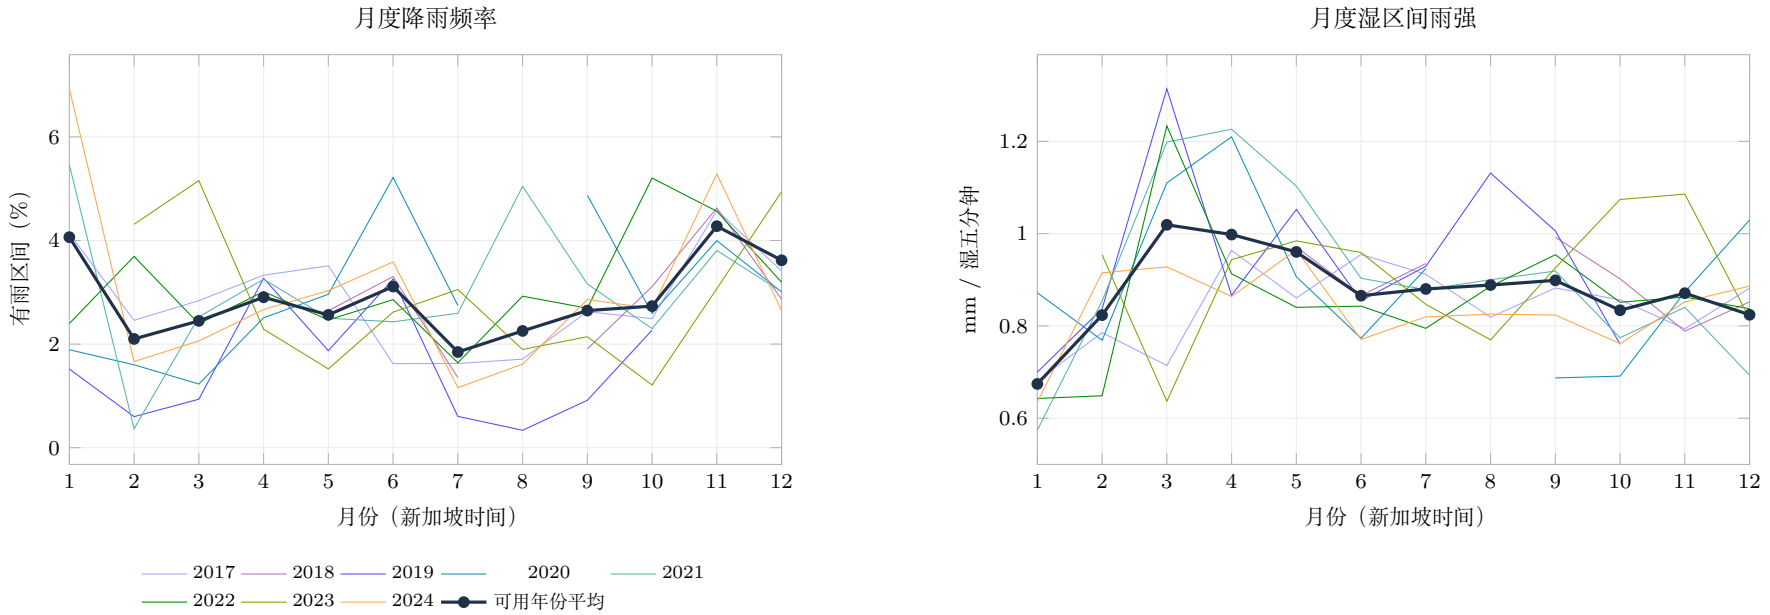
图 1：2024 年观测站降雨地图



2024 年有 70 个站点，其中 56 个年度覆盖率不低于 90%。彩色点只表示该观测站的统计量；灰色叉为低覆盖率站点。S33（Jurong Pier Road）的雨频最高，为 3.55%。地图不进行空间插值，也不代表岛上每个位置的降雨量。边界采用 geoBoundaries 中源自 URA 的 2016 年陆地轮廓（ODbL 1.0），仅作地理参照。

Task 2 特征启示（站点）。候选特征包括站点 ID 和经纬度，以表示站点间差异。Task 2 不直接沿用跨年比较的 21 站限制，而按历史特征及未来标签的完整程度筛选训练窗口。

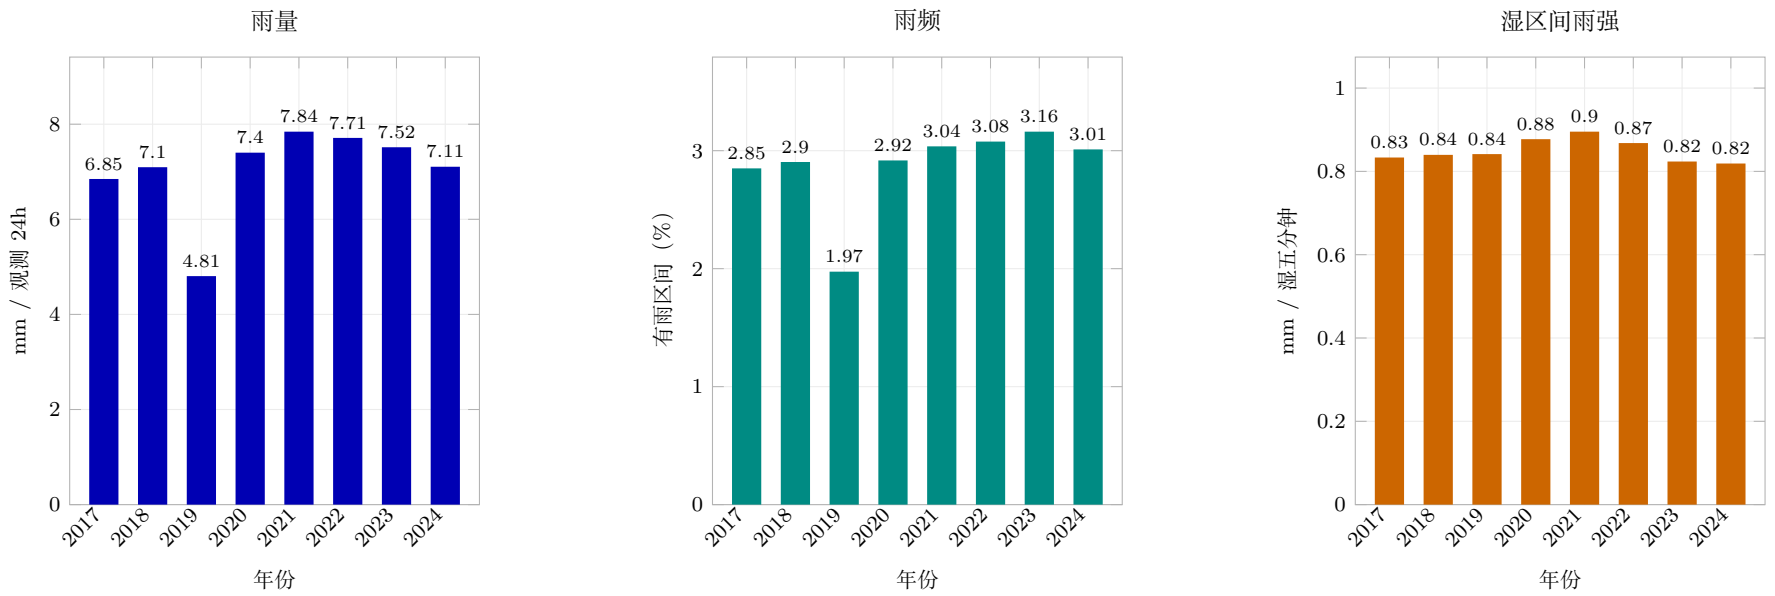
图 2：一年内的月度规律



固定站点样本中，合格站点年月的覆盖率至少为 80%，先对站点等权平均，再对可用年份等权平均。月度平均雨频以 11 月最高（4.28%）、7 月最低（1.85%）；有雨区间平均雨量以 3 月约 1.02 mm、1 月约 0.67 mm。雨频与有雨区间雨量呈现不同的季节变化。各月包含 6–8 个年份，每个合格年月包含 17–21 个站点。

Task 2 特征构造（月份）。月度雨频与雨强的变化模式不同，因而使用月份的正弦、余弦编码表示年内周期，并与小时编码组合，刻画季节与日内降雨规律的共同作用。

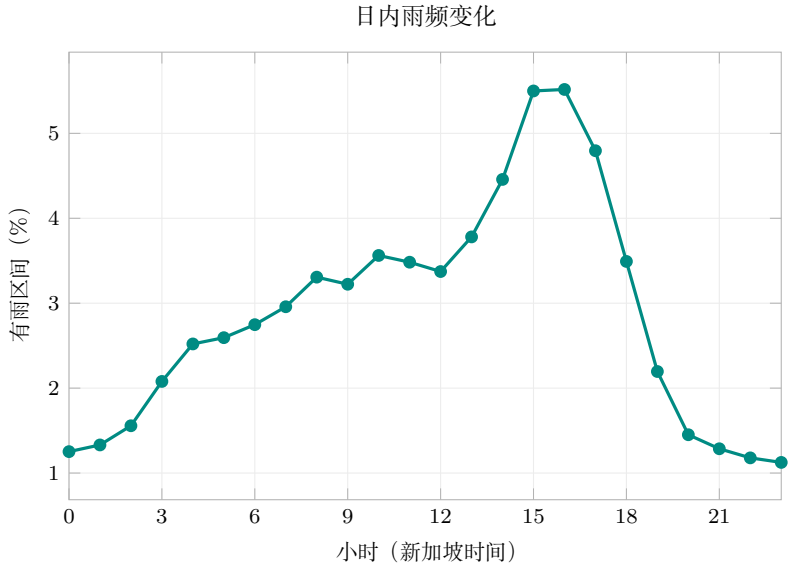
图 3：固定站点的年度变化

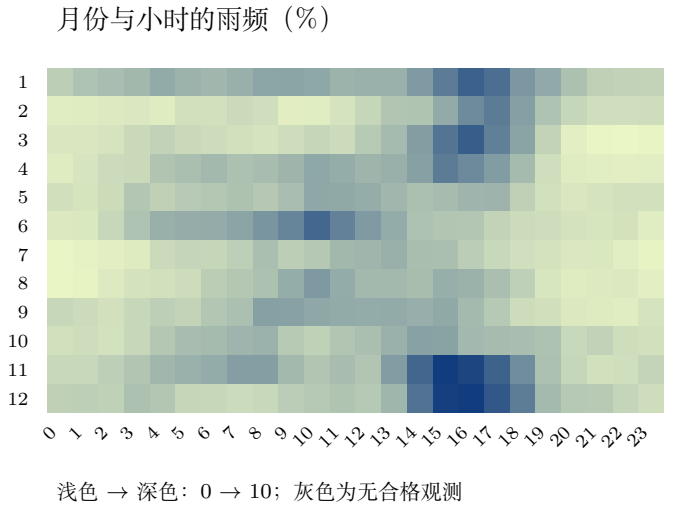


各年采用相同的 21 个站点进行等权比较，每个站点的年度覆盖率至少为 80%。平均雨量 / 观测 24h 从 2019 年的 4.81 mm 到 2021 年的 7.84 mm。2019 年的雨频为 1.97%，明显低于其余年份，而有雨区间雨量为 0.841 mm，与相邻年份接近，表明该年偏低的归一化雨量主要对应较低的降雨频率。

Task 2 特征构造（年份）。训练、验证和测试按年份划分。模型使用月份与小时的周期特征，不加入年份编号。NEA 的 2019 年气候回顾将当年偏干与强正位相印度洋偶极子联系起来，为年际变化提供外部背景。

图 4：降雨频率的日内变化

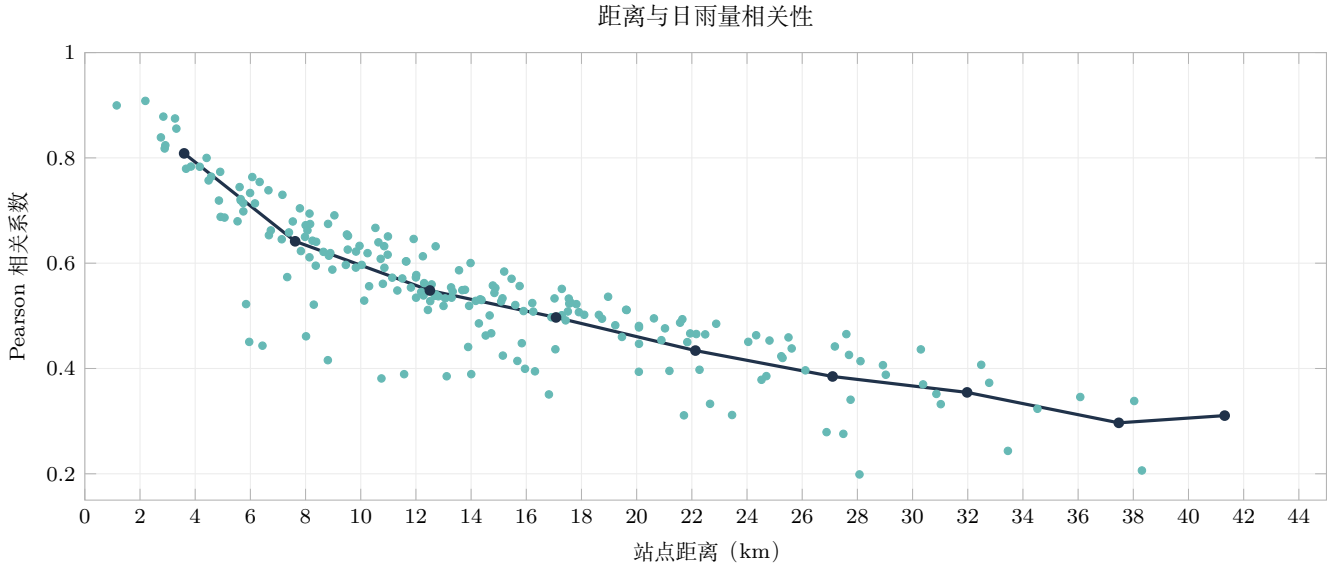




降雨频率在 16:00–17:00 达到日内高峰，且高峰时段与强度随月份变化。11–12 月的下午高峰较明显，6 月的较高雨频更接近上午至中午。统计对覆盖率至少 80% 的站点、年份、月份、小时组合等权平均。该结果支持同时使用小时、月份与二者交互项作为预测特征。

Task 2 特征启示（小时与月份）。使用新加坡当地小时的周期编码，并考虑月份与小时的交互项：下午雨频高峰的强弱和时刻会随月份变化。Logistic 和线性 SVM 需显式构造交互特征；树模型可学习这类组合关系，其实际贡献仍由对照实验检验。

图 5：站点距离与日雨量的相关性

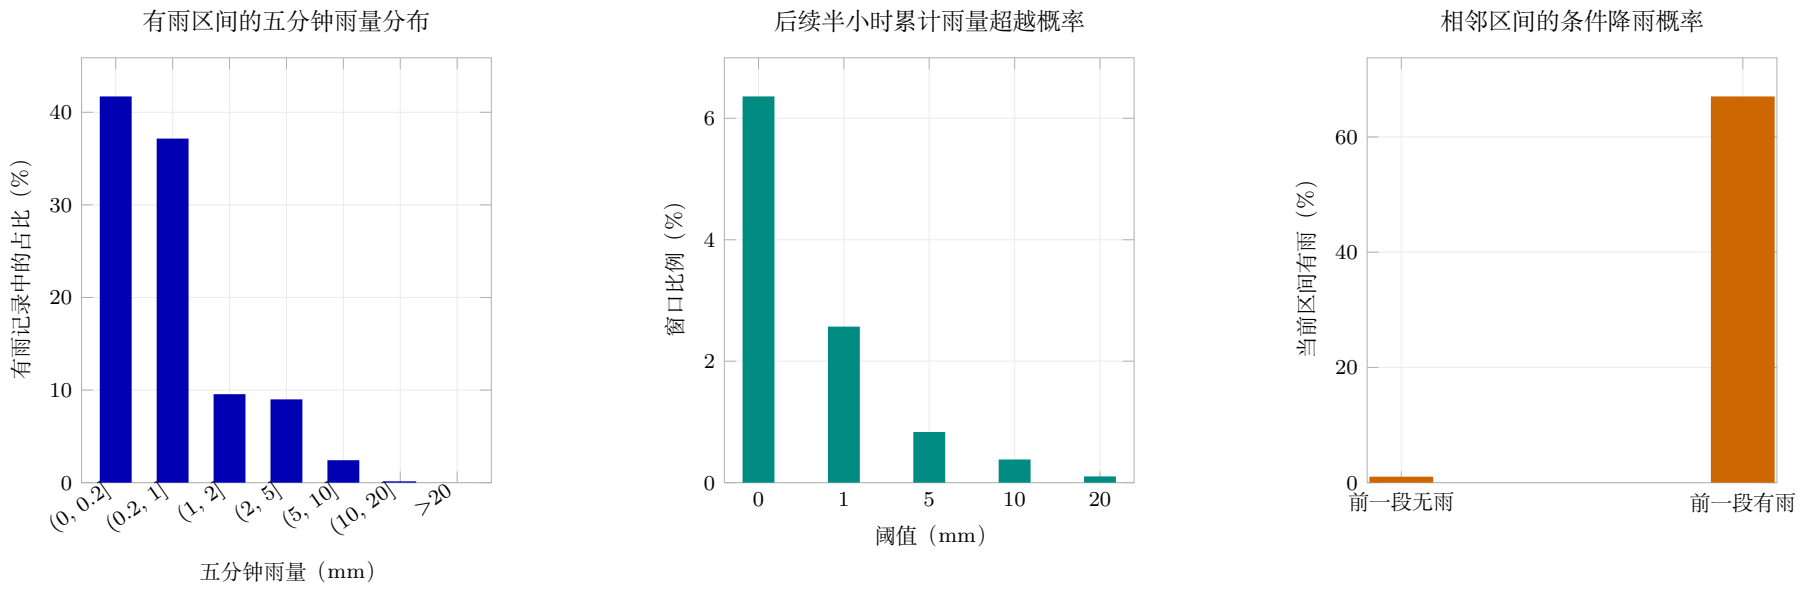


21 个站点形成 210 对站点组合。距离不超过 5 km 的 17 对站点，日雨量平均 Pearson 相关系数为 0.809；距离超过 30 km 的 12 对为 0.336。每 5 km 距离组的平均相关性总体随距离增加而降低，表明降雨具有空间相关性。

站点并非独立。附近站点可能同时经历同一场降雨；不同站点对还可能共享同一个站点。因此，91 个站点不能视为 91 份完全独立的天气样本，210 对相关系数也不是 210 个独立样本。共同有效日的筛选与前文相同。

Task 2 特征构造（邻站）。邻近站点的日雨量呈现较强相关性，因此加入三个最近邻站的历史雨量均值、最大值和有雨比例。Task 2 通过加入邻站特征前后的模型比较，评价其对半小时预测的贡献。

图 6：雨量分布、半小时超越概率与降雨持续性



有雨区间的雨量分布。八年全部站点的有雨五分钟观测中，41.72% 的雨量位于 $(0, 0.2]$ mm，37.16% 位于 $(0.2, 1]$ mm。合计 78.88% 的有雨区间雨量不超过 1 mm，表明多数降雨区间的累计雨量较小。全部有效五分钟观测中的无雨比例为 97.08%。

半小时累计雨量的超越概率。2024 年共有 6,374,476 个完整后续六区间窗口。后续 30 分钟累计雨量严格超过 0 mm 和 5 mm 的窗口比例分别为 6.36% 和 0.83%，超越概率随雨量阈值升高而降低。累计雨量按九位小数比较，以避免阈值边界的浮点误差。图中横轴按阈值类别排列。

相邻区间的降雨持续性。2024 年同站点连续五分钟观测显示，前一区间无雨时，后一区间有雨的条件概率为 1.04%；前一区间有雨时，该概率为 67.03%。降雨具有明显的短时持续性，支持在预测模型中纳入近期雨量及连续有雨时长。

Task 2 特征启示（持续性与稀有事件）。实际特征包括最近读数、过去 15/30/60 分钟累计、近期雨势变化和连续有雨时长。只使用预测时已可获得的记录，缺测不补为无雨。下文逐阈值给出正例数、PR-AUC、Brier score 和校准曲线。

4. Task 2：预测目标与时间切分

预测目标。对于站点 s、时刻 t 和雨量阈值 q，估计未来 30 分钟累计雨量严格超过 q 的概率。设置 $q \in \{0, 5, 25\}$ mm，每个目标分别训练分类器；同一站点时刻保留一份特征与三个标签列。

$$R^{30}_{s,t} = \sum_{k=1}^{6} r_{s,t+5k\,\min}, \qquad y^{(q)}_{s,t} = \mathbf{1}(R^{30}_{s,t} > q), \qquad \hat{p}_q = P(y^{(q)} = 1 \mid x_{s,t}).$$

标签构造。将时间戳作为五分钟区间的终点，累计 $(t, t+30\text{min}]$ 内六个有效区间的雨量，保留九位小数后与阈值比较。当前区间不计入目标；任一未来区间缺测时不构造标签。累计雨量等于阈值时标签为 0。

用途	有效行数	>0 正例	>5 正例	>25 正例
2017–2022：全部训练记录	34,542,285	2,074,430	279,801	19,787
2023 上半年：概率校准	3,325,499	251,794	30,699	1,532
2023 下半年：模型选择	3,393,373	197,358	28,000	2,487
2024：测试	6,374,476	405,430	53,193	3,517

训练与验证。所有基础分类器与预处理均使用 2017–2022 年全部 34,542,285 条有效训练记录。2023 年上半年拟合概率校准函数，下半年选择模型及概率判别阈值；2024 年用于测试。标签窗口不得跨上述时间边界。校准、选择和测试保留自然类别分布。

5. 从 Task 1 到特征工程

Task 1 依据	构造方式	实际输入
下午高峰随月份变化	小时、月份周期编码与交互	8 个日历特征；不加入年份 ID
站点差异与空间相关	站点 ID、经纬度、三个最近邻站	邻站雨量均值、最大值、有雨比例
短时降雨持续性	最新读数及 5/10/15/30/60 分钟滞后	15/30/60 分钟累计、变化和雨段长度

历史与邻站特征。只使用预测时已可获得的观测，观测时刻和保留的更新时间均不晚于 t。从过去 90 分钟检索历史；最近读数超过 30 分钟时标记不可用。邻站由当时已知坐标确定，聚合三个最近合格邻站的雨量、有效观测数、读数年龄及距离。Spark 窗口函数和连接处理全量记录。

时间编码。令 h 为当地小时（包含分钟的小数部分），m 为月份。小时和月份使用下列周期编码，并将两组编码的四个乘积作为交互项，共形成八个特征。这样 23:00 与 00:00、12 月与 1 月在特征空间中保持接近。

$$h_{\sin} = \sin(2\pi h/24), \quad h_{\cos} = \cos(2\pi h/24), \qquad m_{\sin} = \sin[2\pi(m-1)/12], \quad m_{\cos} = \cos[2\pi(m-1)/12].$$

输入处理。缺失值采用训练期均值填补；缺失标志的筛选和站点类别词表也仅使用完整训练期。线性模型对站点进行 one-hot 编码，树模型使用类别索引；常量特征排除。Logistic 与 SVM 使用特征标准化。通过九个 Logistic 模型比较日历与站点、加入本站历史、再加入邻站历史三组特征。

特征组比较设置。九个特征组比较模型使用 L2 正则参数 0.001，最多迭代 80 次，收敛容差为 10^{-6}。其中 0 个模型达到设定的迭代上限。正式模型比较中的 Logistic 与 SVM 最多迭代 100 次。

特征维度。完整输入包含 45 个数值特征和 27 个缺失标志，加上站点编码后，线性模型为 162 维，树模型为 73 维。

L2 Logistic 特征组	测试 PR-AUC：0 mm	5 mm	25 mm
日历与站点	0.11588	0.01671	0.00139
加本站历史	0.53158	0.15868	0.01482
再加邻站	0.56134	0.17982	0.01713

邻站信息的增量。相对于本站历史模型，加入邻站历史后三个目标的测试 PR-AUC 依次变化 +0.02975、+0.02114、+0.00231。结果与 Task 1 的空间相关性分析一致。

6. 模型、不平衡处理与概率校准

模型	参数
L2 Logistic（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
Linear SVM（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
XGBoost（Spark 接口）	80 棵树，深度 4，学习率 0.1，64 bins，最小子节点权重 20；$L_2 = 1$

训练策略。比较自然分布、类别加权和受约束 SMOTE 三种策略。令 N 为真实训练记录总数，P 为相应目标的正例数，类别权重为 $w_+ = N/(2P)$、$w_- = N/[2(N-P)]$。SMOTE 目标正例占比为 20%，正例总数最多为原始正例的 10 倍。每种策略均保留全部真实训练记录；合成观测仅添加到训练集。

SMOTE 构造。所有训练正例均可作为合成来源，按站点依次处理以控制内存。只在同站点、相同缺失模式、离散状态及雨量零值模式下检索最多五个近邻。对 16 个连续雨量特征用同一个系数插值，时间编码和其他离散信息保持原值；无合适近邻时复制原样本。

概率校准。利用 2023 年上半年观测拟合 Platt 函数 $\hat{p} = 1/[1 + \exp(-(az + b))]$，其中 z 为基础模型分数，约束 $a \geq 0$。该函数把 SVM 分数转换成概率，并调整类别加权或重采样后的概率尺度。若某组预测概率约为 10%，理想情况下该组实际正例比例也应接近 10%。

7. 评价方法与验证集选择

评价指标。ROC-AUC 评价正负例排序，随机排序的参考值为 0.5。PR-AUC 综合 Precision 与 Recall，适合正例较少的目标；随机排序的 Precision 参考水平约为正例比例 π。两种面积均由 Spark 精确积分计算。Brier score 为预测概率与标签的均方差，越小越好。

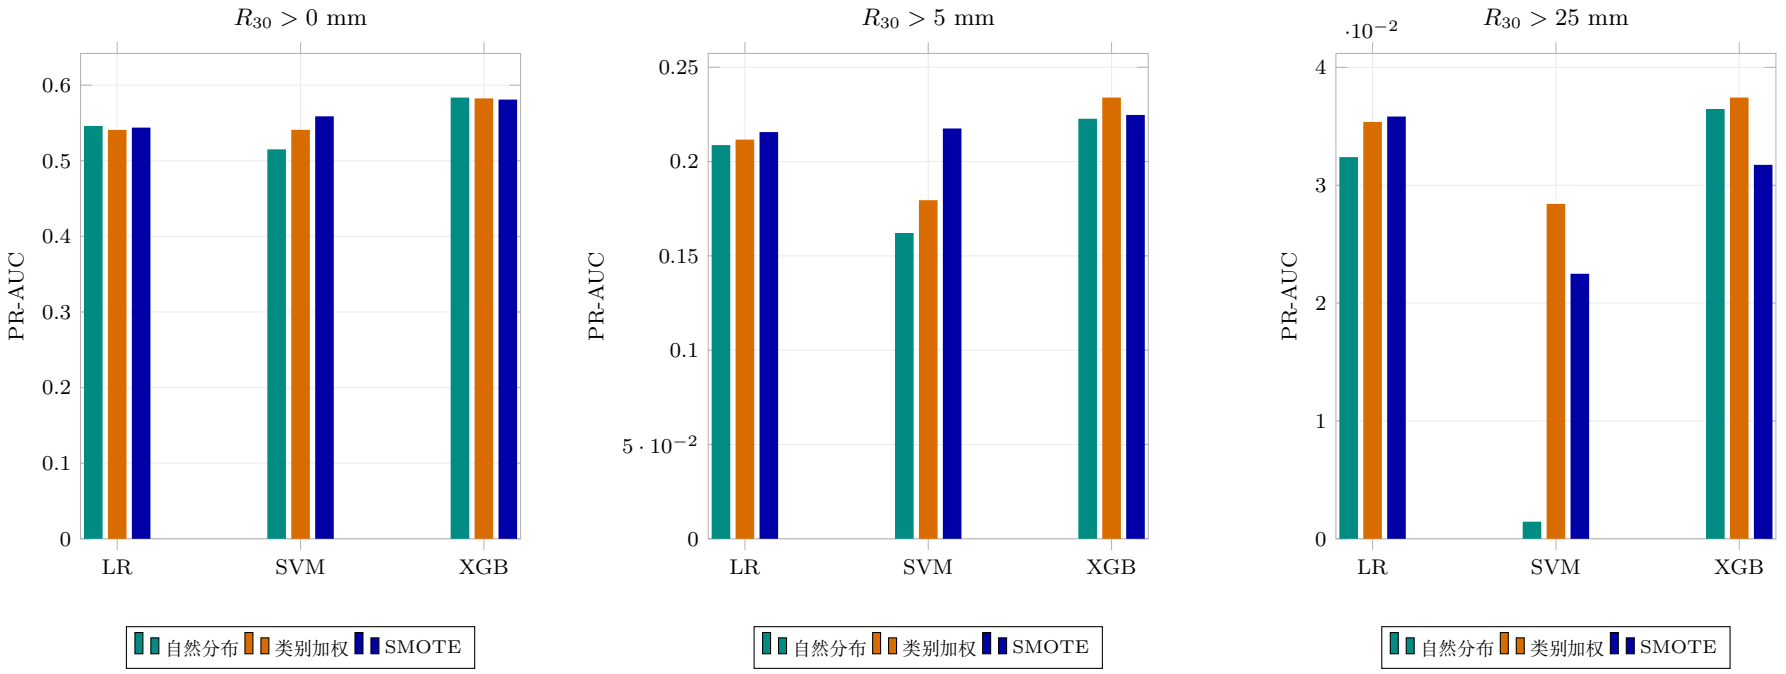
模型选择。在 2023 年下半年比较各算法和雨量阈值的训练策略，主要按 PR-AUC 选择，Brier score 作为并列时的依据。概率判别阈值在该验证集上按 F1 选择，用于计算测试 Precision、Recall、F1 和 Accuracy；它与定义标签的雨量阈值不同。测试结果不参与模型选择。

算法 / 策略	选择 PR-AUC：0 mm	5 mm	25 mm
Logistic / 自然分布	0.54605	0.20874	0.03239
Logistic / 类别加权	0.54088	0.21162	0.03537
Logistic / SMOTE	0.54389	0.21562	0.03583
SVM / 自然分布	0.51511	0.16211	0.00145
SVM / 类别加权	0.54095	0.17952	0.02842
SVM / SMOTE	0.55882	0.21753	0.02249
XGBoost / 自然分布	0.58363	0.22270	0.03647
XGBoost / 类别加权	0.58252	0.23392	0.03744
XGBoost / SMOTE	0.58096	0.22471	0.03173

迭代状态。正式比较中，Logistic 的九个模型有 0 个达到 100 次迭代上限，SVM 的九个模型有 9 个达到该上限。

选定模型。验证集选出的最终模型为 0 mm：自然分布 XGBoost；5 mm：类别加权 XGBoost；25 mm：类别加权 XGBoost。各算法在三个目标上的最优策略，共 9 个模型，均在完整测试集上评价。

图 7：训练策略的验证集比较



验证比较。相对于自然分布训练，类别加权在 9 个算法与目标组合中的 7 个组合提高 PR-AUC，SMOTE 在 6 个组合提高 PR-AUC。因此，不平衡处理的收益需要根据算法与预测目标分别评价。所有比较采用相同完整训练期与相同验证记录。

8. 2024 年测试结果

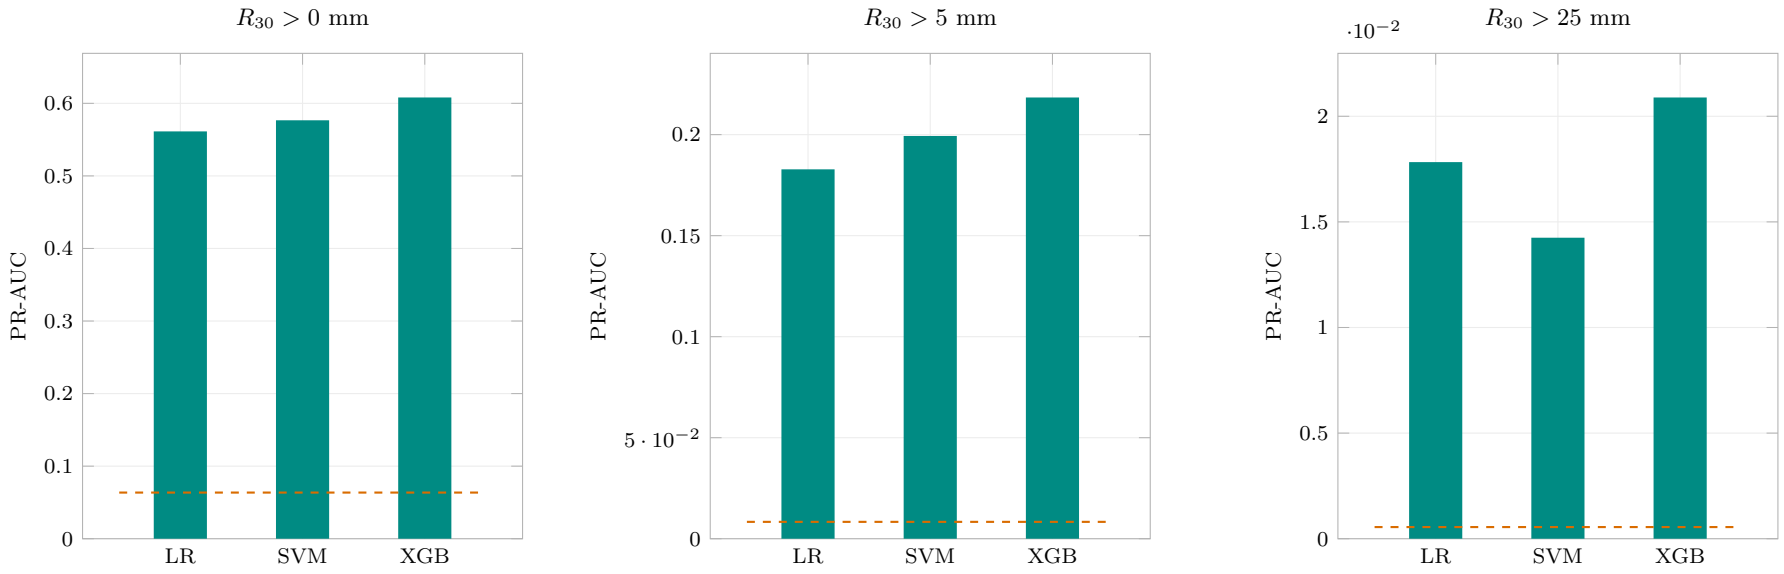
阈值 mm	算法	验证选定策略	ROC-AUC	PR-AUC	Brier
0	Logistic	自然分布	0.85625	0.56134	0.0392597
0	SVM	SMOTE	0.85451	0.57665	0.0401863
0	XGBoost	自然分布	0.87908	0.60809	0.0364909
5	Logistic	SMOTE	0.85293	0.18282	0.0075397
5	SVM	SMOTE	0.72667	0.19935	0.0077310
5	XGBoost	类别加权	0.87952	0.21839	0.0072009
25	Logistic	SMOTE	0.86018	0.01783	0.0005496
25	SVM	类别加权	0.85936	0.01425	0.0005487
25	XGBoost	类别加权	0.90435	0.02089	0.0005449

测试样本。每个目标均评价 6,374,476 个真实窗口，三个目标的正例比例为 6.3602%、0.83447% 和 0.055173%。所有概率指标基于校准后的预测。高雨量目标的正例较少，Accuracy 需结合 PR-AUC 和概率评价解释。

阈值 mm	最终模型	数据集	ROC-AUC	PR-AUC	Brier
0	XGBoost	训练	0.88029	0.61097	0.0341990
0	XGBoost	验证	0.87681	0.58363	0.0347079
0	XGBoost	测试	0.87908	0.60809	0.0364909
5	XGBoost	训练	0.88578	0.23066	0.0069161
5	XGBoost	验证	0.89447	0.23392	0.0070515
5	XGBoost	测试	0.87952	0.21839	0.0072009
25	XGBoost	训练	0.93661	0.03887	0.0005609
25	XGBoost	验证	0.90912	0.03744	0.0007191
25	XGBoost	测试	0.90435	0.02089	0.0005449

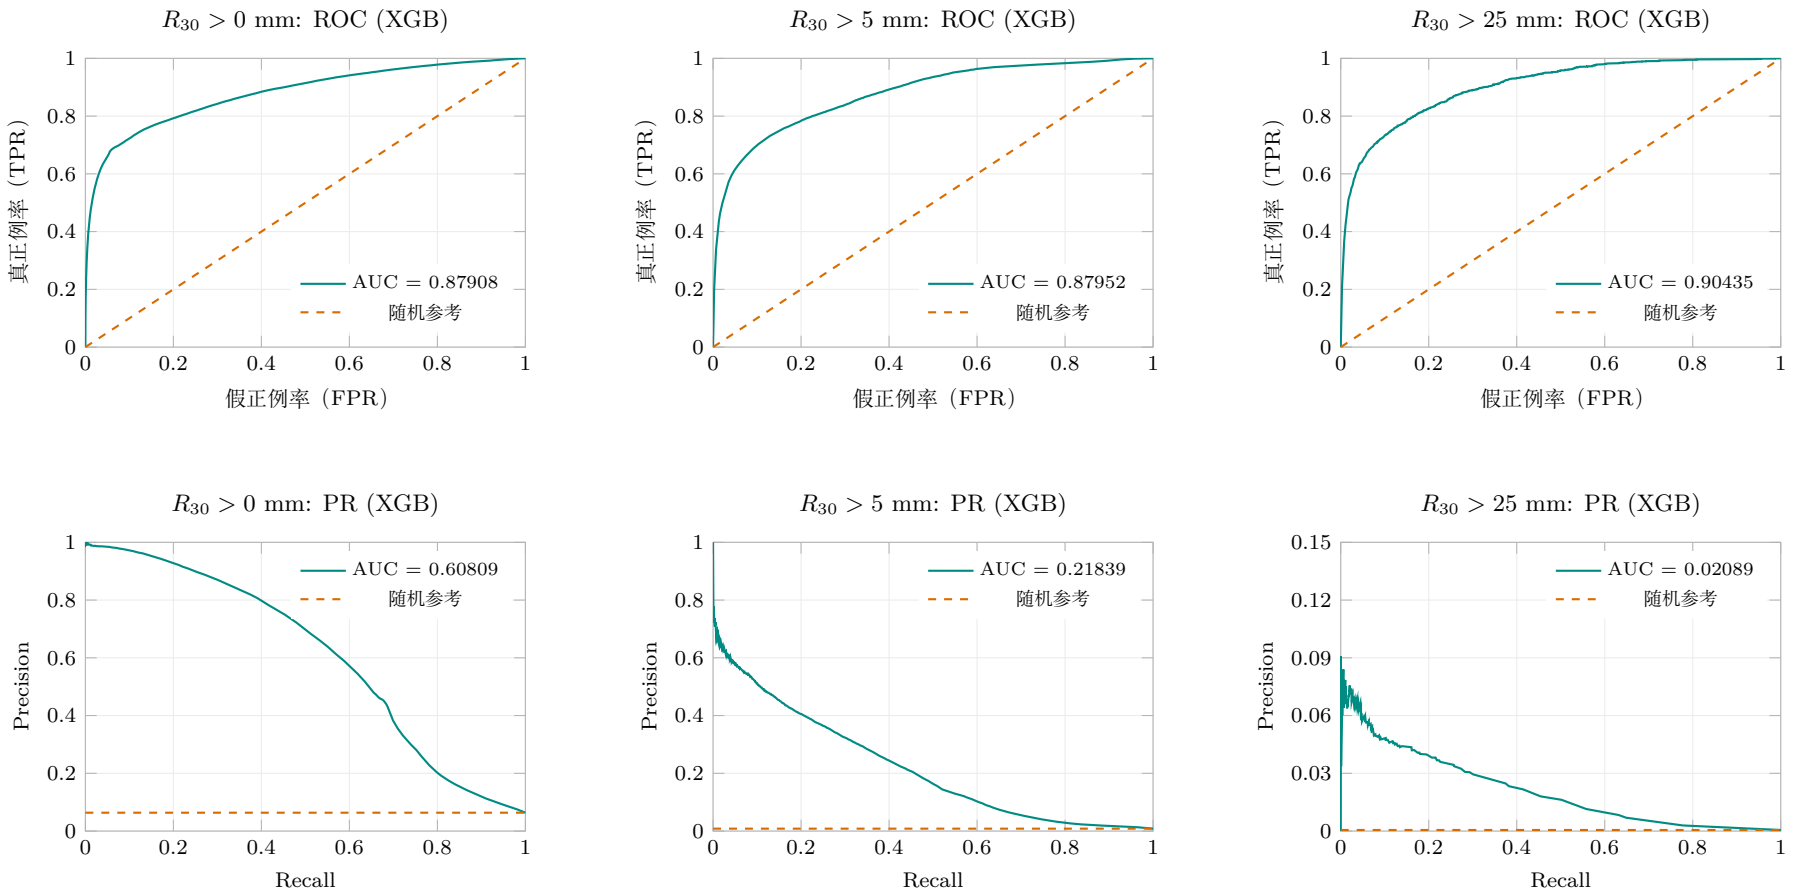
训练与测试比较。训练指标使用全部真实训练记录，不包含 SMOTE 合成观测；验证与测试也使用全部合格记录。各时期正例比例不同，PR-AUC 的跨时期差异同时受到模型泛化与事件发生频率影响。

图 8：测试集 PR-AUC 比较



测试比较。最终选定模型的测试 PR-AUC 分别为 0.60809、0.21839、0.02089，均高于对应的随机排序参考水平（橙色虚线）。25 mm 目标的 PR-AUC 仍较低，强降雨识别的 Precision 与 Recall 有较大提升空间。

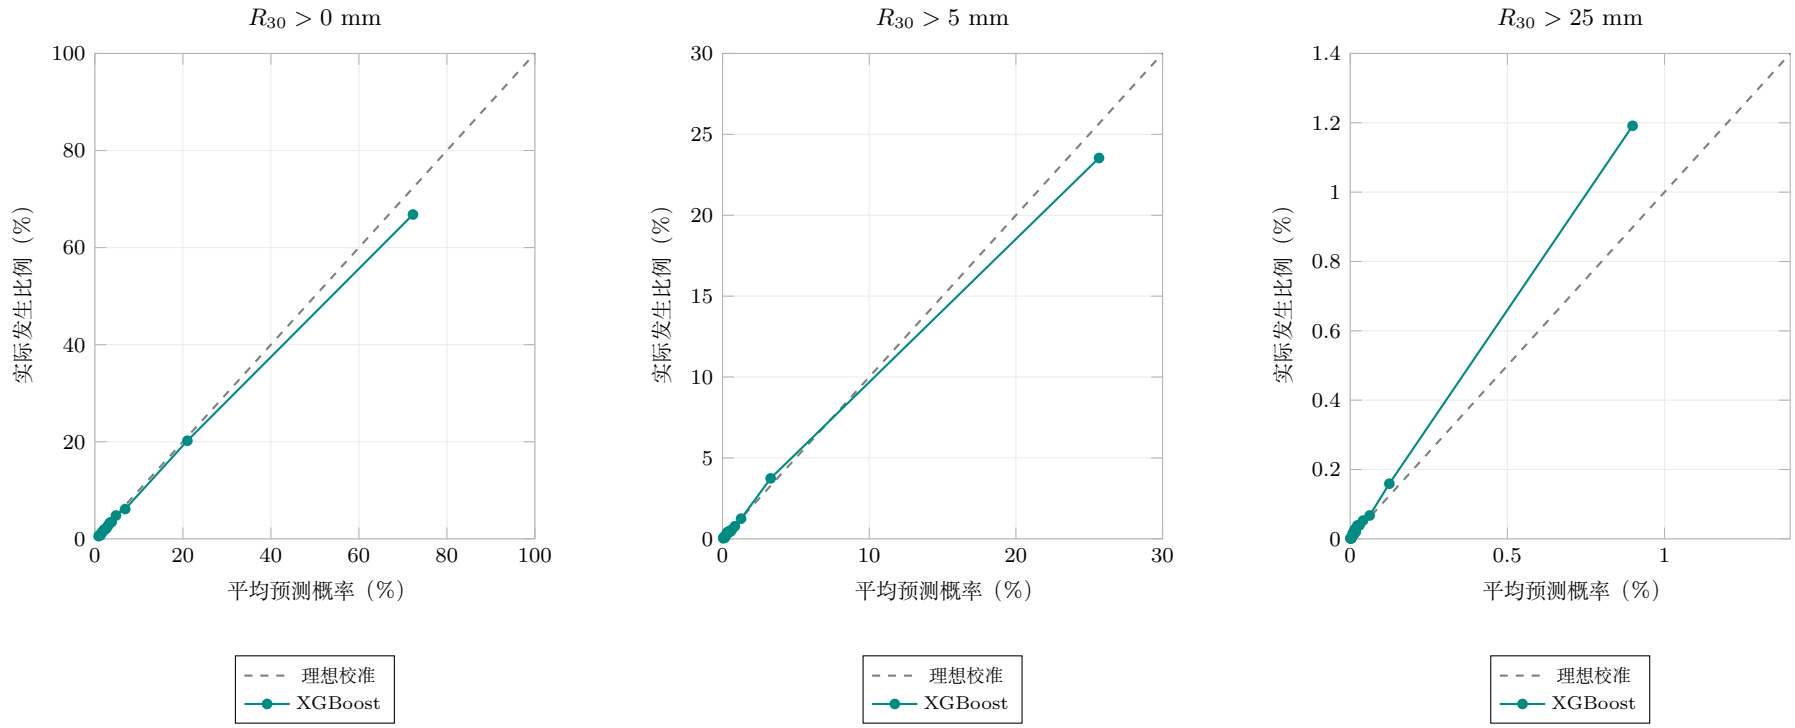
图 9：最终选定模型的 ROC 与 PR 曲线



评价对象。三列按 0、5、25 mm 雨量阈值排列，分别对应独立训练的分类器：0 mm：自然分布 XGBoost；5 mm：类别加权 XGBoost；25 mm：类别加权 XGBoost。这些模型由 2023 年下半年验证集选定。所有模型使用 2017–2022 年全部 34,542,285 条有效训练记录。曲线及 AUC 使用完整 2024 年测试集的 6,374,476 个窗口。ROC 图中虚线为 $y = x$，PR 图中虚线为测试集正例比例。25 mm 的 PR 面板将纵轴放大至 0–0.15，以展示低 Precision 区间。

排序表现。三个目标的 ROC-AUC 分别为 0.87908、0.87952、0.90435，PR-AUC 分别为 0.60809、0.21839、0.02089。较高雨量阈值对应的事件更稀少，需结合 PR 曲线评价模型能否同时取得较高 Precision 和 Recall。

图 10：校准曲线与概率质量



概率质量。三个目标的平均预测概率为 6.9640%、0.8596%、0.0422%，实际发生比例为 6.3602%、0.8345%、0.0552%。0 mm 与 5 mm 目标整体略高估风险，25 mm 目标整体低估风险。图中每个点汇总一组相近概率的预测，灰色虚线 $y = x$ 表示预测概率与实际比例一致。

校准效果。类别加权 XGBoost 在 5 mm 与 25 mm 目标中经校准后的 Brier score 明显降低，说明自然分布校准集有助于纠正加权训练造成的概率偏移。0 mm 目标的 Brier score 则由 0.0363148 变为 0.0364909，校准未改善该目标的测试概率误差。

稀有事件校准。25 mm 目标的最高平均预测概率组包含 164,015 个窗口，平均预测概率为 0.898%，实际超越比例为 1.191%。该组实际发生比例高于预测概率，表明较高风险窗口中的强降雨概率仍被低估。

9. 分类指标与补充分析

阈值 mm	模型	判别阈值	Precision	Recall	F1	Accuracy
0	XGBoost	0.3236	0.62066	0.56419	0.59108	0.95035
5	XGBoost	0.1758	0.29634	0.33540	0.31466	0.98781
25	XGBoost	0.0240	0.04208	0.16548	0.06709	0.99746

分类评价。表中判别阈值由验证集确定。高阈值事件中负例占比很大，因此高 Accuracy 不代表有效识别了强降雨；主要比较 ROC-AUC、PR-AUC，并以 Brier score 和校准曲线评价概率。

阈值 mm	真实正例	合成行数	增广正例（%）	雨量变化行数	孤立状态复制
0	2,074,430	6,042,534	20.000	3,615,180	263,540
5	279,801	2,518,209	7.550	1,292,705	291,565
25	19,787	178,083	0.570	67,189	54,652

空间与时间依赖。相邻站点可能受同一降雨过程影响，半小时窗口也存在重叠。后续可按日期或降雨事件分组评价，进一步比较模型在不同站点与事件中的稳定性。三个阈值独立训练，后续可研究跨阈值概率的单调约束。

10. 补充实验：5 mm 调参与最终预测入口

实验设计。候选模型使用全部 27,434,009 条有效 2017–2021 年记录，2022 年用于调参。预处理仅在对应训练期拟合，剔除跨越划分边界的目标窗口。比较六组固定配置，按 PR-AUC 选择，以 Brier 作为并列判据；无抽样或 early stopping。选定配置后，在全部 34,542,285 条有效 2017–2022 年记录上重训。2023 年上半年拟合单调 Platt 校准，下半年选择概率管线及判别阈值；随后固定模型评价 2024 年。**选定参数**。类别加权 XGBoost：200 棵树、深度 6、学习率 0.05、128 bins、最小子节点权重 20、L2 正则 5、L1 正则 0。2022 年 PR-AUC 从原参数配置的 0.24617 升至 0.25049。新流程对全部数值特征设置缺失标志，与原流程筛选缺失标志的方式略有不同，收益不能全部归因于调参。原第 8–9 节表格与曲线保留为原比较实验结果。

2024 测试指标	原比较实验 5 mm 模型	调参后的最终 5 mm 模型
PR-AUC	0.21839	0.22640
ROC-AUC	0.87952	0.87908
Brier score	0.0072009	0.0071609
Precision	0.29634	0.29402
Recall	0.33540	0.34657
F1	0.31466	0.31814

结果解释。测试集共 6,374,476 个有效窗口，53,193 个正例，正例比例为 0.83447%。PR-AUC 相对提高约 3.7%，Brier 略降，但 ROC-AUC 与 Precision 略降。分类指标使用各流程验证选定的判别阈值，并非固定误报率比较。新模型判别阈值为 0.169824，平均预测概率为 0.87725%；Brier 低于训练期正例率常数基线 0.0082751。未计算事件分块置信区间，不宣称统计显著提升。**计算环境**。本地 Mac 构造的特征上传至 Google Compute Engine e2-highmem-8：8 vCPU、64 GB 配置内存（系统约 62 GiB）、100 GB Balanced Persistent Disk、Ubuntu 22.04.5 LTS x86_64。Python 3.11、Java 17、Spark 3.5.8、XGBoost 3.2.0；单机 local[8]，两个 XGBoost worker，每任务 4 CPU，driver heap 6 GiB，不使用 GPU。本配置用于补充调参、重训、校准与测试，不改变原 Task 1 和原模型比较的执行环境记录。

10.1. 未采用的空间特征与应用限制

空间交互对照。固定上述参数，增加八个由已有历史特征派生的交互项：本站与邻站最新及半小时雨量差、邻站最大与平均雨量差、邻站有雨而本站干燥的比例、读数年龄差、本站最近 15 分钟占半小时雨量比例及邻站雨量对数。缺失输入保持缺失，不使用未来观测；这些变量不代表风向或风暴速度。

验证指标	调参模型	加空间交互特征
2022 PR-AUC	0.250486	0.250632
2023 下半年 PR-AUC	0.239991	0.238817
2023 下半年 Brier	0.00701053	0.00701540

选择结论。较新的验证期排序和概率误差均未改善，因此不采用空间特征扩展，也不根据 2024 年成绩选择该扩展。保留调参模型作为 5 mm 预测模型。2024 年此前已被原实验查看过；本次参数选择未读取它，但它不是研究者完全未见的封存集。**预测入口**。输入站点、五分钟网格上的预测时间及 0、5、25 mm 阈值，输出超越概率。5 mm 默认加载调参校准管线；0 与 25 mm 沿用原验证选定模型。可显式选择原模型作对照。预测仍需要已准备的历史特征行，不是实时服务，且其历史样本范围依赖完整未来标签。三个独立目标尚无跨阈值单调保证；未知站点编码的处理不能证明新站点预测精度。**AI 使用补充**。Codex 辅助补充实验脚本、云端部署、文件检查及双语报告整理。结果来自实际完整数据运行；空间对照结果来自云端验证输出。小组成员负责审核，人工小数据仅用于实现检查。

11. AI 使用声明与参考文献

AI 使用声明。本项目使用 OpenAI Codex 辅助研究设计、数据处理和模型代码编写、结果核对与报告文字整理。报告中的降雨统计与模型评价结果均来自实际数据处理和模型运行；SMOTE 合成样本仅用于训练。

资料来源。

1. NEA，Historical Rainfall across Singapore，2017–2024 年度数据集。
2. Meteorological Service Singapore，Climate of Singapore。
3. NEA，2019 年气候回顾。用于偏干年份与正位相印度洋偶极子的外部背景，未用作模型预测特征。
4. geoBoundaries，Singapore ADM0；轮廓源自 URA 2016 年资料，ODbL 1.0。
5. Apache Spark 3.5.8，MLlib 分类与回归文档，用于 Logistic 与 Linear SVM 实现；评价采用 Spark BinaryClassificationEvaluator。
6. XGBoost，PySpark Estimator 文档，用于外部 Spark XGBoost 集成；实际安装版本为 3.2.0。
7. scikit-learn，Precision–Recall 文档与概率校准文档。