新加坡历史降雨：时空规律与概率预测

Task 1 与 2：2017–2024 年 Spark 探索与概率预测

小组成员。潘禹翔（A0355687J）、侯佳成（A0353127J）、吴嘉蕊（A0262371J）。

研究内容。本项目利用 2017–2024 年的新加坡降雨观测数据分析时间与空间变化规律，并建立模型，预测监测站在未来 30 分钟内累计雨量超过给定阈值的概率。

数据与方法。使用 NEA / data.gov.sg 的八个年度数据集，源记录共 48,538,713 条，去重后 48,538,627 条，涉及 91 个站点 ID。全量清洗和聚合由 Spark 执行；跨年比较采用 21 个稳定站点，避免监测网络变化混入年度差异。

主要结果。全部有效五分钟区间中 97.08% 无雨。合格日内样本的雨频高峰为新加坡时间 16:00–17:00。月度可用样本平均雨频以 11 月最高、7 月最低，但各月的可用年份及站点组成不完全相同。固定站点样本中，按观测时长归一化的雨量以 2019 年最低、2021 年最高。近距离站点的日雨量相关性总体高于远距离站点；八年不能据此推断长期气候变化。

预测结果。原算法比较采用 Spark MLlib Logistic、Linear SVM 及外部 Spark XGBoost 集成。最终三个 XGBoost 模型分别在 16 组完整参数网格上调参；2017–2021 年训练、2022 年选参数，再用全部 2017–2022 年重训。2023 年上半年校准，下半年选择概率管线和判别阈值。2024 年最终测试 PR-AUC 为 0.61218、0.22511、0.02118。0 mm 保留未校准概率，5 与 25 mm 使用校准概率。

年份	雨量 / 观测 24h（mm）	雨频（%）	湿区间雨强（mm/5min）	平均覆盖率（%）
2017	6.85	2.85	0.833	94.6
2018	7.10	2.90	0.840	82.9
2019	4.81	1.97	0.841	94.7
2020	7.40	2.92	0.877	95.3
2021	7.84	3.04	0.895	97.8
2022	7.71	3.08	0.868	99.0
2023	7.52	3.16	0.824	95.2
2024	7.11	3.01	0.819	95.6

表中各年均使用相同的 21 个站点，站点等权。雨量指标按观测时长归一化，不能解释为官方年度累计或真实日累计。月度图和日内图的合格样本组成仍可变化。

1. 数据来源、字段与清洗

来源与字段。每条记录包含 observation timestamp、update timestamp、station ID/name/device ID、经纬度、reading update timestamp、reading value、reading type、reading unit 及日期字段。本数据只有降雨相关观测，不包含气温、湿度和风等变量。API 预览只用于确认字段和年度 ID；所有天气结论来自完整文件。

数据核对。下载完整年度 CSV 后，将 Spark 读入的记录数与年度 API 元数据的记录数核对，并检查重复观测、时间对齐和雨量取值。

清洗步骤。Spark 按 Asia/Singapore 解析时间；保留有限、非负、单位为 mm、类型为预期五分钟累计、站点 ID 和时间合法且 CSV 记录有效的行。只有与五分钟网格的距离不超过两秒时才对齐，原始 epoch 同时保留；其他离网格记录排除并审计。按 station ID 与对齐时刻去重，优先保留 reading update 最新的行，再使用原始观测时刻及确定的字段顺序打破并列。年度文件合并后再次检查跨文件重复。

年份	源记录数	删除重复数	偏离网格超过 2 秒	负雨量数	站点数
2017	5,256,106	86	0	0	62
2018	4,594,246	0	0	0	56
2019	5,026,862	0	0	0	54
2020	6,334,473	0	0	0	80
2021	7,044,646	0	0	0	76
2022	7,133,230	0	0	0	72
2023	6,742,890	0	0	0	74
2024	6,406,260	0	0	0	70

清洗结果。86 条重复记录全部来自 2017 年；八年数据中未发现负雨量、偏离五分钟网格超过两秒的时间戳或跨文件重复。缺失时段不计为零雨量。对超过 50 mm/5min 的读数进行额外筛查，本次没有触发该条件的记录。

2. 指标定义与公平比较

设站点在给定时间段内的有效观测数为 N，雨量为 $r_i \geq 0$，有雨区间数为 $W = \sum_i \mathbf{1}(r_i > 0)$，预期日历槽数为 E。本文使用：

$$\begin{aligned} \text{覆盖率} &= N/E, \qquad E = 288 \times \text{日历天数}, \\ \text{雨频（\%）} &= 100W/N, \\ \text{湿区间雨强（mm/5min）} &= \sum_i r_i/W \quad (W > 0), \\ \text{雨量 / 观测 24h（mm）} &= 288 \sum_i r_i/N. \end{aligned}$$

预期日历槽数显式处理闰年；低覆盖率也可能反映站点只运行了部分年份。雨强的分母仅包含有雨区间。对于单个站点和同一时间段，归一化雨量等于 288 × 雨频/100 × 湿区间雨强。分别取站点平均后，该乘积恒等式一般不再成立。归一化雨量不是官方日累计或年度累计，也不能恢复遗漏风暴。

年度固定样本。八年共出现 91 个站点 ID，其中 21 个同时满足：八年均有观测、每年覆盖率至少 80%、经纬度跨度各不超过 0.005°。其余 70 个只是不进入固定站点的跨年比较，清洗时没有删除这些站点的有效观测。21 个站点等权平均；不同分析使用的站点范围见下一页。

月度与日内样本。图 2、4 从这 21 个站点中进一步筛选数据完整的年月或小时组合。月度先对站点等权平均，再对可用年份等权平均；每个合格年月有 17–21 个站点，各月有 6–8 个可用年份。严格要求同站点同月份在八年均达标时，只剩 5、6、7、9、10、12 月，作为额外对照。

空间比较。图 1 使用 2024 年的站点，当年共 70 个，其中 56 个覆盖率至少 90%，用于地图着色，另 14 个以灰色标记。图 5 使用固定 21 站的日累计，要求日覆盖率至少 95%，每对至少有 365 个共同有效日期。80%、90%、95% 是本项目选定的数据完整程度门槛。

3. 计算环境与各项分析的样本范围

计算环境。Task 1 使用 Apple Silicon Mac：10 个逻辑 CPU、16 GiB RAM，macOS 26.5.2 ARM64，Python 3.12.14、Java Temurin 17.0.20.1+1、Spark 3.5.8。Task 2 在 gpushare 运行，环境为 Python 3.11.10、Azul Zulu Java 17.0.20.1、Spark 3.5.8、XGBoost 3.2.0。gpushare 容器配额为 42 CPU、约 667.68 GiB RAM；完整特征的模型训练限定使用 20 个 CPU，默认 driver heap 为 6 GiB。

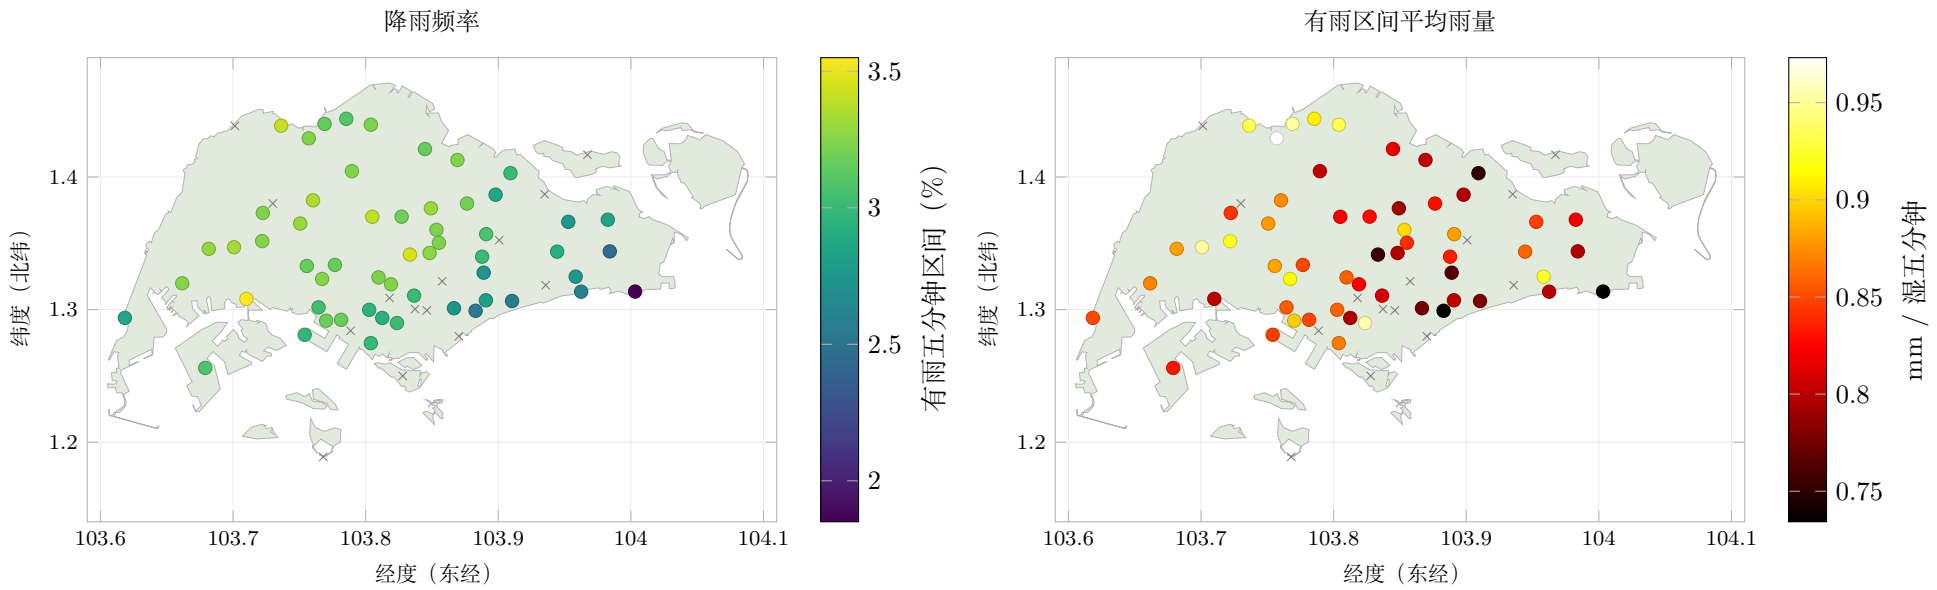
Spark 配置与分工。Task 1 与初始特征组比较采用单机双线程模式 `local[2]`。完整特征的模型比较与评价采用 `local[20]`，shuffle partitions 为 80，default parallelism 为 20。XGBoost 使用两个工作进程，每个任务配置 10 个 CPU。不使用 GPU，以低优先级串行执行各项实验。Spark DataFrame/SQL 与窗口函数用于全量清洗、时间聚合、标签和特征构造；模型训练与评价使用 Spark ML 管线。一般阶段 Java 堆为 6 GiB，进程总内存停止上限为 12 GiB；XGBoost 训练和评价的总内存上限为 40 GiB。

分析样本。各项分析根据比较目的采用相应的站点范围与数据完整性筛选条件，具体见下表。

分析	使用范围	筛选说明
图 1：2024 站点地图	当年 70 站中的 56 站	年覆盖率至少 90%；另 14 站灰色标记
图 2：月度变化	固定 21 站的合格子集	每个合格年月保留 17–21 站
图 3：年度变化	同一组 21 站	其余 70 站不参与固定站点跨年比较
图 4：日内变化	固定 21 站的合格组合	年月小时组合覆盖率至少 80%
图 5：距离与日雨量相关性	固定 21 站，210 对	日覆盖率至少 95%，共同有效日至少 365
图 6 左：有雨时的雨量分布	八年全部 91 站	仅统计有雨五分钟区间
图 6 中、右：半小时超阈值与持续性	2024 年全部 70 站的有效观测	六个未来槽完整，或两个五分钟槽连续

清洗核对。源记录数与 API 计数一致；删除 86 条重复记录，缺失时段不补成零。全部观测的无雨比例也使用全部 91 站，而不是仅使用 21 站。

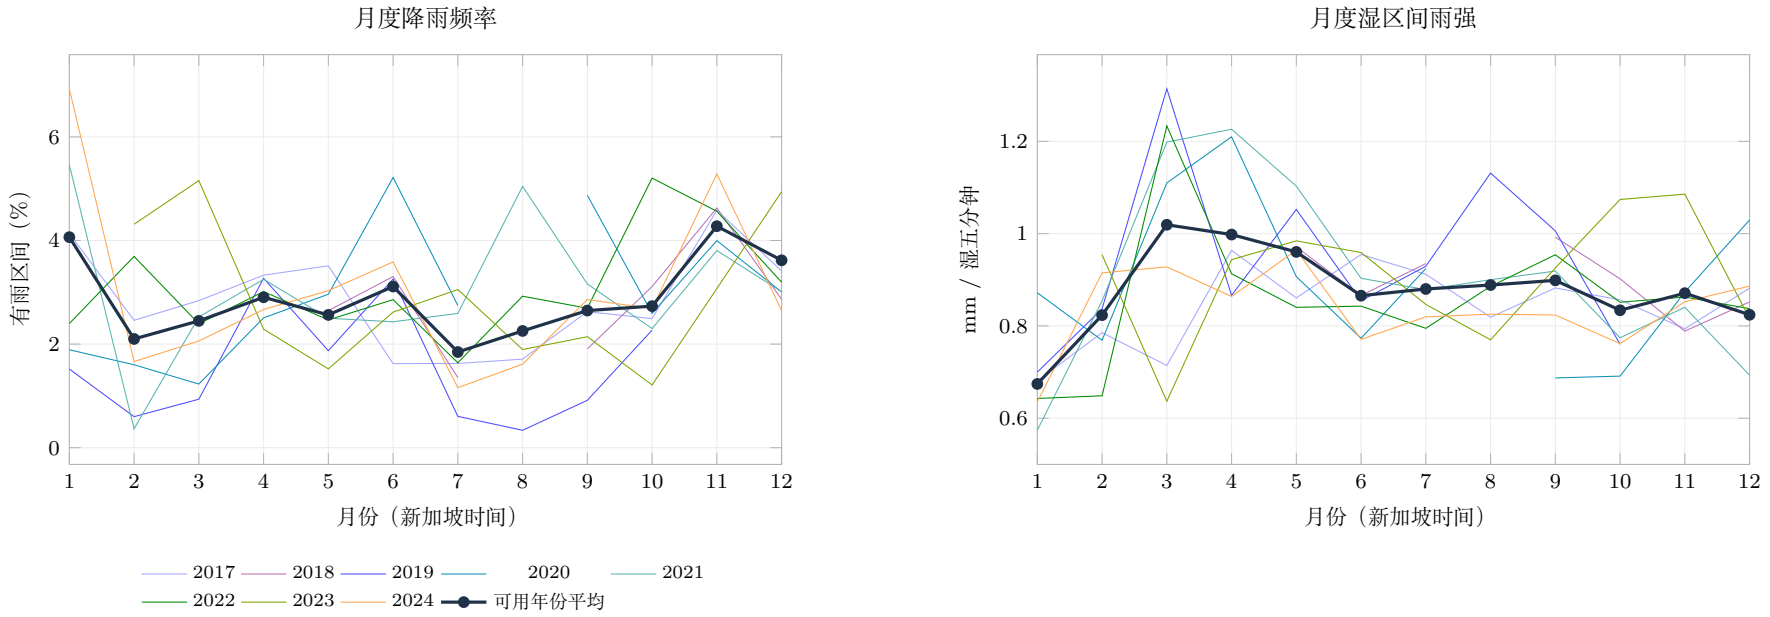
图 1：2024 年观测站降雨地图



2024 年有 70 个站点，其中 56 个年度覆盖率不低于 90%。彩色点只表示该观测站的统计量；灰色叉为低覆盖率站点。S33（Jurong Pier Road）的雨频最高，为 3.55%。地图不进行空间插值，也不代表岛上每个位置的降雨量。边界采用 geoBoundaries 中源自 URA 的 2016 年陆地轮廓（ODbL 1.0），仅作地理参照。

Task 2 特征启示（站点）。候选特征包括站点 ID 和经纬度，以表示站点间差异。Task 2 不直接沿用跨年比较的 21 站限制，而按历史特征及未来标签的完整程度筛选训练窗口。

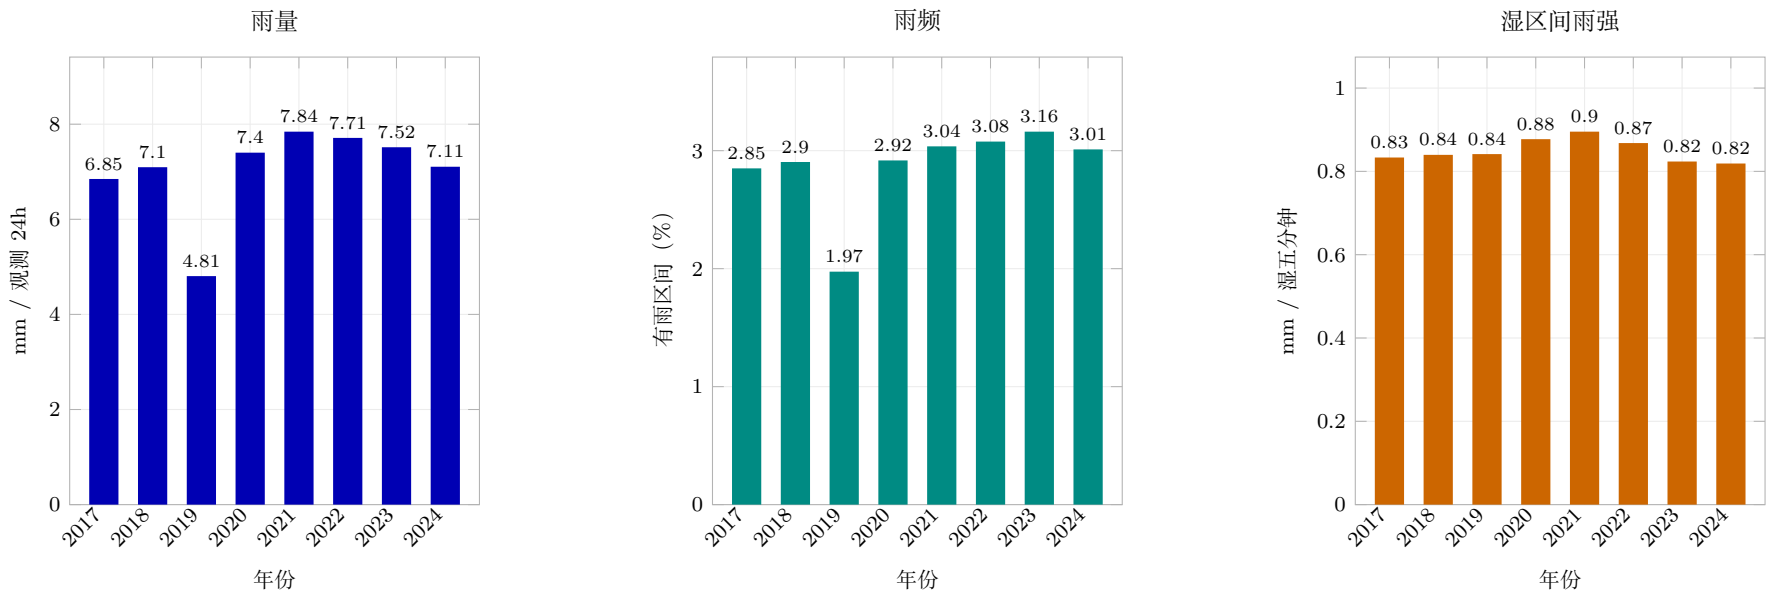
图 2：一年内的月度规律



固定站点样本中，合格站点年月的覆盖率至少为 80%，先对站点等权平均，再对可用年份等权平均。月度平均雨频以 11 月最高（4.28%）、7 月最低（1.85%）；有雨区间平均雨量以 3 月约 1.02 mm、1 月约 0.67 mm。雨频与有雨区间雨量呈现不同的季节变化。各月包含 6–8 个年份，每个合格年月包含 17–21 个站点。

Task 2 特征构造（月份）。月度雨频与雨强的变化模式不同，因而使用月份的正弦、余弦编码表示年内周期，并与小时编码组合，刻画季节与日内降雨规律的共同作用。

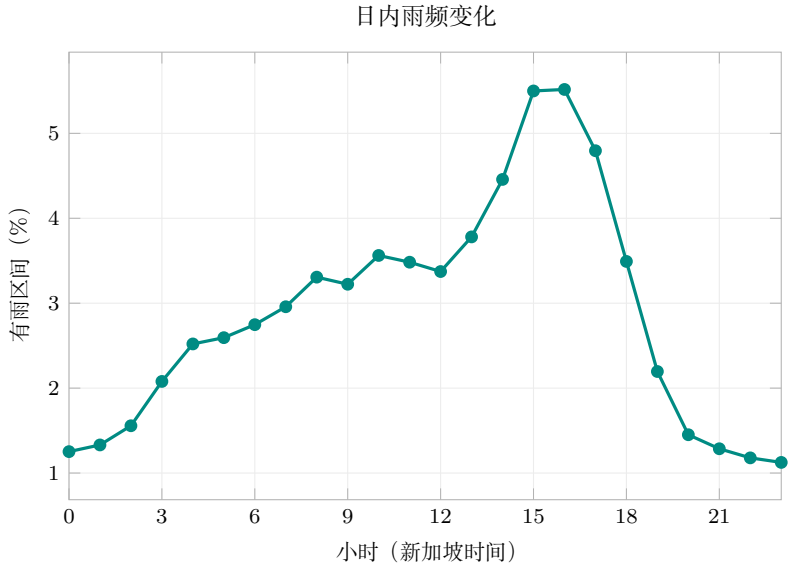
图 3：固定站点的年度变化

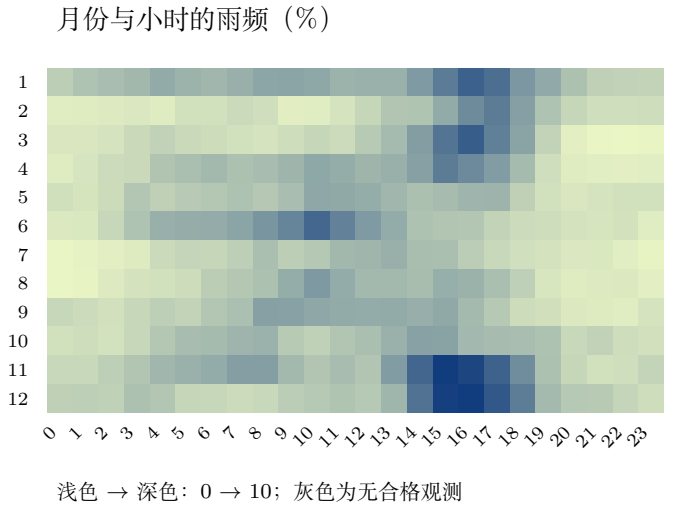


各年采用相同的 21 个站点进行等权比较，每个站点的年度覆盖率至少为 80%。平均雨量 / 观测 24h 从 2019 年的 4.81 mm 到 2021 年的 7.84 mm。2019 年的雨频为 1.97%，明显低于其余年份，而有雨区间雨量为 0.841 mm，与相邻年份接近，表明该年偏低的归一化雨量主要对应较低的降雨频率。

Task 2 特征构造（年份）。训练、验证和测试按年份划分。模型使用月份与小时的周期特征，不加入年份编号。NEA 的 2019 年气候回顾将当年偏干与强正位相印度洋偶极子联系起来，为年际变化提供外部背景。

图 4：降雨频率的日内变化

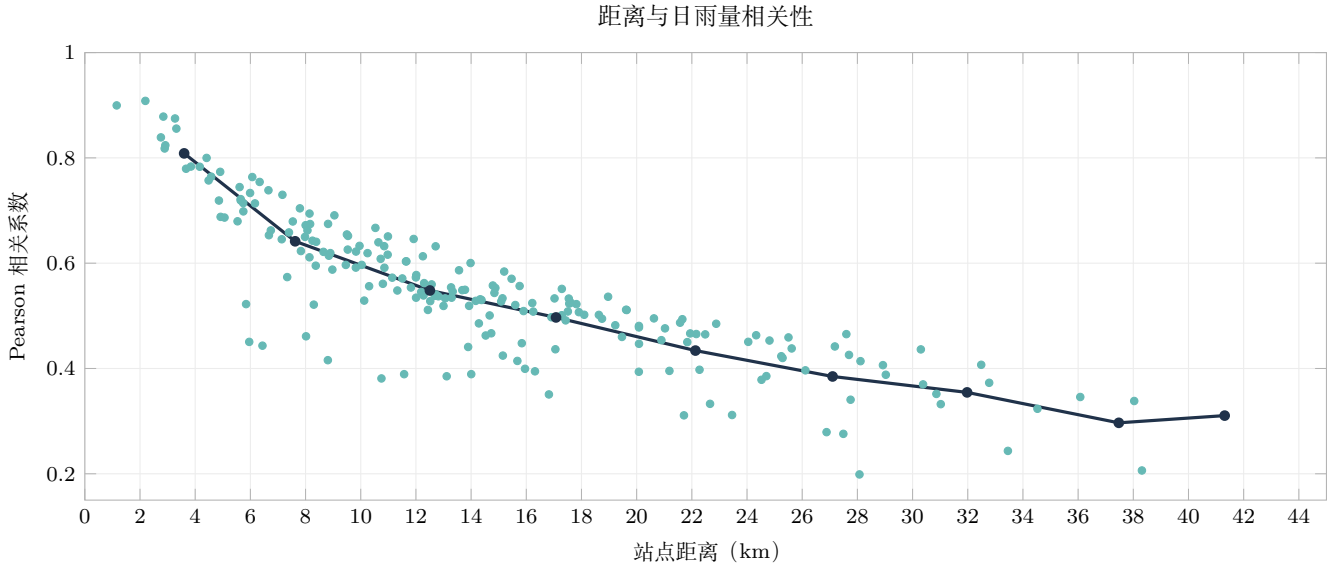




降雨频率在 16:00–17:00 达到日内高峰，且高峰时段与强度随月份变化。11–12 月的下午高峰较明显，6 月的较高雨频更接近上午至中午。统计对覆盖率至少 80% 的站点、年份、月份、小时组合等权平均。该结果支持同时使用小时、月份与二者交互项作为预测特征。

Task 2 特征启示（小时与月份）。使用新加坡当地小时的周期编码，并考虑月份与小时的交互项：下午雨频高峰的强弱和时刻会随月份变化。Logistic 和线性 SVM 需显式构造交互特征；树模型可学习这类组合关系，其实际贡献仍由对照实验检验。

图 5：站点距离与日雨量的相关性

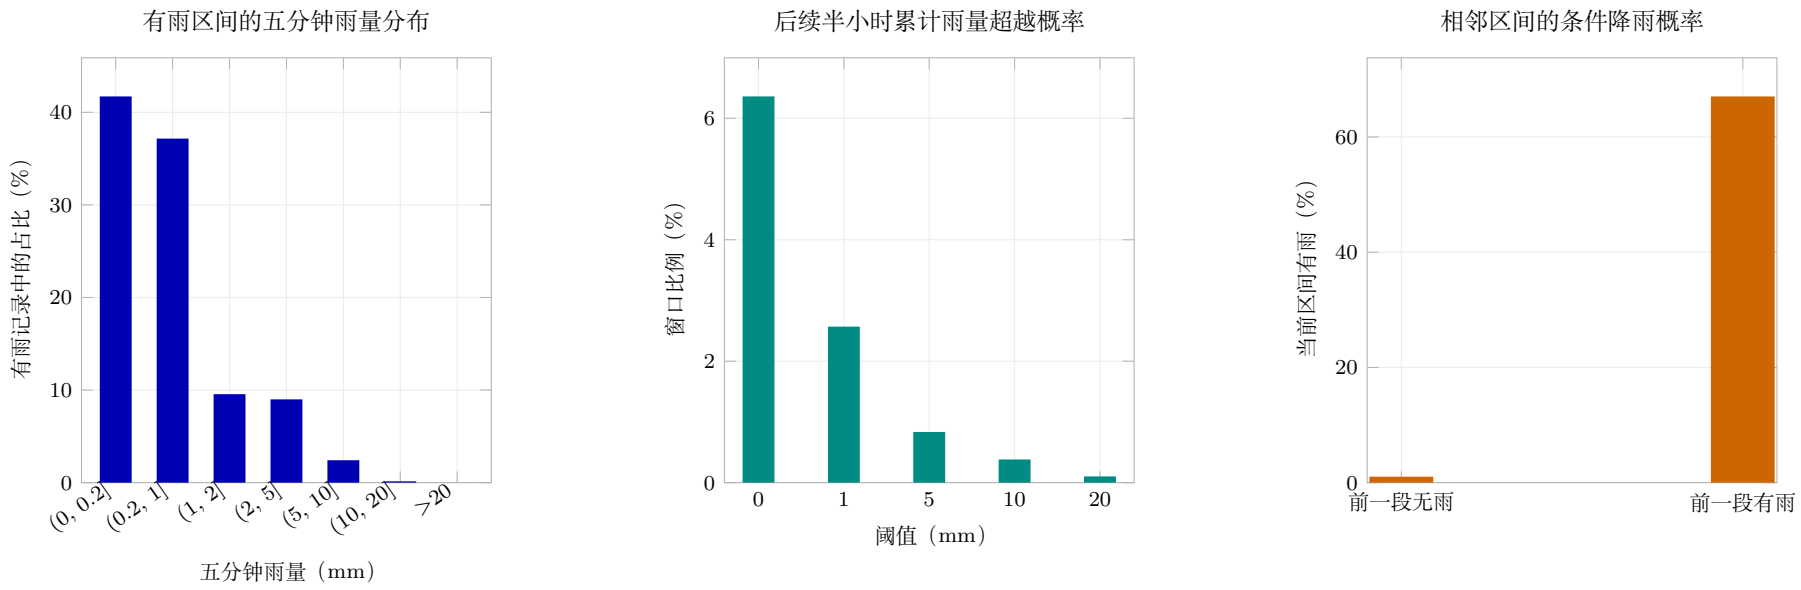


21 个站点形成 210 对站点组合。距离不超过 5 km 的 17 对站点，日雨量平均 Pearson 相关系数为 0.809；距离超过 30 km 的 12 对为 0.336。每 5 km 距离组的平均相关性总体随距离增加而降低，表明降雨具有空间相关性。

站点并非独立。附近站点可能同时经历同一场降雨；不同站点对还可能共享同一个站点。因此，91 个站点不能视为 91 份完全独立的天气样本，210 对相关系数也不是 210 个独立样本。共同有效日的筛选与前文相同。

Task 2 特征构造（邻站）。邻近站点的日雨量呈现较强相关性，因此加入三个最近邻站的历史雨量均值、最大值和有雨比例。Task 2 通过加入邻站特征前后的模型比较，评价其对半小时预测的贡献。

图 6：雨量分布、半小时超越概率与降雨持续性



有雨区间的雨量分布。八年全部站点的有雨五分钟观测中，41.72% 的雨量位于 $(0, 0.2]$ mm，37.16% 位于 $(0.2, 1]$ mm。合计 78.88% 的有雨区间雨量不超过 1 mm，表明多数降雨区间的累计雨量较小。全部有效五分钟观测中的无雨比例为 97.08%。

半小时累计雨量的超越概率。2024 年共有 6,374,476 个完整后续六区间窗口。后续 30 分钟累计雨量严格超过 0 mm 和 5 mm 的窗口比例分别为 6.36% 和 0.83%，超越概率随雨量阈值升高而降低。累计雨量按九位小数比较，以避免阈值边界的浮点误差。图中横轴按阈值类别排列。

相邻区间的降雨持续性。2024 年同站点连续五分钟观测显示，前一区间无雨时，后一区间有雨的条件概率为 1.04%；前一区间有雨时，该概率为 67.03%。降雨具有明显的短时持续性，支持在预测模型中纳入近期雨量及连续有雨时长。

Task 2 特征启示（持续性与稀有事件）。实际特征包括最近读数、过去 15/30/60 分钟累计、近期雨势变化和连续有雨时长。只使用预测时已可获得的记录，缺测不补为无雨。下文逐阈值给出正例数、PR-AUC、Brier score 和校准曲线。

4. Task 2：预测目标与时间切分

预测目标。对于站点 s、时刻 t 和雨量阈值 q，估计未来 30 分钟累计雨量严格超过 q 的概率。设置 $q \in \{0, 5, 25\}$ mm，每个目标分别训练分类器；同一站点时刻保留一份特征与三个标签列。

阈值选择。本项目预设 0、5 和 25 mm 三个雨量阈值，分别考察未来半小时是否出现降雨、是否超过较低的正雨量门槛，以及是否发生较大累计雨量事件。选择不同门槛旨在比较事件发生频率降低时，模型的排序能力和概率质量如何变化。这些阈值是本项目的实验设置，并非官方降雨等级。每个阈值分别训练和选择分类器，当前预测接口仅支持这三个值，不支持任意连续雨量阈值。

$$R^{30}_{s,t} = \sum_{k=1}^{6} r_{s,t+5k\,\min}, \qquad y^{(q)}_{s,t} = \mathbf{1}(R^{30}_{s,t} > q), \qquad \hat{p}_q = P(y^{(q)} = 1 \mid x_{s,t}).$$

标签构造。将时间戳作为五分钟区间的终点，累计 $(t, t + 30\text{min}]$ 内六个有效区间的雨量，保留九位小数后与阈值比较。当前区间不计入目标；任一未来区间缺测时不构造标签。累计雨量等于阈值时标签为 0。

用途	有效行数	> 0 正例	> 5 正例	> 25 正例
2017–2022：全部训练记录	34,542,285	2,074,430	279,801	19,787
2023 上半年：概率校准	3,325,499	251,794	30,699	1,532
2023 下半年：模型选择	3,393,373	197,358	28,000	2,487
2024：测试	6,374,476	405,430	53,193	3,517

训练与验证。原算法比较与最终重训均使用全部 34,542,285 条有效 2017–2022 年记录。网格候选模型及其预处理使用全部 27,434,009 条有效 2017–2021 年记录，以 2022 年选择参数。2023 年上半年拟合概率校准，下半年选择概率管线和判别阈值；2024 年评价固定后的模型。标签窗口不得跨划分边界，校准、验证和测试保留自然类别分布。

5. 从 Task 1 到特征工程

Task 1 依据	构造方式	实际输入
下午高峰随月份变化	小时、月份周期编码与交互	8 个日历特征；不加入年份 ID
站点差异与空间相关	站点 ID、经纬度、三个最近邻站	邻站雨量均值、最大值、有雨比例
短时降雨持续性	最新读数及 5/10/15/30/60 分钟滞后	15/30/60 分钟累计、变化和雨段长度

历史与邻站特征。只使用预测时已可获得的观测，观测时刻和保留的更新时间均不晚于 t。从过去 90 分钟检索历史；最近读数超过 30 分钟时标记不可用。邻站由当时已知坐标确定，聚合三个最近合格邻站的雨量、有效观测数、读数年龄及距离。Spark 窗口函数和连接处理全量记录。

时间编码。令 h 为当地小时（包含分钟的小数部分），m 为月份。小时和月份使用下列周期编码，并将两组编码的四个乘积作为交互项，共形成八个特征。这样 23:00 与 00:00、12 月与 1 月在特征空间中保持接近。

$$h_{\sin} = \sin(2\pi h/24), \quad h_{\cos} = \cos(2\pi h/24), \qquad m_{\sin} = \sin[2\pi(m-1)/12], \quad m_{\cos} = \cos[2\pi(m-1)/12].$$

输入处理。缺失值采用训练期均值填补；缺失标志的筛选和站点类别词表也仅使用完整训练期。线性模型对站点进行 one-hot 编码，树模型使用类别索引；常量特征排除。Logistic 与 SVM 使用特征标准化。通过九个 Logistic 模型比较日历与站点、加入本站历史、再加入邻站历史三组特征。

特征组比较设置。九个特征组比较模型使用 L2 正则参数 0.001，最多迭代 80 次，收敛容差为 10^{-6}。其中 0 个模型达到设定的迭代上限。正式模型比较中的 Logistic 与 SVM 最多迭代 100 次。

特征维度。原比较模型使用 45 个数值特征、27 个筛选后的缺失标志及站点编码：线性模型为 162 维，树模型为 73 维。最终网格模型对全部 46 个候选数值变量设置缺失标志，排除常量数值变量后使用 45 个数值特征和一个站点类别索引，共 92 维。所有填补和编码参数仅在对应训练期拟合，因此与原比较的差异不能全部归因于调参。

L2 Logistic 特征组	测试 PR-AUC：0 mm	5 mm	25 mm
日历与站点	0.11588	0.01671	0.00139
加本站历史	0.53158	0.15868	0.01482
再加邻站	0.56134	0.17982	0.01713

邻站信息的增量。相对于本站历史模型，加入邻站历史后三个目标的测试 PR-AUC 依次变化 +0.02975、+0.02114、+0.00231。结果与 Task 1 的空间相关性分析一致。

6. 模型、不平衡处理与概率校准

算法比较设置。本节固定参数表与三种训练策略对应原 27 次算法比较，不是最终网格模型。Logistic 与 Linear SVM 使用 Spark MLlib；XGBoost 使用外部 Spark 接口。原比较的结果保留为基线，最终 XGBoost 参数在第 7.1 节给出。

模型	参数
L2 Logistic（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
Linear SVM（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
XGBoost（Spark 接口）	80 棵树，深度 4，学习率 0.1，64 bins，最小子节点权重 20；$L_2 = 1$

训练策略。比较自然分布、类别加权和受约束 SMOTE 三种策略。令 N 为真实训练记录总数，P 为相应目标的正例数，类别权重为 $w_+ = N/(2P)$、$w_- = N/[2(N-P)]$。SMOTE 目标正例占比为 20%，正例总数最多为原始正例的 10 倍。每种策略均保留全部真实训练记录；合成观测仅添加到训练集。

SMOTE 构造。所有训练正例均可作为合成来源，按站点依次处理以控制内存。只在同站点、相同缺失模式、离散状态及雨量零值模式下检索最多五个近邻。对 16 个连续雨量特征用同一个系数插值，时间编码和其他离散信息保持原值；无合适近邻时复制原样本。

概率校准。利用 2023 年上半年观测拟合 Platt 函数 $\hat{p} = 1/[1 + \exp(-(az + b))]$，其中 z 为基础模型分数，约束 $a \geq 0$。该函数把 SVM 分数转换成概率，并调整类别加权或重采样后的概率尺度。若某组预测概率约为 10%，理想情况下该组实际正例比例也应接近 10%。

7. 评价方法与验证集选择

评价指标。ROC-AUC 评价正负例排序，随机排序的参考值为 0.5。PR-AUC 综合 Precision 与 Recall，适合正例较少的目标；随机排序的 Precision 参考水平约为正例比例 π。两种面积均由 Spark 精确积分计算。Brier score 为预测概率与标签的均方差，越小越好。

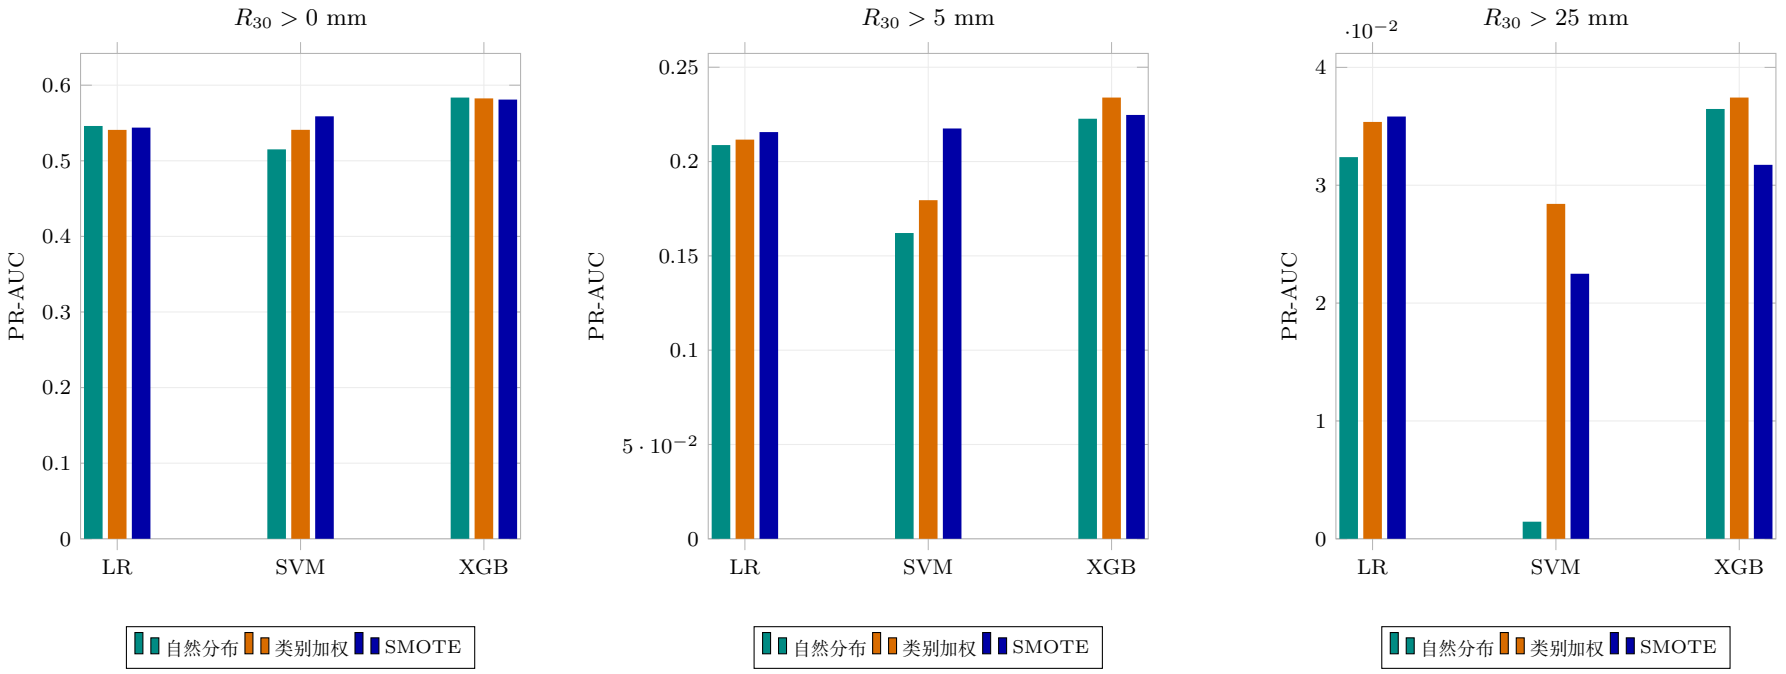
模型选择。原算法比较按 2023 H2 的 PR-AUC 选择算法与训练策略，以 Brier 作为并列判据。最终网格模型的超参数按 2022 年 PR-AUC 选择，校准与未校准管线按 2023 H2 Brier 选择。所有分类判别阈值在相应验证预测上按 F1 确定，用于测试 Precision、Recall、F1 和 Accuracy；它与定义标签的雨量阈值不同。2024 年结果不参与本轮选择。

算法 / 策略	选择 PR-AUC：0 mm	5 mm	25 mm
Logistic / 自然分布	0.54605	0.20874	0.03239
Logistic / 类别加权	0.54088	0.21162	0.03537
Logistic / SMOTE	0.54389	0.21562	0.03583
SVM / 自然分布	0.51511	0.16211	0.00145
SVM / 类别加权	0.54095	0.17952	0.02842
SVM / SMOTE	0.55882	0.21753	0.02249
XGBoost / 自然分布	0.58363	0.22270	0.03647
XGBoost / 类别加权	0.58252	0.23392	0.03744
XGBoost / SMOTE	0.58096	0.22471	0.03173

迭代状态。正式比较中，Logistic 的九个模型有 0 个达到 100 次迭代上限，SVM 的九个模型有 9 个达到该上限。

选定模型。原算法比较在三个目标上均选择 XGBoost：0 mm 使用自然分布，5 与 25 mm 使用类别加权。图 7 和图 8 保留该原始比较。最终预测入口统一采用第 7.1 节的三个网格搜索模型，其指标和曲线在下文单独呈现。

图 7：训练策略的验证集比较



验证比较。相对于自然分布训练，类别加权在 9 个算法与目标组合中的 7 个组合提高 PR-AUC，SMOTE 在 6 个组合提高 PR-AUC。因此，不平衡处理的收益需要根据算法与预测目标分别评价。所有比较采用相同完整训练期与相同验证记录。

7.1. XGBoost 网格搜索与最终模型

网格设计。固定 XGBoost 算法，对每个雨量阈值独立遍历四个参数候选集合的完整笛卡尔积，共 $2^4 = 16$ 组，三个目标共 48 个候选拟合。树数量为 100 或 200，深度为 4 或 6，学习率为 0.05 或 0.1，L2 正则为 1 或 5。其余固定为 128 bins、最小子节点权重 20、L1 正则 0、行和列采样比例 1。0 mm 使用自然分布，5 与 25 mm 使用类别加权。使用按年份划分的验证集，而非随机折叠交叉验证；不抽样训练行，不使用 early stopping。

参数选择与重训。每个候选使用完整 2017–2021 年数据，并按 2022 年 Spark 精确 PR-AUC 排序，Brier 作为并列判据。选定参数后，在全部 2017–2022 年记录上重新拟合预处理和分类器。2023 年上半年拟合单调 Platt 校准，下半年按 Brier 在校准与未校准管线中选择，并按 F1 选择分类判别阈值。最终模型在读取本轮 2024 年测试结果前固定。

雨量阈值 mm	树数量	深度	学习率	L2 正则	最终概率	2022 PR-AUC
0	100	6	0.05	5	未校准	0.61137
5	100	6	0.05	5	Platt 校准	0.25174
25	100	4	0.05	5	Platt 校准	0.03050

8. 2024 年测试结果

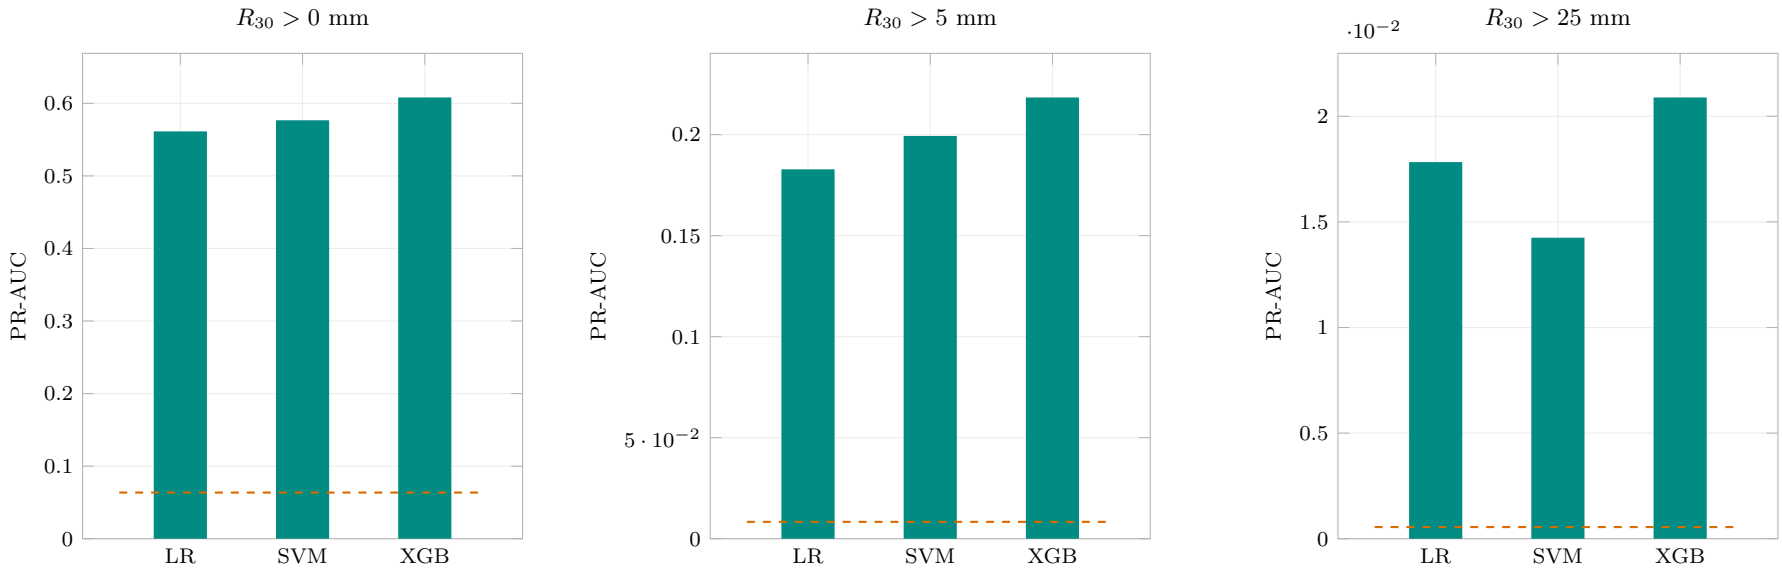
阈值 mm	原算法	验证选定策略	ROC-AUC	PR-AUC	Brier
0	Logistic	自然分布	0.85625	0.56134	0.0392597
0	SVM	SMOTE	0.85451	0.57665	0.0401863
0	XGBoost	自然分布	0.87908	0.60809	0.0364909
5	Logistic	SMOTE	0.85293	0.18282	0.0075397
5	SVM	SMOTE	0.72667	0.19935	0.0077310
5	XGBoost	类别加权	0.87952	0.21839	0.0072009
25	Logistic	SMOTE	0.86018	0.01783	0.0005496
25	SVM	类别加权	0.85936	0.01425	0.0005487
25	XGBoost	类别加权	0.90435	0.02089	0.0005449

测试样本。上表为原算法比较；下表为最终网格模型。每个目标在 2024 年均评价 6,374,476 个有效窗口，正例比例分别为 6.3602%、0.83447% 和 0.055173%。最终 0 mm 概率未经校准，5 与 25 mm 已校准。

阈值 mm	网格模型	数据集	ROC-AUC	PR-AUC	Brier
0	XGBoost	2023 H2 验证	0.88141	0.58987	0.0343148
0	XGBoost	2024 测试	0.88002	0.61218	0.0361268
5	XGBoost	2023 H2 验证	0.89386	0.23927	0.0070153
5	XGBoost	2024 测试	0.88159	0.22511	0.0071700
25	XGBoost	2023 H2 验证	0.91441	0.03934	0.0007187
25	XGBoost	2024 测试	0.90309	0.02118	0.0005448

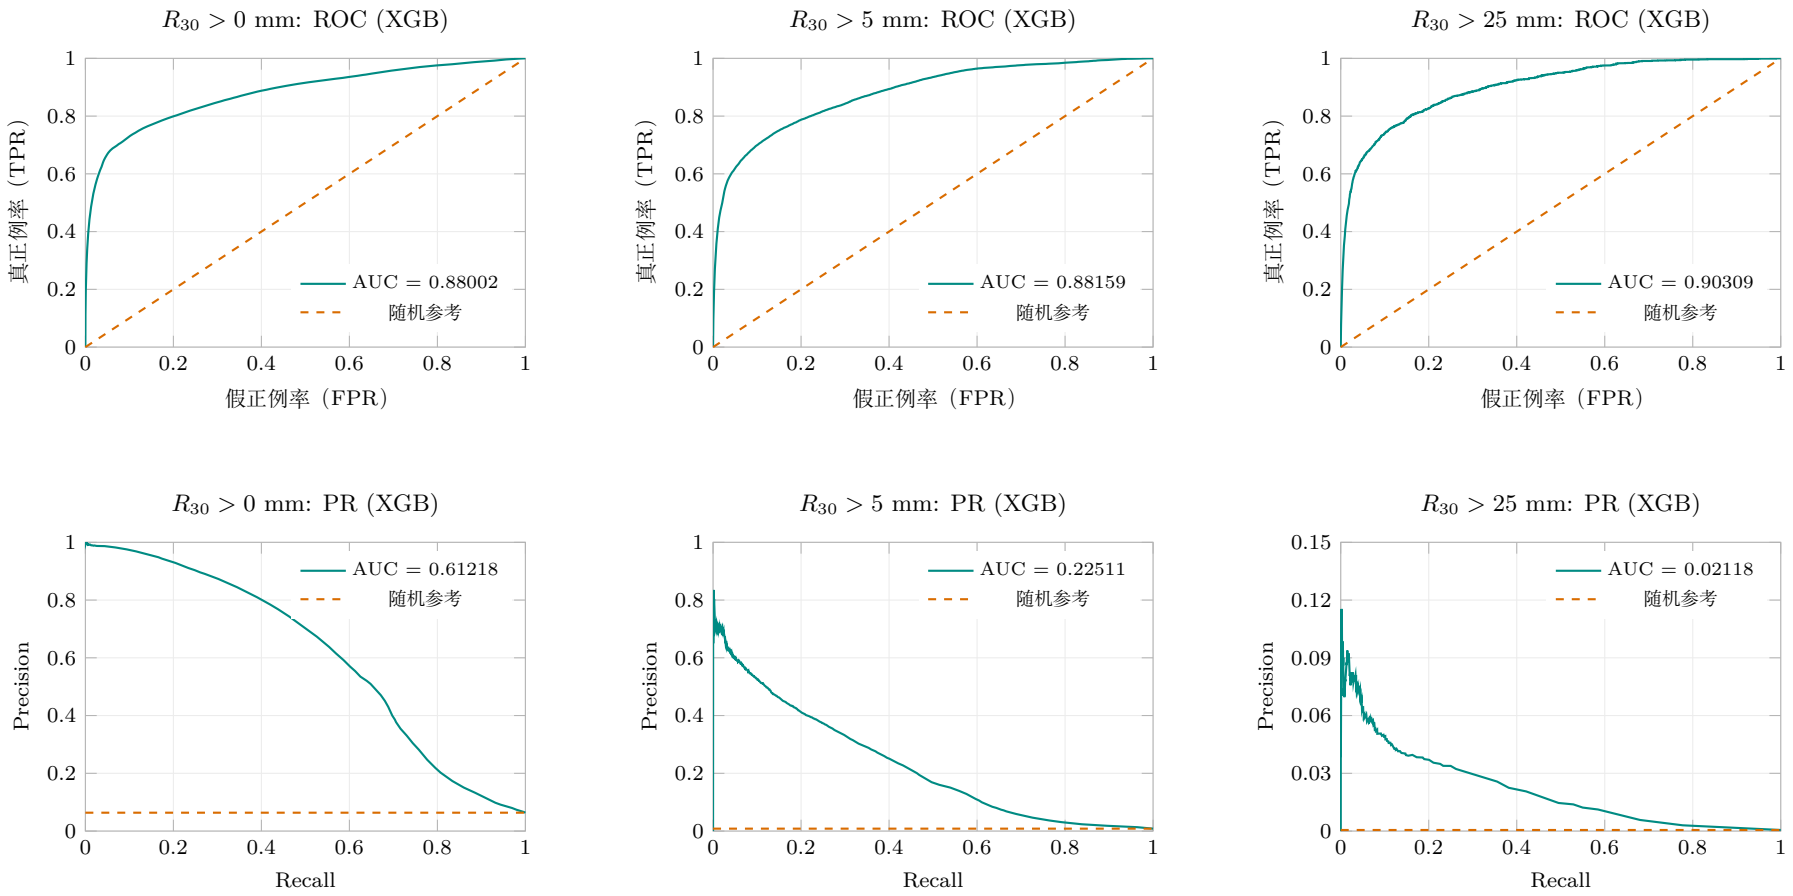
跨时期比较。2022 年指标对应 2017–2021 年训练的候选模型；2023 H2 与 2024 年指标对应 2017–2022 年重训后的固定模型。各时期正例比例不同，PR-AUC 变化同时受到模型与事件发生频率影响，不能将它直接解释为性能提升或下降。

图 8：原算法比较的测试集 PR-AUC



测试比较。图 8 为原算法比较，三个 XGBoost 的测试 PR-AUC 为 0.60809、0.21839、0.02089。最终网格模型分别为 0.61218、0.22511、0.02118，均略高；但 25 mm 的 ROC-AUC 与 F1 下降，因此不能称为所有性能均改善。最终 5 mm 的 PR-AUC 也低于此前单独调参模型的 0.22640。测试结果用于报告，不用于重新选择参数或模型。

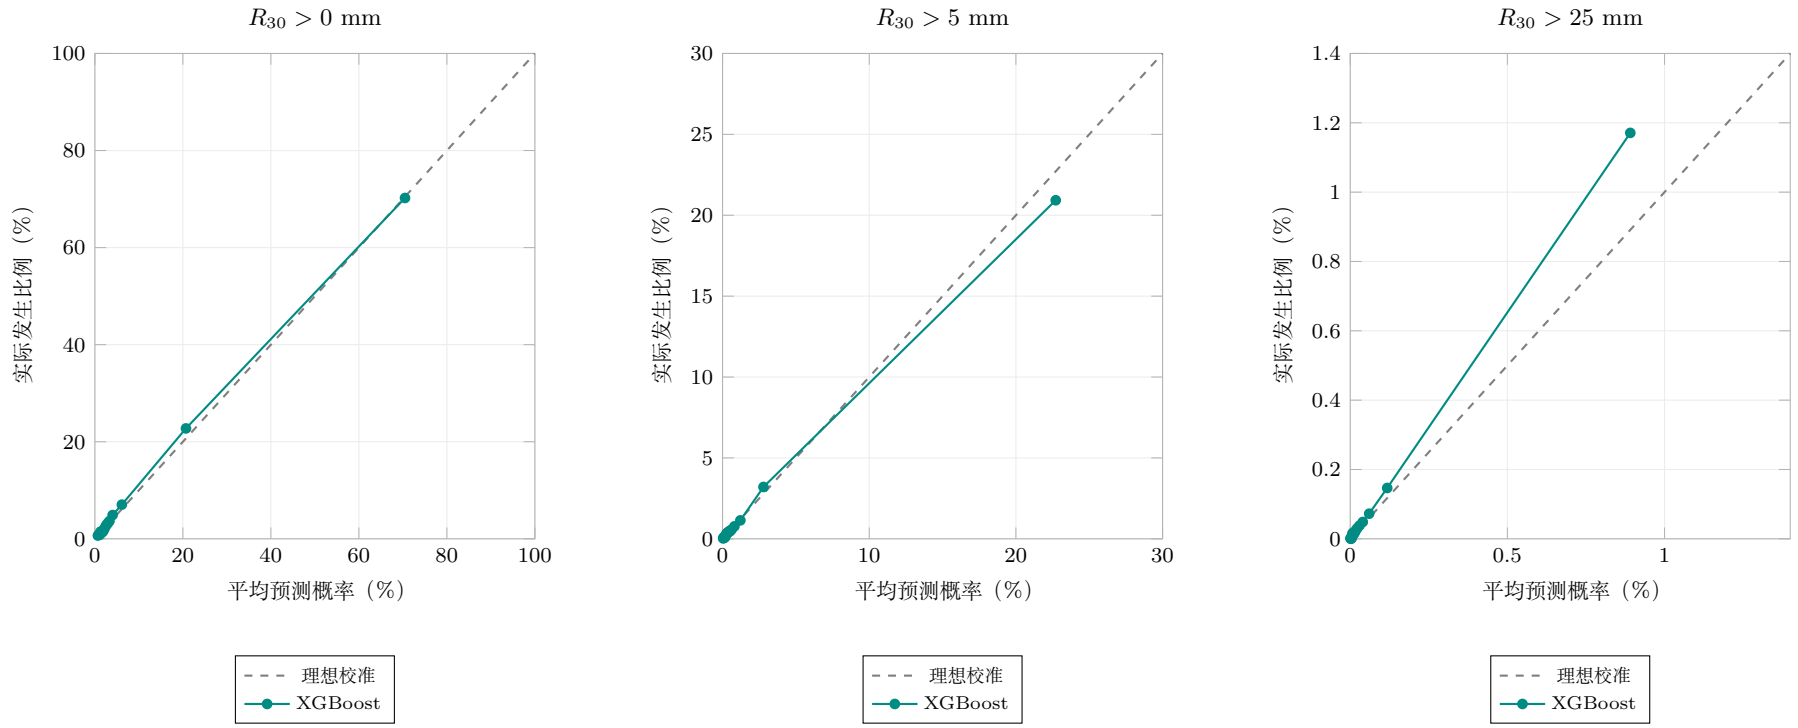
图 9：最终选定模型的 ROC 与 PR 曲线



评价对象。曲线对应固定的三个网格模型，按 0、5、25 mm 排列；全部使用 2017–2022 年重训，并在完整 2024 年测试窗口上评价。图中坐标是经有界简化保留的实际曲线点，AUC 由全部分数精确计算。ROC 虚线为 $y = x$，PR 虚线为测试正例比例；25 mm 的 PR 纵轴放大至 0–0.15。

排序表现。最终三个模型的 ROC-AUC 分别为 0.88002、0.88159、0.90309，PR-AUC 分别为 0.61218、0.22511、0.02118。较高雨量阈值对应更稀少的事件，应结合 PR 曲线和正例比例解释较高的 ROC-AUC。

图 10：校准曲线与概率质量



概率质量。三个目标的平均预测概率为 6.1816%、0.8603%、0.0426%，实际发生比例为 6.3602%、0.8345%、0.0552%。每个点汇总一组相近预测概率的窗口，灰色虚线表示理想校准。整体平均值接近并不保证各风险区间均准确。

校准选择。2023 H2 的 0 mm 未校准 Brier 为 0.0343148，优于校准后的 0.0344561，因此保留未校准概率。5 与 25 mm 校准后 Brier 分别为 0.0070153、0.0007187，明显低于其加权模型未校准误差 0.1144999、0.0994519。管线选择只使用验证集，测试集仅评价选定结果。

稀有事件校准。25 mm 的最高平均预测概率组包含 170,814 个窗口，平均预测概率为 0.891%，实际发生比例为 1.171%。该分组结果应结合有限正例数量解释；未计算事件分块置信区间，不宣称统计显著改善。

9. 分类指标与补充分析

阈值 mm	网格模型	判别阈值	Precision	Recall	F1	Accuracy
0	XGBoost	0.285102	0.62658	0.56163	0.59233	0.95083
5	XGBoost	0.194984	0.30804	0.32470	0.31615	0.98828
25	XGBoost	0.031623	0.04585	0.10918	0.06458	0.99825

分类评价。表中判别阈值由验证集确定。高阈值事件中负例占比很大，因此高 Accuracy 不代表有效识别了强降雨；主要比较 ROC-AUC、PR-AUC，并以 Brier score 和校准曲线评价概率。

原 SMOTE 统计。下表对应原比较的合成样本；最终网格模型不使用 SMOTE。

阈值 mm	真实正例	合成行数	增广正例（%）	雨量变化行数	孤立状态复制
0	2,074,430	6,042,534	20.000	3,615,180	263,540
5	279,801	2,518,209	7.550	1,292,705	291,565
25	19,787	178,083	0.570	67,189	54,652

空间与时间依赖。相邻站点可能受同一降雨过程影响，半小时窗口也存在重叠。后续可按日期或降雨事件分组评价，进一步比较模型在不同站点与事件中的稳定性。三个阈值独立训练，后续可研究跨阈值概率的单调约束。

历史调参与空间对照。此前 5 mm 六组配置搜索在 2023 H2 的 PR-AUC 为 0.239991、Brier 为 0.00701053，略优于最终网格模型的 0.239268、0.00701530。为统一三个目标的实验流程，本项目仍固定采用网格模型，并不宣称 5 mm 网格搜索优于此前模型。固定此前参数增加八个空间交互特征后，2023 H2 PR-AUC 为 0.238817、Brier 为 0.00701540，因此未采用该扩展。

预测入口与限制。输入站点、五分钟网格上的预测时间及 0、5、25 mm 阈值，加载对应网格管线并输出超越概率；可显式选择原比较模型。仍依赖已准备的历史特征行，其样本范围受完整未来标签限制，尚非实时服务。三个目标独立训练，无跨阈值概率单调保证。2024 年此前已被原实验查看过；本轮参数与最终模型在重新测试前固定，但此评价属于后续实验，不是研究者完全未见的封存测试。

9.1. 补充实验：距离感知的五邻站特征

目的与边界。本节是在既有网格 XGBoost 主线之外增加的补充实验；默认预测入口和主要结论仍采用第 7.1 节的网格模型。它检验「相邻站点距离不同，邻站降雨的参考价值是否也不同」这一问题。实验只使用预测时点及之前可获得的站点坐标和五分钟降雨读数；不使用未来降雨、验证期或测试期信息来构造任一特征。

特征与训练。树模型的原 73 维向量增加五个最近邻站的 14 个降雨量/可用性变量及其 14 个缺失标记（28 维），再增加五个邻站距离、最近可报告邻站距离、反距离加权雨量、以 5 km 为尺度的指数衰减加权雨量及其 8 个缺失标记（16 维），得到 117 维。距离和邻接关系按在该时点已知的站点坐标建立；填充值只在训练期拟合。实验使用 2017–2022 年的 34,542,285 个合格窗口训练，2023 H1 校准、2023 H2 在 27 个算法/类别策略候选中选择，随后固定模型评估完整的 2024 年。完整距离训练运行于 Google Cloud Compute Engine 的 Ubuntu 24.04 `e2-custom-20-65536` 虚拟机（20 vCPU、64 GiB RAM、200 GB 持久磁盘），使用 Python 3.11.10、Java 17.0.20.1、Spark 3.5.8 与 XGBoost 3.2.0。

2024 年冻结模型结果。三个阈值均选为 XGBoost；0 mm 使用自然类别比例，5 mm 与 25 mm 使用类别加权。

阈值 (mm)	网格 PR-AUC	网格 ROC-AUC	网格 Brier	距离版 PR-AUC	距离版 ROC-AUC	距离版 Brier
0	0.61218	0.88002	0.036127	0.62838	0.89045	0.035469
5	0.22511	0.88159	0.007170	0.23991	0.89277	0.007079
25	0.02118	0.90309	0.000545	0.02367	0.91855	0.000544

解释。距离版在该补充实验的 2024 年结果中三个阈值的 PR-AUC 和 ROC-AUC 都较高，Brier 都较低，说明把距离作为显式信息值得进一步研究。两组模型的特征、参数搜索和模型选择协议并不相同，表中的数值只是补充性对照，不能归因于单一特征，也不构成用测试集重新选择默认模型。2024 年此前已在原实验中查看过；本轮是在固定方案后的后续评估，而非研究者完全未见的封存测试。

10. AI 使用声明与参考文献

AI 使用声明。本项目使用 OpenAI Codex 辅助研究设计、数据处理和模型代码编写、结果核对与报告文字整理。报告中的降雨统计与模型评价结果均来自实际数据处理和模型运行；SMOTE 合成样本仅用于训练。

资料来源。

1. NEA，Historical Rainfall across Singapore，2017–2024 年度数据集。
2. Meteorological Service Singapore，Climate of Singapore。
3. NEA，2019 年气候回顾。用于偏干年份与正位相印度洋偶极子的外部背景，未用作模型预测特征。
4. geoBoundaries，Singapore ADM0；轮廓源自 URA 2016 年资料，ODbL 1.0。
5. Apache Spark 3.5.8，MLlib 分类与回归文档，用于 Logistic 与 Linear SVM 实现；评价采用 Spark BinaryClassificationEvaluator。
6. XGBoost，PySpark Estimator 文档，用于外部 Spark XGBoost 集成；实际安装版本为 3.2.0。
7. scikit-learn，Precision–Recall 文档与概率校准文档。