新加坡历史降雨：时空规律与概率预测

Task 1 与 2：2017–2024 年 Spark 探索与概率预测

小组成员。潘禹翔、侯佳成、吴嘉蕊。

研究内容。本项目利用 2017–2024 年的新加坡降雨观测数据分析时间与空间变化规律，并建立模型，预测监测站在未来 30 分钟内累计雨量超过给定阈值的概率。

数据与方法。使用 NEA / data.gov.sg 的八个年度数据集，源记录共 48,538,713 条，去重后 48,538,627 条，涉及 91 个站点 ID。全量清洗和聚合由 Spark 执行；跨年比较采用 21 个稳定站点，避免监测网络变化混入年度差异。

主要结果。全部有效五分钟区间中 97.08% 无雨。合格日内样本的雨频高峰为新加坡时间 16:00–17:00。月度可用样本平均雨频以 11 月最高、7 月最低，但各月的可用年份及站点组成不完全相同。固定站点样本中，按观测时长归一化的雨量以 2019 年最低、2021 年最高。近距离站点的日雨量相关性总体高于远距离站点；八年不能据此推断长期气候变化。

年份	雨量 / 观测 24h（mm）	雨频（%）	湿区间雨强（mm/5min）	平均覆盖率（%）
2017	6.85	2.85	0.833	94.6
2018	7.10	2.90	0.840	82.9
2019	4.81	1.97	0.841	94.7
2020	7.40	2.92	0.877	95.3
2021	7.84	3.04	0.895	97.8
2022	7.71	3.08	0.868	99.0
2023	7.52	3.16	0.824	95.2
2024	7.11	3.01	0.819	95.6

表中各年均使用相同的 21 个站点，站点等权。雨量指标按观测时长归一化，不能解释为官方年度累计或真实日累计。月度图和日内图的合格样本组成仍可变化。

1. 数据来源、字段与清洗

来源与字段。每条记录包含 observation timestamp、update timestamp、station ID/name/device ID、经纬度、reading update timestamp、reading value、reading type、reading unit 及日期字段。本数据只有降雨相关观测，不包含气温、湿度和风等变量。API 预览只用于确认字段和年度 ID；所有天气结论来自完整文件。

数据核对。下载完整年度 CSV 后，将 Spark 读入的记录数与年度 API 元数据的记录数核对，并检查重复观测、时间对齐和雨量取值。

清洗步骤。Spark 按 Asia/Singapore 解析时间；保留有限、非负、单位为 mm、类型为预期五分钟累计、站点 ID 和时间合法且 CSV 记录有效的行。只有与五分钟网格的距离不超过两秒时才对齐，原始 epoch 同时保留；其他离网格记录排除并审计。按 station ID 与对齐时刻去重，优先保留 reading update 最新的行，再使用原始观测时刻及确定的字段顺序打破并列。年度文件合并后再次检查跨文件重复。

年份	源记录数	删除重复数	偏离网格超过 2 秒	负雨量数	站点数
2017	5,256,106	86	0	0	62
2018	4,594,246	0	0	0	56
2019	5,026,862	0	0	0	54
2020	6,334,473	0	0	0	80
2021	7,044,646	0	0	0	76
2022	7,133,230	0	0	0	72
2023	6,742,890	0	0	0	74
2024	6,406,260	0	0	0	70

清洗结果。86 条重复记录全部来自 2017 年；八年数据中未发现负雨量、偏离五分钟网格超过两秒的时间戳或跨文件重复。缺失时段不计为零雨量。对超过 50 mm/5min 的读数进行额外筛查，本次没有触发该条件的记录。

2. 指标定义与公平比较

设站点在给定时间段内的有效观测数为 N，雨量为 $r_i \geq 0$，有雨区间数为 $W = \sum_i \mathbf{1}(r_i > 0)$，预期日历槽数为 E。本文使用：

$$\begin{aligned} \text{覆盖率} &= N/E, \qquad E = 288 \times \text{日历天数}, \\ \text{雨频（\%）} &= 100W/N, \\ \text{湿区间雨强（mm/5min）} &= \sum_i r_i/W \quad (W > 0), \\ \text{雨量 / 观测 24h（mm）} &= 288 \sum_i r_i/N. \end{aligned}$$

预期日历槽数显式处理闰年；低覆盖率也可能反映站点只运行了部分年份。雨强的分母仅包含有雨区间。对于单个站点和同一时间段，归一化雨量等于 288 × 雨频/100 × 湿区间雨强。分别取站点平均后，该乘积恒等式一般不再成立。归一化雨量不是官方日累计或年度累计，也不能恢复遗漏风暴。

年度固定样本。八年共出现 91 个站点 ID，其中 21 个同时满足：八年均有观测、每年覆盖率至少 80%、经纬度跨度各不超过 0.005°。其余 70 个只是不进入固定站点的跨年比较，清洗时没有删除这些站点的有效观测。21 个站点等权平均；不同分析使用的站点范围见下一页。

月度与日内样本。图 2、4 从这 21 个站点中进一步筛选数据完整的年月或小时组合。月度先对站点等权平均，再对可用年份等权平均；每个合格年月有 17–21 个站点，各月有 6–8 个可用年份。严格要求同站点同月份在八年均达标时，只剩 5、6、7、9、10、12 月，作为额外对照。

空间比较。图 1 使用 2024 年的站点，当年共 70 个，其中 56 个覆盖率至少 90%，用于地图着色，另 14 个以灰色标记。图 5 使用固定 21 站的日累计，要求日覆盖率至少 95%，每对至少有 365 个共同有效日期。80%、90%、95% 是本项目选定的数据完整程度门槛。

3. 计算环境与各项分析的样本范围

计算环境。Task 1 使用 Apple Silicon Mac：10 个逻辑 CPU、16 GiB RAM，macOS 26.5.2 ARM64，Python 3.12.14、Java Temurin 17.0.20.1+1、Spark 3.5.8。Task 2 在 gpushare 运行，环境为 Python 3.11.10、Azul Zulu Java 17.0.20.1、Spark 3.5.8、XGBoost 3.2.0。gpushare 容器配额为 42 CPU、约 667.68 GiB RAM；完整特征的模型训练限定使用 20 个 CPU，默认 driver heap 为 6 GiB。

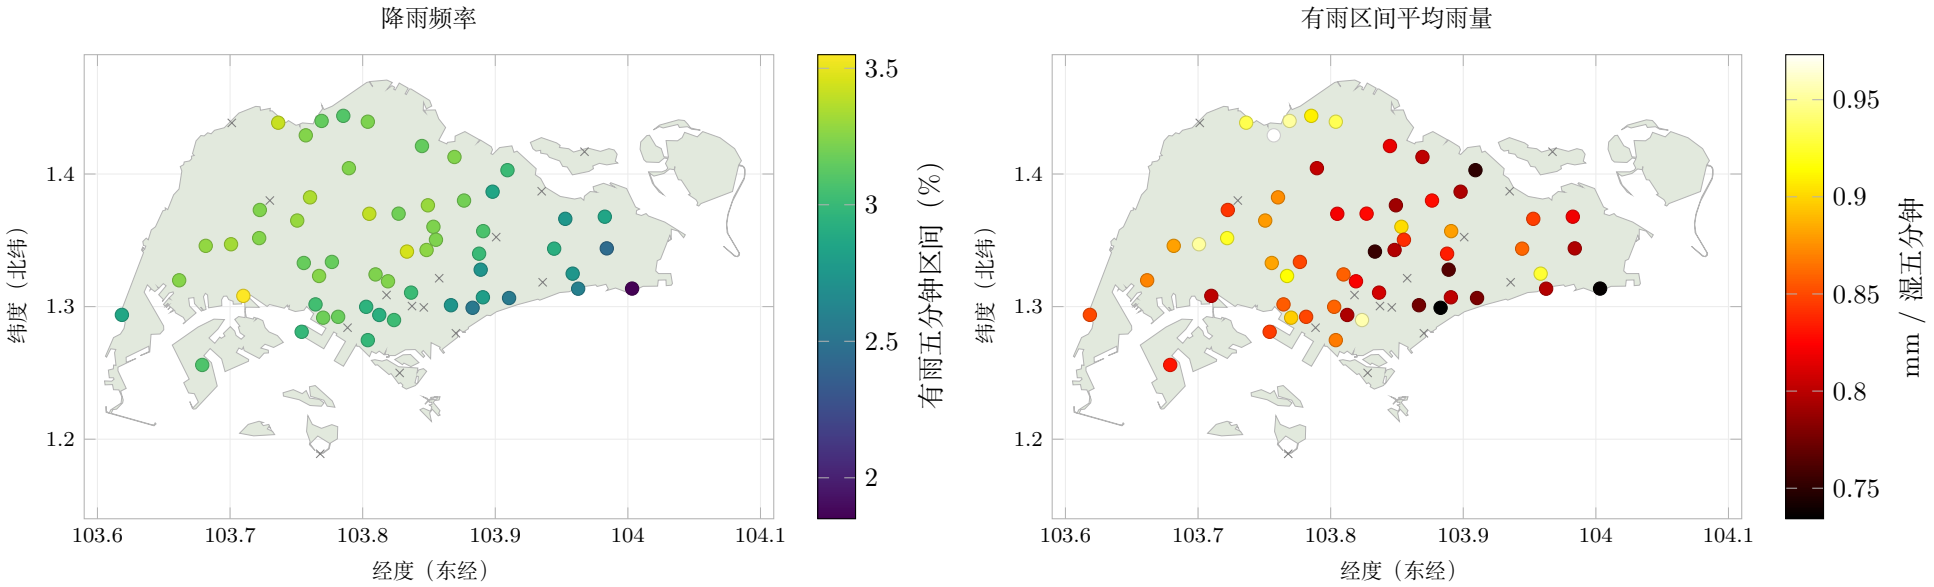
Spark 配置与分工。Task 1 与初始特征组比较采用单机双线程模式 `local[2]`。完整特征的模型比较与评价采用 `local[20]`，shuffle partitions 为 80，default parallelism 为 20。XGBoost 使用两个工作进程，每个任务配置 10 个 CPU。不使用 GPU，以低优先级串行执行各项实验。Spark DataFrame/SQL 与窗口函数用于全量清洗、时间聚合、标签和特征构造；模型训练与评价使用 Spark ML 管线。一般阶段 Java 堆为 6 GiB，进程总内存停止上限为 12 GiB；XGBoost 训练和评价的总内存上限为 40 GiB。

分析样本。各项分析根据比较目的采用相应的站点范围与数据完整性筛选条件，具体见下表。

分析	使用范围	筛选说明
图 1：2024 站点地图	当年 70 站中的 56 站	年覆盖率至少 90%；另 14 站灰色标记
图 2：月度变化	固定 21 站的合格子集	每个合格年月保留 17–21 站
图 3：年度变化	同一组 21 站	其余 70 站不参与固定站点跨年比较
图 4：日内变化	固定 21 站的合格组合	年月小时组合覆盖率至少 80%
图 5：距离与日雨量相关性	固定 21 站，210 对	日覆盖率至少 95%，共同有效日至少 365
图 6 左：有雨时的雨量分布	八年全部 91 站	仅统计有雨五分钟区间
图 6 中、右：半小时超阈值与持续性	2024 年全部 70 站的有效观测	六个未来槽完整，或两个五分钟槽连续

清洗核对。源记录数与 API 计数一致；删除 86 条重复记录，缺失时段不补成零。全部观测的无雨比例也使用全部 91 站，而不是仅使用 21 站。

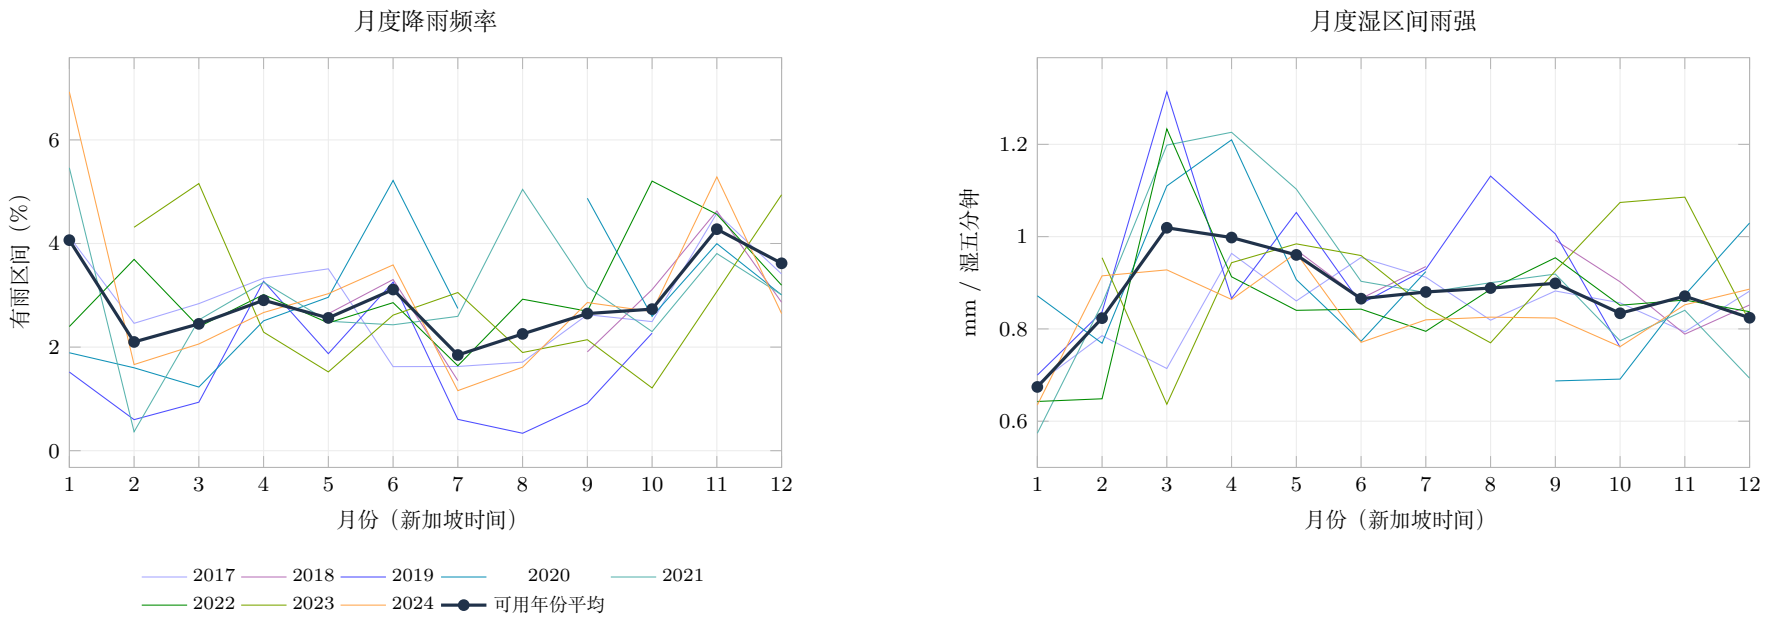
图 1：2024 年观测站降雨地图



2024 年有 70 个站点，其中 56 个年度覆盖率不低于 90%。彩色点只表示该观测站的统计量；灰色叉为低覆盖率站点。S33（Jurong Pier Road）的雨频最高，为 3.55%。地图不进行空间插值，也不代表岛上每个位置的降雨量。边界采用 geoBoundaries 中源自 URA 的 2016 年陆地轮廓（ODbL 1.0），仅作地理参照。

Task 2 特征启示（站点）。候选特征包括站点 ID 和经纬度，以表示站点间差异。Task 2 不直接沿用跨年比较的 21 站限制，而按历史特征及未来标签的完整程度筛选训练窗口。

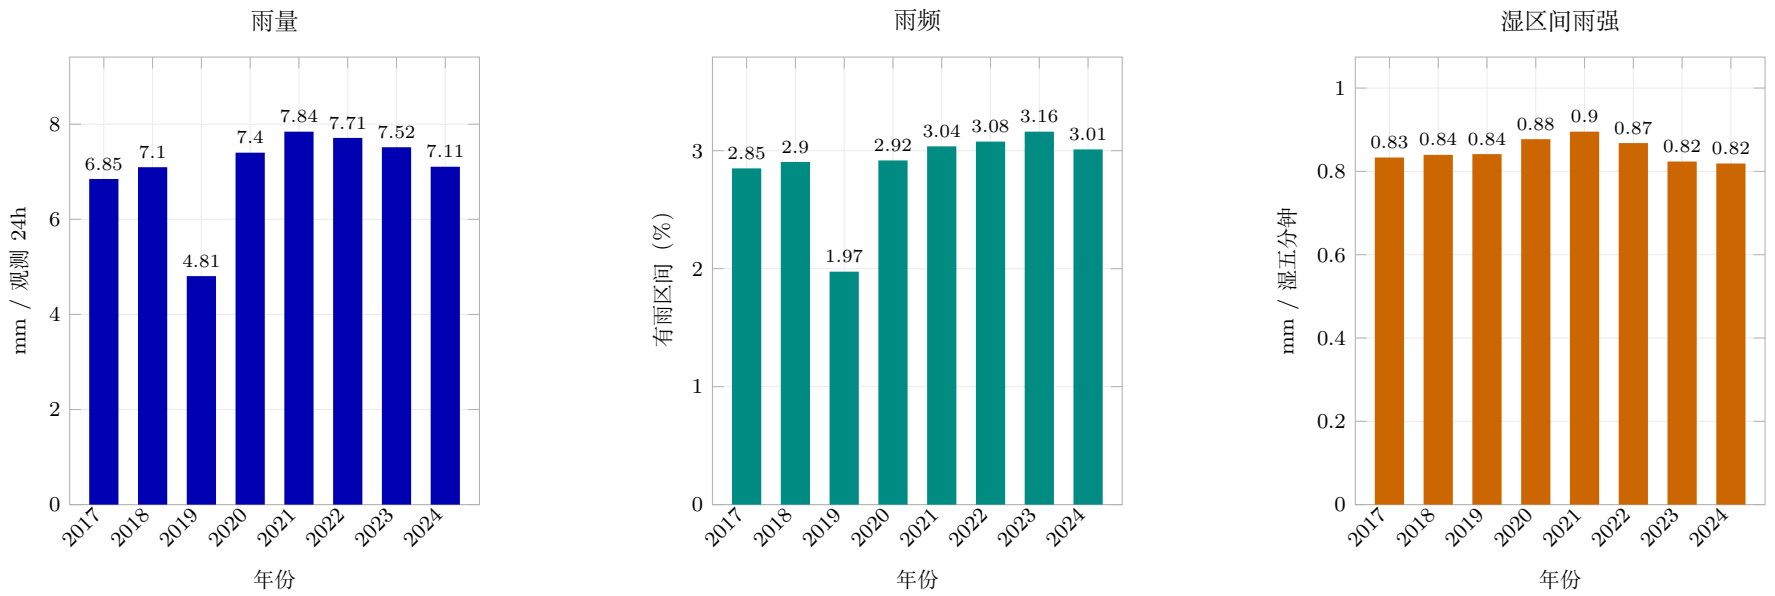
图 2：一年内的月度规律



固定站点样本中，合格站点年月的覆盖率至少为 80%，先对站点等权平均，再对可用年份等权平均。月度平均雨频以 11 月最高（4.28%）、7 月最低（1.85%）；有雨区间平均雨量以 3 月约 1.02 mm、1 月约 0.67 mm。雨频与有雨区间雨量呈现不同的季节变化。各月包含 6–8 个年份，每个合格年月包含 17–21 个站点。

Task 2 特征构造（月份）。月度雨频与雨强的变化模式不同，因而使用月份的正弦、余弦编码表示年内周期，并与小时编码组合，刻画季节与日内降雨规律的共同作用。

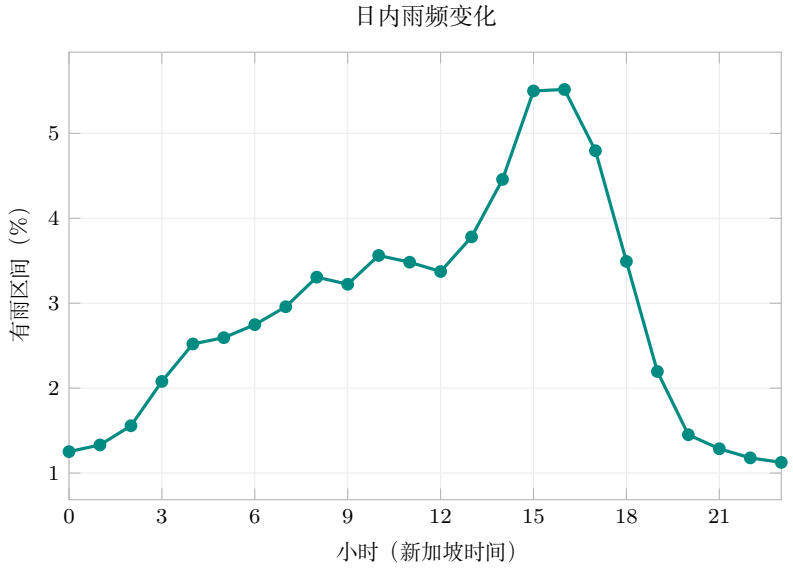
图 3：固定站点的年度变化

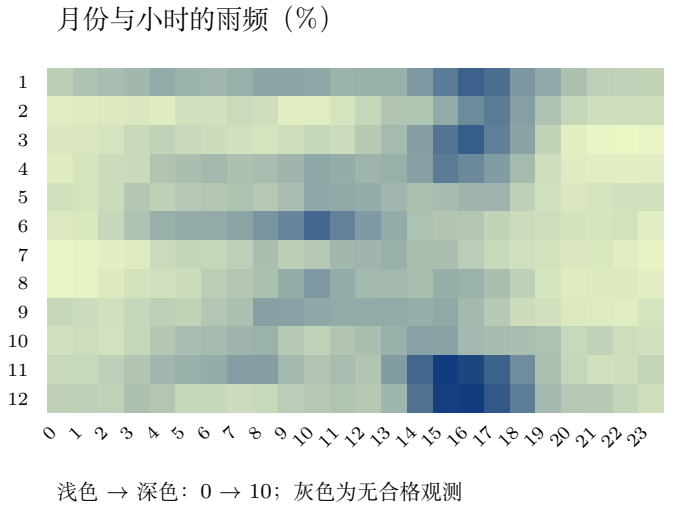


各年采用相同的 21 个站点进行等权比较，每个站点的年度覆盖率至少为 80%。平均雨量 / 观测 24h 从 2019 年的 4.81 mm 到 2021 年的 7.84 mm。2019 年的雨频为 1.97%，明显低于其余年份，而有雨区间雨量为 0.841 mm，与相邻年份接近，表明该年偏低的归一化雨量主要对应较低的降雨频率。

Task 2 特征构造（年份）。训练、验证和测试按年份划分。模型使用月份与小时的周期特征，不加入年份编号。NEA 的 2019 年气候回顾将当年偏干与强正位相印度洋偶极子联系起来，为年际变化提供外部背景。

图 4：降雨频率的日内变化

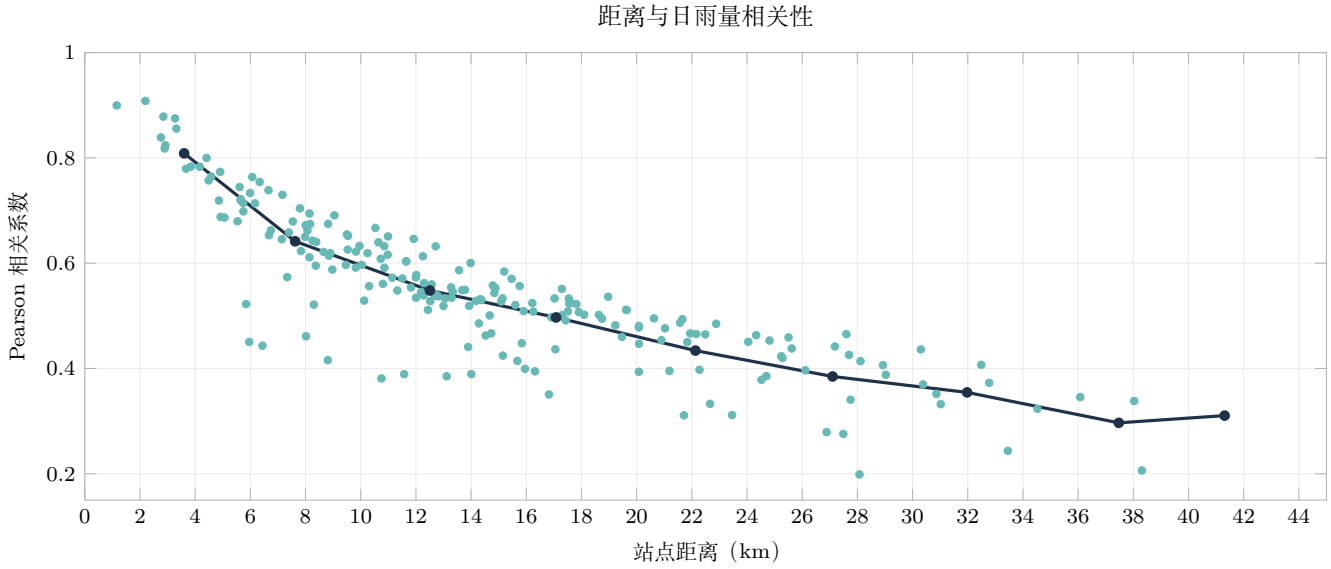




降雨频率在 16:00–17:00 达到日内高峰，且高峰时段与强度随月份变化。11–12 月的下午高峰较明显，6 月的较高雨频更接近上午至中午。统计对覆盖率至少 80% 的站点、年份、月份、小时组合等权平均。该结果支持同时使用小时、月份与二者交互项作为预测特征。

Task 2 特征启示（小时与月份）。使用新加坡当地小时的周期编码，并考虑月份与小时的交互项：下午雨频高峰的强弱和时刻会随月份变化。Logistic 和线性 SVM 需显式构造交互特征；树模型可学习这类组合关系，其实际贡献仍由对照实验检验。

图 5：站点距离与日雨量的相关性

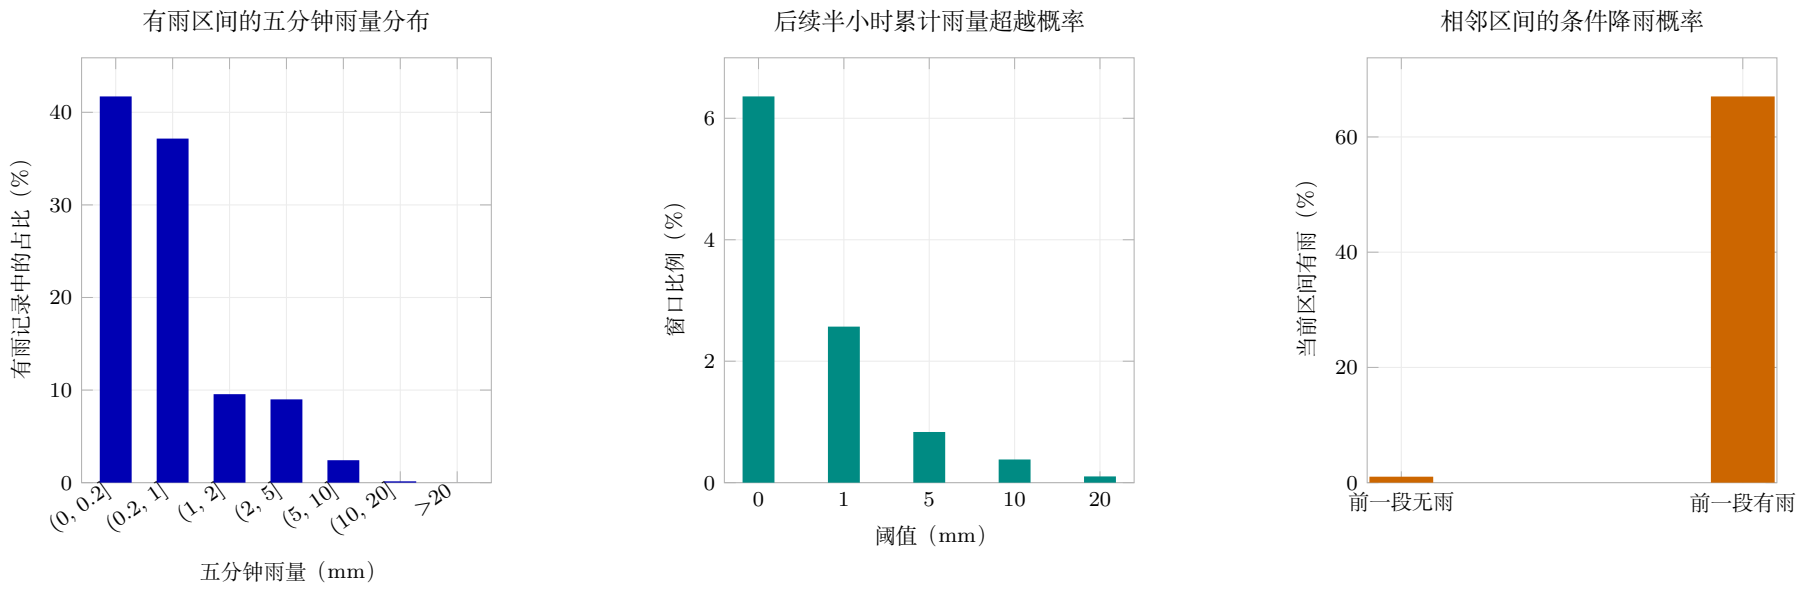


21 个站点形成 210 对站点组合。距离不超过 5 km 的 17 对站点，日雨量平均 Pearson 相关系数为 0.809；距离超过 30 km 的 12 对为 0.336。每 5 km 距离组的平均相关性总体随距离增加而降低，表明降雨具有空间相关性。

站点并非独立。附近站点可能同时经历同一场降雨；不同站点对还可能共享同一个站点。因此，91 个站点不能视为 91 份完全独立的天气样本，210 对相关系数也不是 210 个独立样本。共同有效日的筛选与前文相同。

Task 2 特征构造（邻站）。邻近站点的日雨量呈现较强相关性，因此加入三个最近邻站的历史雨量均值、最大值和有雨比例。Task 2 通过加入邻站特征前后的模型比较，评价其对半小时预测的贡献。

图 6：雨量分布、半小时超越概率与降雨持续性



有雨区间的雨量分布。八年全部站点的有雨五分钟观测中，41.72% 的雨量位于 $(0, 0.2]$ mm，37.16% 位于 $(0.2, 1]$ mm。合计 78.88% 的有雨区间雨量不超过 1 mm，表明多数降雨区间的累计雨量较小。全部有效五分钟观测中的无雨比例为 97.08%。

半小时累计雨量的超越概率。2024 年共有 6,374,476 个完整后续六区间窗口。后续 30 分钟累计雨量严格超过 0 mm 和 5 mm 的窗口比例分别为 6.36% 和 0.83%，超越概率随雨量阈值升高而降低。累计雨量按九位小数比较，以避免阈值边界的浮点误差。图中横轴按阈值类别排列。

相邻区间的降雨持续性。2024 年同站点连续五分钟观测显示，前一区间无雨时，后一区间有雨的条件概率为 1.04%；前一区间有雨时，该概率为 67.03%。降雨具有明显的短时持续性，支持在预测模型中纳入近期雨量及连续有雨时长。

Task 2 特征启示（持续性与稀有事件）。实际特征包括最近读数、过去 15/30/60 分钟累计、近期雨势变化和连续有雨时长。只使用预测时已可获得的记录，缺测不补为无雨。下文逐阈值给出正例数、PR-AUC、Brier score 和校准曲线。

4. Task 2：预测目标与时间切分

预测目标。对于站点 s、时刻 t 和雨量阈值 q，估计未来 30 分钟累计雨量严格超过 q 的概率。设置 $q \in \{0, 5, 25\}$ mm，每个目标分别训练分类器；同一站点时刻保留一份特征与三个标签列。

$$R^{30}_{s,t} = \sum_{k=1}^{6} r_{s,t+5k\,\min}, \qquad y^{(q)}_{s,t} = \mathbf{1}(R^{30}_{s,t} > q), \qquad \hat{p}_q = P(y^{(q)} = 1 \mid x_{s,t}).$$

标签构造。将时间戳作为五分钟区间的终点，累计 $(t, t+30\text{min}]$ 内六个有效区间的雨量，保留九位小数后与阈值比较。当前区间不计入目标；任一未来区间缺测时不构造标签。累计雨量等于阈值时标签为 0。

用途	有效行数	>0 正例	>5 正例	>25 正例
2017–2022：全部训练记录	34,542,285	2,074,430	279,801	19,787
2023 上半年：概率校准	3,325,499	251,794	30,699	1,532
2023 下半年：模型选择	3,393,373	197,358	28,000	2,487
2024：测试	6,374,476	405,430	53,193	3,517

训练与验证。所有模型及预处理均使用 2017–2022 年全部 34,542,285 条有效训练记录。2023 年上半年拟合概率校准函数，下半年选择模型及概率判别阈值；2024 年用于测试。标签窗口不得跨上述时间边界。校准、选择和测试保留自然类别分布。

5. 从 Task 1 到特征工程

Task 1 依据	构造方式	实际输入
下午高峰随月份变化	小时、月份周期编码与交互	8 个日历特征；不加入年份 ID
站点差异与空间相关	站点 ID、经纬度、三个最近邻站	邻站雨量均值、最大值、有雨比例
短时降雨持续性	最新读数及 5/10/15/30/60 分钟滞后	15/30/60 分钟累计、变化和雨段长度

历史与邻站特征。只使用预测时已可获得的观测，观测时刻和保留的更新时间均不晚于 t。从过去 90 分钟检索历史；最近读数超过 30 分钟时标记不可用。邻站由当时已知坐标确定，聚合三个最近合格邻站的雨量、有效观测数、读数年龄及距离。Spark 窗口函数和连接处理全量记录。

时间编码。令 h 为当地小时（包含分钟的小数部分），m 为月份。小时和月份使用下列周期编码，并将两组编码的四个乘积作为交互项，共形成八个特征。这样 23:00 与 00:00、12 月与 1 月在特征空间中保持接近。

$$h_{\sin} = \sin(2\pi h/24), \quad h_{\cos} = \cos(2\pi h/24), \qquad m_{\sin} = \sin[2\pi(m-1)/12], \quad m_{\cos} = \cos[2\pi(m-1)/12].$$

输入处理。缺失值填补、缺失标志和站点类别词表仅基于完整训练期拟合。线性模型对站点进行 one-hot 编码，树模型使用类别索引；常量特征排除。Logistic 与 SVM 使用特征标准化。通过九个 Logistic 模型比较日历与站点、加入本站历史、再加入邻站历史三组特征。

特征组比较设置。九个特征组比较模型使用 L2 正则参数 0.001，最多迭代 80 次，收敛容差为 10^{-6}。其中 0 个模型达到设定的迭代上限。正式模型比较中的 Logistic 与 SVM 最多迭代 100 次。

特征维度。完整输入包含 45 个数值特征和 27 个缺失标志，加上站点编码后，线性模型为 162 维，树模型为 73 维。

L2 Logistic 特征组	测试 PR-AUC：0 mm	5 mm	25 mm
日历与站点	0.11588	0.01671	0.00139
加本站历史	0.53158	0.15868	0.01482
再加邻站	0.56134	0.17982	0.01713

邻站信息的增量。相对于本站历史模型，加入邻站历史后三个目标的测试 PR-AUC 依次变化 +0.02975、+0.02114、+0.00231。结果与 Task 1 的空间相关性分析一致。

6. 模型、不平衡处理与概率校准

模型	参数
L2 Logistic（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
Linear SVM（MLlib）	$\lambda = 0.001$，标准化，最大迭代 100，容差 10^{-6}
XGBoost（Spark 接口）	80 棵树，深度 4，学习率 0.1，64 bins，子节点权重 20；$L_2 = 1$

训练策略。比较自然分布、类别加权和受约束 SMOTE 三种策略。类别权重为 $w_+ = N/(2P)$、$w_- = N/[2(N-P)]$。SMOTE 目标正例占比为 20%，正例总数最多为原始正例的 10 倍。每种策略均保留全部真实训练记录；合成观测仅添加到训练集。

SMOTE 构造。所有训练正例均可作为合成来源，按站点依次处理以控制内存。只在同站点、相同缺失模式、离散状态及雨量零值模式下检索最多五个近邻。对 16 个连续雨量特征用同一个系数插值，时间编码和其他离散信息保持原值；无合适近邻时复制原样本。

概率校准。利用 2023 年上半年观测拟合 Platt 函数 $\hat{p} = 1/[1 + \exp(-(az + b))]$，其中 z 为基础模型分数，约束 $a \geq 0$。该函数把 SVM 分数转换成概率，并调整类别加权或重采样后的概率尺度。若某组预测概率约为 10%，理想情况下该组实际正例比例也应接近 10%。

7. 评价方法与验证集选择

评价指标。ROC-AUC 评价正负例排序，随机排序的参考值为 0.5。PR-AUC 综合 Precision 与 Recall，适合正例较少的目标；随机排序的 Precision 参考水平约为正例比例 π。两种面积均由 Spark 精确积分计算。Brier score 为预测概率与标签的均方差，越小越好。

模型选择。在 2023 年下半年比较各算法和雨量阈值的训练策略，主要按 PR-AUC 选择，Brier score 作为并列时的依据。概率判别阈值在该验证集上按 F1 选择，用于计算测试 Precision、Recall、F1 和 Accuracy；它与定义标签的雨量阈值不同。测试结果不参与模型选择。

实验说明。预测实验正在以完整训练数据重新估计，本稿不列示尚未完成的模型评价结果。

10. AI 使用声明与参考文献

AI 使用声明。本项目使用 OpenAI Codex 辅助研究设计、数据处理和模型代码编写、结果核对与报告文字整理。报告中的降雨统计与模型评价结果均来自实际数据处理和模型运行；SMOTE 合成样本仅用于训练。

资料来源。

1. NEA，Historical Rainfall across Singapore，2017–2024 年度数据集。
2. Meteorological Service Singapore，Climate of Singapore。
3. NEA，2019 年气候回顾。用于偏干年份与正位相印度洋偶极子的外部背景，未用作模型预测特征。
4. geoBoundaries，Singapore ADM0；轮廓源自 URA 2016 年资料，ODbL 1.0。
5. Apache Spark 3.5.8，MLlib 分类与回归文档，用于 Logistic 与 Linear SVM 实现；评价采用 Spark BinaryClassificationEvaluator。
6. XGBoost，PySpark Estimator 文档，用于外部 Spark XGBoost 集成；实际安装版本为 3.2.0。
7. scikit-learn，Precision–Recall 文档与概率校准文档。